# HIỂU DỮ LIỆU

02

Thuộc tính dữ liệu
Thống kê mô tả
Tương quan
Kiểm định thống kê

Bài giảng Khai phá dữ liệu

**TS. Lê Hoàng Quỳnh**

Trường Đại học Công nghệ,
Đại học Quốc gia Hà Nội

lhquynh@vnu.edu.vn

# Nội dung

01 Giới thiệu

02 Khám phá dữ liệu

03 Thống kê mô tả dữ liệu

04 Các mối quan hệ trong dữ liệu

05 Bài tập, tài liệu và tổng kết

**Hiểu dữ liệu**
**để chọn phương pháp**
**khai phá phù hợp.**

# Nội dung bài học

01 **Giới thiệu**

02 Khám phá dữ liệu

03 Thống kê mô tả dữ liệu

04 Các mối quan hệ trong dữ liệu

05 Bài tập, tài liệu và tổng kết

TRONG PHẦN NÀY

Khám phá dữ liệu trước khi mô hình hóa

Vị trí trong quy trình CRISP-DM

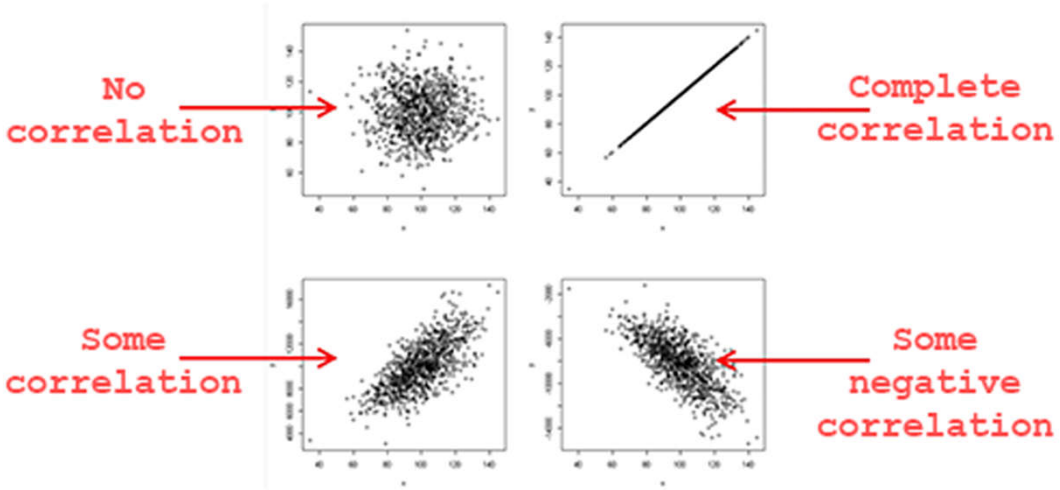
# Khám phá dữ liệu trước khi mô hình hóa

***Play with data first!***

## Bản chất và đặc điểm

- Kiểu dữ liệu
- Dữ liệu có nhiễu, không đầy đủ, thiếu giá trị hoặc mất cân bằng không?
- Tóm tắt dữ liệu bằng thống kê mô tả
- Phân bố và quan hệ:
  - Hình dạng và phân bố của dữ liệu
  - Tương quan
  - Các quan hệ phụ thuộc

  *(cả tường minh và tiềm ẩn)*

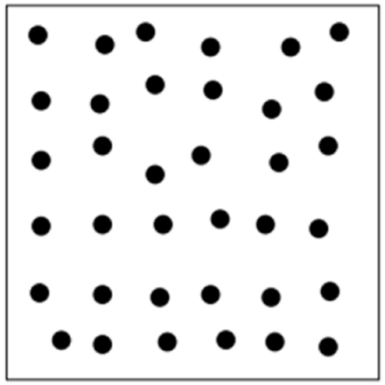



**Chỉ áp dụng học máy hoặc học sâu sau khi đã hiểu dữ liệu!**

# Làm đúng cách hay chọn đúng việc?

***Do things right or do the right things?***

- Mối quan hệ giữa dữ liệu đầu vào và mục tiêu phân tích có phù hợp không?
  - *Quảng cáo dựa trên đến sở thích người dùng?*
  - *Giới tính có liên quan đến sở thích đọc sách không?*



- Có thể và có nên áp dụng phân cụm cho bất kỳ tập dữ liệu nào không?
- Mô hình chủ đề sẽ ra sao nếu dữ liệu quá thưa và thiếu các từ đồng xuất hiện?
- Khai phá mẫu phổ biến có ý nghĩa gì nếu dữ liệu chứa nhiều mục vốn đã rất phổ biến?

# Quy trình CRISP-DM

## CRISP-DM là gì?

Cross-Industry Standard Process for Data Mining: quy trình KPDL chuẩn tham chiếu công nghiệp

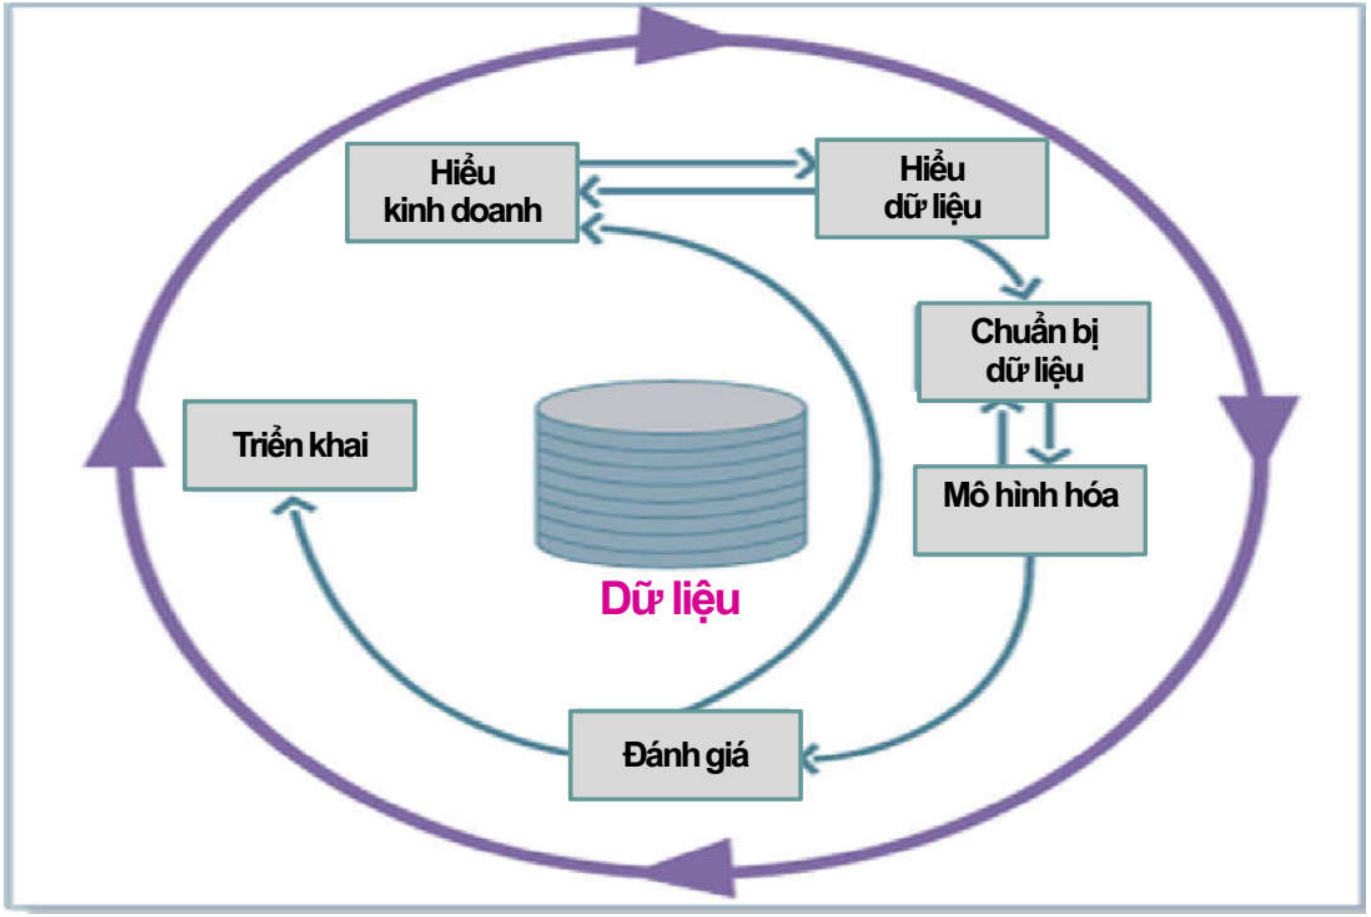
Công bố năm 2000 nhằm chuẩn hóa quy trình phân tích và khai phá dữ liệu.

Đây là một quy trình được sử dụng phổ biến.

## Sáu giai đoạn

1. Hiểu bài toán nghiệp vụ/hiểu kinh doanh
2. Hiểu dữ liệu
3. Chuẩn bị dữ liệu
4. Mô hình hóa
5. Đánh giá
6. Triển khai

# Quy trình CRISP-DM



# CRISP-DM Giai đoạn 1: Hiểu bài toán nghiệp vụ

### Xác định mục tiêu nghiệp vụ

Làm rõ mục tiêu cần đạt và tiêu chí đánh giá thành công.

### Đánh giá hiện trạng

Xem xét nguồn lực, yêu cầu, giả định, ràng buộc, rủi ro và phương án dự phòng. Phân tích chi phí và lợi ích.

### Xác định mục tiêu khai phá dữ liệu

Chuyển mục tiêu nghiệp vụ thành mục tiêu kỹ thuật và tiêu chí thành công tương ứng.

### Lập kế hoạch dự án

Xác định công cụ, kỹ thuật và kế hoạch chi tiết cho các giai đoạn tiếp theo.

# CRISP-DM Giai đoạn 1: Hiểu bài toán nghiệp vụ (tiếp)

## 5 yếu tố cốt yếu dưới dạng 5 câu hỏi

- Ta đã biết (có được gì)?
- Cần quyết định điều gì?
- Cố gắng đạt được cái gì?
- Điều gì/ yếu tố nào cản trở bài toán?
- Tìm hiểu thêm được gì?

# CRISP-DM Giai đoạn 2: Hiểu dữ liệu

### Thu thập dữ liệu ban đầu (Collect)

Lấy dữ liệu từ các nguồn và nạp vào môi trường phân tích.

### Mô tả dữ liệu (Describe)

Xem định dạng, số lượng bản ghi, số trường và đặc điểm của từng trường.

### Khám phá dữ liệu (Explore)

Dùng truy vấn và trực quan hóa để phát hiện các quan hệ, xu hướng và nhóm dữ liệu.

### Kiểm tra chất lượng (Verify data quality)

Nhận diện lỗi, thiếu dữ liệu và các vấn đề cần xử lý ở bước chuẩn bị dữ liệu.

# CRISP-DM Giai đoạn 3: Chuẩn bị dữ liệu

### Lựa chọn

Chọn dữ liệu phù hợp, nêu lý do lựa chọn hoặc loại bỏ.

### Làm sạch

Sửa lỗi, điền giá trị thiếu hoặc loại dữ liệu không phù hợp. Chất lượng đầu vào quyết định chất lượng đầu ra.

*“garbage in, garbage out”*

### Xây dựng/suy diễn

Tạo thuộc tính mới, ví dụ chỉ số BMI.

### Tích hợp

Tích hợp dữ liệu từ nhiều nguồn.

### Chuyển dạng

Định dạng lại dữ liệu cho mô hình, ví dụ chuyển biểu diễn số và chuỗi.

# Nội dung

01 Giới thiệu

**02 Khám phá dữ liệu**

03 Thống kê mô tả dữ liệu

04 Các mối quan hệ trong dữ liệu

05 Bài tập, tài liệu và tổng kết

TRONG PHẦN NÀY

Thuộc tính dữ liệu

Dữ liệu đơn biến, hai biến và đa biến

Dữ liệu phức tạp và có cấu trúc

# Nội dung

01 Giới thiệu

**02 Khám phá dữ liệu**

03 Thống kê mô tả dữ liệu

04 Các mối quan hệ trong dữ liệu

05 Bài tập, tài liệu và tổng kết

TRONG PHẦN NÀY

**Thuộc tính dữ liệu**

Dữ liệu đơn biến, nhị biến và đa biến

Dữ liệu phức tạp và có cấu trúc

# Thuộc tính dữ liệu

- **Thuộc tính mô tả một đặc điểm của đối tượng**

- Trong cơ sở dữ liệu: trường (field), cột (column), thuộc tính (attribute)

- Trong kho dữ liệu: chiều (dimension)

- Trong thống kê: biến (variable)

- Trong học máy: đặc trưng (feature) hoặc chiều (dimension)

- **Ví dụ về dữ liệu sinh viên**

Mã sinh viên, họ tên, giới tính, năm sinh, số điện thoại, địa chỉ, v.v..

- **Mỗi đối tượng dữ liệu còn được gọi là**

- quan sát (observation),

- bản ghi (record),

- mẫu (sample).

# Các kiểu thuộc tính

- Thuộc tính định danh / phân loại (nominal / categorical)
- Thuộc tính nhị phân (binary)
- Thuộc tính thứ bậc (ordinal)
- Thuộc tính số (numeric):
    - Thuộc tính khoảng cách (interval–scaled)
    - Thuộc tính tỉ lệ (ratio–scaled)
    - Thuộc tính rời rạc (discrete) và thuộc tính liên tục (continuous)

# Thuộc tính định danh / phân loại *(nominal / categorical attributes)*

- **Các giá trị biểu thị nhóm hoặc nhãn**
  *symbols or names of things*

- Có thể là ký hiệu, tên, mã hoặc trạng thái.
- Không có thứ tự tự nhiên và không có ý nghĩa số học.
- Ví dụ: nghề nghiệp, màu tóc, mã khách hàng.
- Mã số của nhóm vẫn là dữ liệu phân loại, Dù được viết bằng chữ số.

- **Từ góc nhìn của thống kê mô tả**
  *From the view of descriptive statistics*

- Trung bình (mean) và trung vị (median) không có ý nghĩa.
- Mode cho biết giá trị xuất hiện nhiều nhất.

# Thuộc tính nhị phân *(binary attributes)*

## Chỉ có hai trạng thái

- Là thuộc tính phân loại chỉ có 2 nhóm:
  - 0 là absent và 1 là present.
  - Boolean: true / false.

- Ví dụ:
  - IsStudent: yes/no, true/false, 0/1
  - CovidTest: negative/postivie

## Đối xứng và bất đối xứng

- Nhị phân đối xứng (symmetric):
- Hai trạng thái có vai trò tương đương
- VD nam / nữ

- Nhị phân bất đối xứng (asymmetric):
- Một trạng thái quan trọng hơn
- Thường gán 1 cho trạng thái quan trọng, hơn, hiếm hơn hoặc là nhãn đích dự đoán
- Ví dụ HIVTest: 1 = dương tính, 0 = âm tính.

# Thuộc tính thứ bậc *(ordinal attributes)*

- Các giá trị có thứ tự hoặc thứ hạng.

- Khoảng cách giữa hai giá trị liên tiếp không nhất thiết bằng nhau hoặc có thể đo được.

- Ví dụ:
- cỡ đồ uống S, M, L;
- điểm chữ A+, A, B;
- mức đánh giá từ 1 đến 5.

- Có thể thu được bằng cách rời rạc hóa các đại lượng số, bằng cách chia miền giá trị thành một số hữu hạn các nhóm có thứ tự.

- **Từ góc nhìn của thống kê mô tả**

  - Có thể tính mode và trung vị (median)

  - Không nên tính trung bình (mean) trực tiếp khi chưa có giả định về khoảng cách giữa các mức.

# Thuộc tính số *(numeric attributes)*

- Biểu thị một đại lượng định lượng được (quantitative) hoặc đo lường (measurable) được.
- Giá trị có thể là số nguyên hoặc số thực.
- Hai loại thuộc tính số:
    - Thuộc tính khoảng cách
    - Thuộc tính tỉ lệ

# Thuộc tính số - thuộc tính khoảng cách *(interval-scaled)*

- Được đo trên một thang đo có các đơn vị/khoảng cách bằng nhau.
- Có thể sắp thứ tự và tính chênh lệch giữa các giá trị.
- Giá trị có thể âm, bằng 0 hoặc dương.
- Ví dụ:

- nhiệt độ 15°C, 18°C, 20°C, 25°C, 30°C, …
- các năm 1010, 1945, 1954, 2010, 2026, …

- **Không có điểm 0 tuyệt đối (true zero)**
- Hiệu số có ý nghĩa nhưng tỉ lệ không có ý nghĩa

  - 30°C không có nghĩa là nóng gấp đôi 15°C.

- **Từ góc nhìn của thống kê mô tả**

  - Có thể tính trung bình, trung vị và mode.

# Thuộc tính số - thuộc tính tỉ lệ *(ratio-scaled)*

- **Có điểm 0 thực sự (inherent zero–point)**

- Điểm 0 biểu thị sự vắng mặt của đại lượng đang đo

- Cho phép so sánh thứ tự, chênh lệch và tỷ lệ.

- Ví dụ:
- lương 2.000 USD gấp đôi lương 1.000 USD
- cân nặng
- chiều cao

- **Từ góc nhìn của thống kê mô tả**

- Có thể tính trung bình, trung vị và mode.

Ghi chú biên tập: làm rõ ví dụ kinh độ / vĩ độ trong bản gốc.

# Thuộc tính rời rạc *(discrete attribute)*

- Các thuật toán khai phá dữ liệu thường phân chia thuộc tính thành rời rạc (discrete) hoặc liên tục (continuous) và được xử lý theo các cách khác nhau
- Một thuộc tính rời rạc có một tập giá trị hữu hạn hoặc vô hạn đếm được (countably infinite)
- Giá trị của thuộc tính rời rạc không nhất thiết là số nguyên.
- Ví dụ:
  - màu tóc, giới tính, cỡ đồ uống – có số lượng giá trị hữu hạn → là thuộc tính rời rạc
  - biến nhị phân 0 / 1, tuổi có giá trị là số nguyên [0, 150]
- Một thuộc tính được gọi là **vô hạn đếm được** nếu tập các giá trị có thể có là vô hạn, nhưng các giá trị đó có thể ánh xạ một-một với các số tự nhiên.
  - Ví dụ: tập mã khách hàng CustomerID

# Thuộc tính liên tục *(continuous attribute)*

- Thuộc tính không rời rạc được xem là thuộc tính liên tục.
- Trong nhiều tài liệu, “numeric” và “continuous” đôi khi được dùng thay thế nhau.

➔ Cần phân biệt khi phân tích:
  - Dữ liệu số có thể là số nguyên hoặc số thực,
  - Có thể rời rạc hoặc liên tục.

# Nội dung

01 Giới thiệu

**02 Khám phá dữ liệu**

03 Thống kê mô tả dữ liệu

04 Các mối quan hệ trong dữ liệu

05 Bài tập, tài liệu và tổng kết

TRONG PHẦN NÀY

Thuộc tính dữ liệu

**Dữ liệu đơn biến, nhị biến và đa biến**

Dữ liệu phức tạp và có cấu trúc

# Dữ liệu đơn biến *(univariate data)*

- Một mẫu gồm n quan sát của một thuộc tính X.
- Mỗi quan sát đóng góp một giá trị $x_i$.
- X có thể là thuộc tính phân loại, nhị phân hoặc thuộc tính số rời rạc / liên tục.

Một cột thuộc tính X, với n dòng dữ liệu.

$$D = [x_1, x_2, \ldots, x_n]^T$$

$$\mathcal{D} = \begin{pmatrix} X \\ \hline x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}$$

# Ví dụ dữ liệu đơn biến

**Ví dụ:**

- COVID-19, 12 kết quả: *{âm, dương, âm, âm, âm, dương, âm, âm, dương, âm, âm, âm}.*
- Điểm môn KPDL, 15 sinh viên: {A, A+, B, B, A, B+, A+, A, B, C, C, A, B+, B, A}.
- Bàn thắng của Messi trong 17 mùa: {1, 8, 17, 16, 38,47, 53, 73, 60, 41, 58, 41, 54, 45, 51, 31, 38}.
- Nhiệt độ cao trung bình tháng ở Hà Nội (°C): {19.7, 20.1, 22.9, 27.2, 31.4, 32.9, 33.1, 32.3, 31.2, 28.8, 25.3, 22.0}.

**Phân tích**

- Xu hướng trung tâm: trung bình, trung vị và mode.
- Độ phân tán: khoảng biến thiên, phương sai, tứ phân vị và độ lệch chuẩn, …
- Trực quan hóa: bảng tần số, biểu đồ cột, histogram biểu đồ tròn, …

# Dữ liệu nhị biến *(bivariate data)*

- Mỗi đối tượng có một cặp giá trị ($x_i$, $y_i$) của hai thuộc tính X và Y.
- Mẫu dữ liệu gồm n cặp quan sát.
- Mỗi thuộc tính có thể là thuộc tính số hoặc thuộc tính phân loại.

Hai cột X và Y, với n dòng dữ liệu.

$$D = [(x_1, y_1), (x_2, y_2), \ldots, (x_n, y_n)]^T$$

$$\mathcal{D} = \begin{pmatrix} X & Y \\ \hline x_1 & y_1 \\ x_2 & y_2 \\ \vdots & \vdots \\ x_n & y_n \end{pmatrix}$$

# Ví dụ dữ liệu nhị biến

## Chi phí quảng cáo và doanh thu

| Quảng cáo | Doanh thu |
|---|---|
| 14 500 | 59 000 |
| 19 000 | 64 000 |
| 22 400 | 89 000 |
| 28 900 | 86 000 |
| 30 000 | 94 000 |
| 32 000 | 104 000 |
| 29 000 | 89 000 |
| 28 000 | 82 000 |
| 32 000 | 88 000 |
| 35 000 | 103 000 |
| 29 000 | 94 000 |
| 38 000 | 140 000 |

## Messi và số bàn thắng cho Barcelona

| Mùa | Trận | Bàn |
|---|---|---|
| 2004-05 | 9 | 1 |
| 2005-06 | 25 | 8 |
| 2006-07 | 36 | 17 |
| 2007-08 | 40 | 16 |
| 2008-09 | 51 | 38 |
| 2009-10 | 53 | 47 |
| 2010-11 | 55 | 53 |
| 2011-12 | 60 | 73 |
| 2012-13 | 50 | 60 |
| 2013-14 | 46 | 41 |
| 2014-15 | 57 | 58 |
| 2015-16 | 49 | 41 |
| 2016-17 | 52 | 54 |
| 2017-18 | 54 | 45 |
| 2018-19 | 50 | 51 |
| 2019-20 | 44 | 31 |
| 2020-21 | 47 | 38 |

## Giờ học mỗi tuần và GPA

| Giờ | GPA |
|---|---|
| 6 | 3.2 |
| 9 | 3.8 |
| 10 | 3.9 |
| 13 | 3.6 |
| 6 | 2.5 |
| 5 | 2.7 |
| 7 | 2.9 |
| 19 | 3.9 |
| 20 | 3.8 |
| 14 | 3.4 |
| 10 | 3.1 |
| 7 | 2.6 |
| 4 | 2.2 |
| 8 | 2.9 |
| 4 | 3.2 |

# Phân tích dữ liệu nhị biến

- Xác định các mối quan hệ tiềm ẩn giữa X và Y:
  - tương quan (correlation),
  - liên kết/ liên quan (association),
  - phụ thuộc (dependency),
  - nhân quả (causality).

- Hồi quy hoặc phân loại để dự đoán Y từ X.
  - Dự đoán giá trị của một biến khi biết giá trị của biến còn lại,
  - Suy luận mối quan hệ nhân quả giữa biến phụ thuộc và biến độc lập (cần thêm giả định và thiết kế phù hợp)

- Có thể thực hiện thống kê mô tả và thống kê suy luận.

- **Các cách trực quan hóa**

- Bảng tần số hoặc bảng tỷ lệ hai chiều.

- Biểu đồ cột nhóm và cột chồng.

- Biểu đồ phân tán hoặc biểu đồ chấm.

- Biểu đồ hộp theo nhóm, histogram theo nhóm và bản đồ nhiệt.

# Dữ liệu đa biến *(multivariate data)*

- Mỗi đối tượng có d thuộc tính. Mẫu gồm n đối tượng được biểu diễn bởi ma trận n × d.
- Hàng thứ i là véc-tơ quan sát $x_i = (x_{i1}, \ldots, x_{id})^T$.
- Các thuộc tính có thể là thuộc tính số hoặc phân loại.

**$D = [x_{ij}]$ (n × d) với i = 1, …, n và j = 1, …, d**

$$\mathcal{D} = \begin{pmatrix} X_1 & X_2 & \cdots & X_d \\ \hline x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nd} \end{pmatrix}$$

# Phân tích dữ liệu đa biến

**Véc-tơ trung bình (multivariate mean vector):**

$$\boldsymbol{\mu} = \mathbb{E}[\mathbf{X}] = \begin{pmatrix} \mathbb{E}[X_1] \\ \mathbb{E}[X_2] \\ \vdots \\ \mathbb{E}[X_d] \end{pmatrix} = \begin{pmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_d \end{pmatrix}$$

**Ma trận hiệp phương sai (covariance matrix):**

- Đường chéo chứa phương sai của từng thuộc tính.
- Các phần tử ngoài đường chéo là hiệp phương sai giữa từng cặp thuộc tính.

$$\boldsymbol{\Sigma} = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^T] = \begin{pmatrix} \sigma_1^2 & \sigma_{12} & \cdots & \sigma_{1d} \\ \sigma_{21} & \sigma_2^2 & \cdots & \sigma_{2d} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{d1} & \sigma_{d2} & \cdots & \sigma_d^2 \end{pmatrix}$$

- Phân loại, hồi quy, phân cụm và khai phá luật kết hợp.

- Có nhiều cách trực quan hóa tùy số chiều và mục tiêu phân tích.

# Giả định độc lập và phân phối đồng nhất

*(Independent & Identically Distributed - IID data)*

- **Dữ liệu độc lập và phân phối đồng nhất** là dữ liệu mà mọi quan sát (mọi điểm dữ liệu) là độc lập với nhau và có cùng phân phối xác suất.

**- Dữ liệu đơn biến:** $x_i (i = 1, \dots, n)$ là các quan sát i.i.d. của biến/thuộc tính $X$.
**- Dữ liệu nhị biến:** $(x_i, y_i)(i = 1, \dots, n)$ là các quan sát i.i.d. của hai biến/thuộc tính $(X, Y)$.
**- Dữ liệu đa biến:** $(x_{i1}, x_{i2}, \dots, x_{id})(i = 1, \dots, n)$ là các quan sát i.i.d. của $d$biến/thuộc tính $(X_1, X_2, \dots, X_d)$.

- **Dữ liệu thực tế thường có phụ thuộc**

- Phụ thuộc theo thời gian, không gian, cấu trúc hoặc tham chiếu.

- Những quan hệ này có thể rất mạnh.

- Cần các biểu diễn và phương pháp phù hợp với dữ liệu phức tạp, có cấu trúc.

# Nội dung bài học

01 Giới thiệu

02 **Khám phá**

03 Thống kê mô tả dữ liệu

04 Các mối quan hệ trong dữ liệu

05 Bài tập, tài liệu và tổng kết

TRONG PHẦN NÀY

Thuộc tính dữ liệu

Dữ liệu đơn biến, nhị biến và đa biến

**Dữ liệu phức tạp và có cấu trúc**

# Dữ liệu phức tạp và có cấu trúc

- Chuỗi thời gian
- Chuỗi rời rạc và chuỗi ký tự
- Dữ liệu không gian
- Dữ liệu không-thời gian
- Dữ liệu mạng và đồ thị
- Các dạng dữ liệu khác

# Dữ liệu chuỗi thời gian *(time-series data)*

- Dữ liệu chuỗi thời gian (time-series data) chứa các giá trị thường được tạo ra thông qua việc đo lường liên tục theo thời gian.
- VD:
  - Cảm biến môi trường - liên tục đo nhiệt độ,
  - Điện tâm đồ (ECG) đo các thông số về nhịp tim của một người.
- Loại dữ liệu này thường có mối phụ thuộc tiềm ẩn giữa các giá trị theo thời gian.

- các giá trị liền kề được ghi lại bởi cảm biến nhiệt độ thường thay đổi một cách từ từ theo thời gian;

→Sự phụ thuộc này cần được xem xét một cách rõ ràng trong quá trình khai phá dữ liệu.

- Bản chất của sự phụ thuộc theo thời gian có thể khác nhau đáng kể tùy thuộc vào từng ứng dụng.

# Dữ liệu chuỗi thời gian (tiếp)

## Thuộc tính ngữ cảnh (*Contextual attributes*)

- Dấu thời gian hoặc chỉ số vị trí trong chuỗi.
- Cho biết hoàn cảnh mà phép đo được thu thập.

## Thuộc tính hành vi (*Behavioral attributes)*

- Các đại lượng được đo, chẳng hạn nhiệt độ.
- Nhiều cảm biến được đồng bộ theo thời gian tạo thành chuỗi thời gian đa biến.

**Các thuộc tính ngữ cảnh thường có ảnh hưởng mạnh đến mối quan hệ phụ thuộc giữa các giá trị của thuộc tính hành vi trong dữ liệu.**

# Định nghĩa chuỗi thời gian

**Multivariate time–series data [2]:**

*A time–series of length $n$ and dimensionality $d$ contains $d$ numeric features at each of $n$ time stamps $t_1, t_2, \ldots, t_n$. Each timestamp contains a component for each of the $d$ series. Therefore, the set of values received at timestamp $t_i$ is $\bar{Y}_i = (y_i^1, y_i^2, \ldots, y_i^d)$. The value of the $j^{th}$ series at timestamp $t_i$ is $y_i^j$. The time–series data are $\{\bar{Y}_1, \bar{Y}_2, \ldots, \bar{Y}_n\}$.*

- Ví dụ: xét hai cảm biến tại một vị trí, theo dõi nhiệt độ và áp suất mỗi giây trong vòng một phút.
  - Đây là một chuỗi thời gian đa biến với: $d = 2, n = 60$
  - Trong một số trường hợp, các mốc thời gian $t_1, t_2, \ldots, t_n$ có thể được thay bằng các chỉ số từ $1$ đến $n$, đặc biệt khi các mốc thời gian cách đều nhau.
- Dữ liệu chuỗi thời gian khá phổ biến trong nhiều ứng dụng như dữ liệu cảm biến, y tế, dự báo thời tiết và phân tích thị trường tài chính.

# Chuỗi rời rạc *(discrete sequence)*

- Chuỗi rời rạc là dạng tương tự chuỗi thời gian nhưng giá trị hành vi là các giá trị phân loại.
- Ngữ cảnh là thời gian hoặc chỉ số vị trí.
- Một dãy độ dài n, có d chiều, gồm các quan sát $Y_1, \ldots, Y_n$. Mỗi $Y_i$ chứa d giá trị rời rạc.
- Quan hệ giữa các vị trí vẫn rất quan trọng, dù giá trị không biến thiên liên tục.

# Chuỗi rời rạc (tiếp)

- Chuỗi các lượt truy cập Web, trong đó địa chỉ trang Web và địa chỉ IP nguồn của yêu cầu được thu thập cho 100 lượt truy cập khác nhau

➔Chuỗi rời rạc có độ dài $n = 100$ và số chiều $d = 2$.

- Chuỗi đơn biến, $d = 1$

➔**Chuỗi ký tự (string).**

- Một chuỗi có thể bao gồm kết hợp cả dữ liệu phân loại (categorical) và dữ liệu số (numerical).

- Chuỗi rời rạc có thể được định nghĩa theo nhiều dạng đa dạng hơn dữ liệu chuỗi thời gian, do các phần tử rời rạc có thể được tổ chức thành các tập hợp (sets).

- **Chuỗi các tập hợp (setwise sequences)**
  - Mỗi phần tử của chuỗi không phải là một giá trị phân loại đơn lẻ, mà là một tập gồm số lượng tùy ý các giá trị phân loại không có thứ tự.
  - Ví dụ, dữ liệu giao dịch siêu thị có thể được biểu diễn thành một chuỗi các tập mặt hàng.

# Chuỗi rời rạc (tiếp)

- Thuộc tính ngữ cảnh có thể là vị trí trong không gian vật lý.
- Chỉ số (index) biểu thị vị trí của giá trị trong chuỗi, bắt đầu từ 0 hoặc 1.

  - Nhật ký sự kiện (Event logs):

    $Login \rightarrow Password \rightarrow Login \rightarrow Password \rightarrow Login \rightarrow Password \rightarrow \cdots$

  - Dữ liệu sinh học (Biological data): Các chuỗi có thể là chuỗi nucleotide hoặc amino acid.
- Chuỗi rời rạc thường khó xử lý hơn đối với các thuật toán khai phá dữ liệu vì chúng không có tính liên tục và biến đổi trơn của các giá trị như trong dữ liệu chuỗi thời gian.

# Dữ liệu không gian *(spatial data)*

- Giá trị như nhiệt độ, áp suất hoặc màu điểm ảnh được đo tại các vị trí trong không gian.
- Ví dụ: nhiệt độ mặt biển theo vị trí để nghiên cứu bão.
- Tọa độ đóng vai trò thuộc tính ngữ cảnh. Nhiệt độ là thuộc tính hành vi.
- Thường có hai thuộc tính không gian và có thể có nhiều thuộc tính hành vi, chẳng hạn thêm áp suất.

# Dữ liệu không gian (tiếp)

- Dữ liệu gồm n quan sát d chiều $X_i$, mỗi quan sát gắn với một vị trí $L_i$.
- Thuộc tính hành vi có thể là số, phân loại hoặc kết hợp cả hai.
- Vị trí có thể là tọa độ chính xác, như kinh độ và vĩ độ.
- Vị trí cũng có thể là vùng logic, như thành phố, tỉnh hoặc bang.

# Dữ liệu không gian (tiếp)

- Tương tự chuỗi thời gian, các vị trí gần nhau thường có liên hệ.
- Với dữ liệu số, giá trị ở các vị trí lân cận thường biến đổi tương đối liên tục.
- Cần khai thác tính lân cận trong phân tích và khai phá dữ liệu.
- Dữ liệu không gian cũng có thể mang giá trị phân loại.

# Dữ liệu không-thời gian *(spatiotemporal data)*

## Không gian và thời gian đều là ngữ cảnh

- Ví dụ: theo dõi nhiệt độ mặt biển tại nhiều vị trí qua nhiều thời điểm.
- Các phép đo phụ thuộc đồng thời vào vị trí và thời gian.

## Thời gian là ngữ cảnh, vị trí là hành vi

- Ví dụ: quỹ đạo di chuyển của một đối tượng.
- Tại mỗi thời điểm, dữ liệu ghi lại vị trí không gian của đối tượng.
- Hai cách biểu diễn phục vụ các dạng bài toán khác nhau.

# Dữ liệu mạng và đồ thị *(network and graph data)*

- Đồ thị G = (N, E) gồm tập nút N và tập cạnh E.
- Nút biểu diễn đối tượng. Cạnh biểu diễn quan hệ giữa các đối tượng.
- Thuộc tính thường gắn với nút, nhưng cũng có thể gắn với cạnh.
- $X_i$ là dữ liệu của nút i. $Y_{ij}$ là dữ liệu của cạnh nối i và j.

# Dữ liệu mạng và đồ thị (tiếp)

## Có hướng hoặc vô hướng

- Liên kết web là cạnh có hướng. Quan hệ bạn bè trên Facebook là cạnh vô hướng.
- Cơ sở dữ liệu đồ thị có thể chứa nhiều đồ thị nhỏ, chẳng hạn các phân tử hóa học.

## Thuộc tính trên nút và cạnh

- Web: nút chứa văn bản của trang.
- Mạng xã hội: cạnh có thể chứa nội dung email hoặc hội thoại.
- Hóa học: nút là nguyên tố, cạnh là liên kết. Khai phá để dự đoán khả năng phản ứng hoặc đặc tính dược học.

# Dữ liệu đồ thị (tiếp)

## Từ dữ liệu đa chiều đến đồ thị tương tự

- Mỗi bản ghi đa chiều được chuyển thành một nút.
- Nối các nút dựa trên độ tương tự giữa các bản ghi.
- Phát hiện cộng đồng trên đồ thị để tìm nhóm các nút tương tự.
- Các cộng đồng tìm được tương ứng với các cụm trong dữ liệu ban đầu.

# Các dạng dữ liệu khác

- Văn bản: dãy ký tự, token, từ, cụm từ, câu hoặc đoạn văn.
- Tiếng nói: có thể biểu diễn dưới dạng chuỗi thời gian hoặc dãy.
- Ảnh: dữ liệu không gian.
- Video: dãy các khung hình.

# Nội dung

01 Giới thiệu

02 Khám phá dữ liệu

03 **Thống kê mô tả dữ liệu**

04 Các mối quan hệ trong dữ liệu

05 Bài tập, tài liệu và tổng kết

TRONG PHẦN NÀY

Đo lường xu hướng trung tâm

Đo lường độ phân tán

# Nội dung

01 Giới thiệu

02 Khám phá dữ liệu

03 **Thống kê mô tả dữ liệu**

04 Các mối quan hệ trong dữ liệu

05 Bài tập, tài liệu và tổng kết

TRONG PHẦN NÀY

**Đo lường xu hướng trung tâm**

Đo lường độ phân tán

# Đo lường xu hướng trung tâm *(central tendency)*

- Cho mẫu D gồm n quan sát, cần tìm một giá trị thể hiện vị trí trung tâm hoặc nơi phần lớn dữ
- liệu tập trung.

- Các đại lượng thường dùng:

  **- Trung bình (mean)**

  **- Trung vị (median)**

  **- Mode**

  **- Trung điểm khoảng biến thiên (midrange)**

# Trung bình cộng *(mean)*

- Trung bình cộng là trung bình về mặt toán học
- Trung bình cộng của tập dữ liệu $\mathcal{D} = \{x_1, x_2, \ldots, x_n\}$ gọi là $\bar{x}$ , được tính bằng:

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

# Trung bình cộng (tiếp)

- TB số bàn thắng của Messi cho Barcelona từ mùa 2004–2005 đến mùa 2020–2021:

$$\mathcal{D} = \{1, 8, 17, 16, 38, 47, 53, 73, 60, 41, 58, 41, 54, 45, 51, 31, 38\}$$

$$\bar{x} = \frac{1 + 8 + 17 + \cdots + 51 + 31 + 38}{17} = \frac{672}{17} = 39.53$$

- Trung bình lương (nghìn $) của 12 nhân viên thuộc 1 công ty

$$\mathcal{D} = \{30, 36, 47, 50, 52, 52, 56, 60, 62, 70, 110, 215\}$$

$$\bar{x} = \frac{30 + 36 + 47 + \cdots + 70 + 110 + 215}{12} = \frac{840}{12} = 70$$

# Trung bình có trọng số *(weighted mean)*

- Mỗi giá tị $x_i$ có thể có trọng số $w_i$ (với i = 1, …n)
- Trọng số thể hiện mức độ quan trọng hoặc tần số xuất hiện của giá trị.
- Khi mọi trọng số bằng nhau, công thức trở thành trung bình cộng.

$$\bar{x} = \frac{\sum_{i=1}^{n} w_i x_i}{\sum_{i=1}^{n} w_i} = \frac{w_1 x_1 + w_2 x_2 + \cdots + w_n x_n}{w_1 + w_2 + \cdots + w_n} \quad (7)$$

# Vấn đề của trung bình

## Tác động của giá trị ngoại lai (outliner)

- Một vài giá trị rất lớn hoặc rất nhỏ có thể anh hưởng đến giá trị trung bình
- Trong ví dụ lương, một số ít người có l Lương rất cao (110 và 215 nghìn USD) làm trung bình tăng lên.
- Một vài điểm rất thấp có thể làm điểm trung bình giảm mạnh.

## Trung bình cắt ngọn (trimmed mean)

- Loại một tỷ lệ các giá trị nhỏ nhất và lớn nhất trước khi tính trung bình.
- Ví dụ: loại 2% ở mỗi đầu của dãy đã sắp xếp.
- Cần nêu rõ tỷ lệ và quy tắc cắt khi báo cáo.

# Trung vị *(median)*

- Phù hợp cho dữ liệu bị lệch (skewed, asymmetric) hơn trung bình cộng
- Trung vị là giá trị ở giữa dãy đã sắp xếp,
chia các quan sát thành hai nửa theo thứ tự.
- Áp dụng cho thuộc tính số hoặc thuộc tính thứ bậc.
- Ít chịu ảnh hưởng của giá trị ngoại lai hơn trung bình.

## Cách xác định

- Nếu n lẻ: lấy giá trị ở vị trí chính giữa.
- Nếu n chẵn: trung vị nằm giữa hai giá trị ở giữa.
- Với dữ liệu số, thường lấy trung bình của hai giá trị này.

# Tính trung vị

- Tập dữ liệu gốc: $\mathcal{D} = \{x_1, x_2, \ldots, x_n\}$
- Tập dữ liệu đã sắp xếp: $\mathcal{D}' = \{x'_1, x'_2, \ldots, x'_n\}$
- Công thức trung vị: $median = \frac{x'_a + x'_b}{2}$
- Ví dụ:
  - Bàn thắng của Messi

$\mathcal{D} = \{1, 8, 17, 16, 38, 47, 53, 73, 60, 41, 58, 41, 54, 45, 51, 31, 38\}.$ $median = x'_9 = 41$
$\mathcal{D}' = \{1, 8, 16, 17, 31, 38, 38, 41, 41, 45, 47, 51, 53, 54, 58, 60, 73\}$

  - Lương

$\mathcal{D} = \{30, 36, 47, 50, 52, 52, 56, 60, 62, 70, 110, 215\}$ $median = \frac{52 + 56}{2} = \frac{108}{2} = 54$

# Mode

## Giá trị có tần số xuất hiện cao nhất

- Áp dụng cho cả dữ liệu định tính và định lượng.
- Dữ liệu có thể có: một mode (unimodal) hoặc nhiều mode (multimodal) - hai mode (bimodal), ba mode (trimodal), …
- Nếu mọi giá trị chỉ xuất hiện một lần thì xem như không có mode

### Ví dụ

- Bàn thắng của Messi: $\{1, 8, 17, 16, 38, 47, 53, 73, 60, 41, 58, 41, 54, 45, 51, 31, 38\}$
- Lương của 12 nhân viên:
$$\{30, 36, 47, 50, 52, 52, 56, 60, 62, 70, 110, 215\}$$
- Điểm bằng chữ:
$$\{A, A+, B, B, A, B+, A+, A, B, C, C, A, B+, B, A\}$$

# Trung điểm khoảng biến thiên *(midrange)*

- Là trung bình của giá trị nhỏ nhất và giá trị lớn nhất.
- Ví dụ lương:

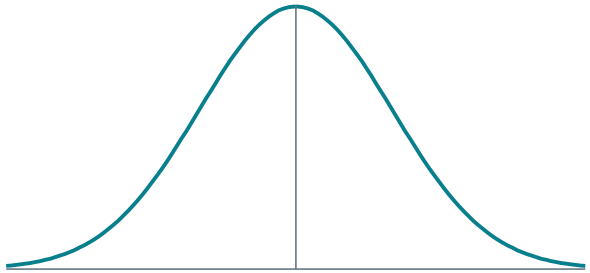
$$\{30, 36, 47, 50, 52, 52, 56, 60, 62, 70, 110, 215\}$$

➔ Midrange = (30 + 215) / 2 = 122.5 nghìn USD.

- Đại lượng này nhạy với giá trị ngoại lai hơn trung bình cộng.

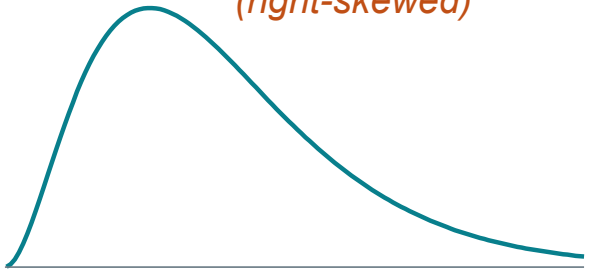
# Trung bình, trung vị và mode khi phân bố lệch

**Đối xứng**



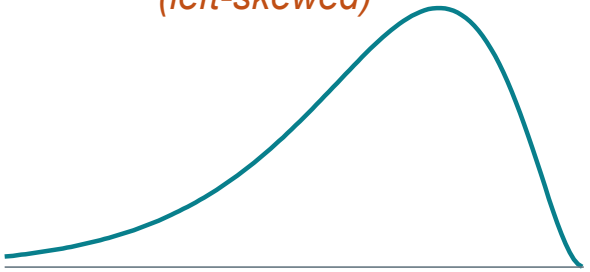
**Trung bình = Trung vị = Mode**

**Lệch phải**
*(right-skewed)*



**Mode < Trung vị < Trung bình**

**Lệch trái**
*(left-skewed)*



**Trung bình < Trung vị < Mode**

- Với phân bố đối xứng hoàn hảo và một đỉnh, trung bình, trung vị và mode trùng nhau.
- Dữ liệu thực tế thường không đối xứng.
  - Ở lệch phải, trung bình nhỏ hơn trung vị.
  - Ở lệch trái, trung bình lớn hơn trung vị.

# Nội dung

01 Giới thiệu

02 Khám phá dữ liệu

03 **Thống kê mô tả dữ liệu**

04 Các mối quan hệ trong dữ liệu

05 Bài tập, tài liệu và tổng kết

TRONG PHẦN NÀY

Đo lường xu hướng trung tâm

**Đo lường độ phân tán**

# Đo lường độ phân tán *(dispersion)*

- Khoảng biến thiên
- Phân vị, tứ phân vị và khoảng tứ phân vị
- Tóm tắt năm số và biểu đồ hộp
- Giá trị ngoại lai
- Phương sai và độ lệch chuẩn

# Khoảng biến thiên *(range)*

- Chênh lệch giữa giá trị lớn nhất và nhỏ nhất trong mẫu.

**Khoảng biến thiên (range) = max − min**

- Bàn thắng của Messi:

$$\{1, 8, 17, 16, 38, 47, 53, 73, 60, 41, 58, 41, 54, 45, 51, 31, 38\}$$

Range = 73 − 1 = 72 bàn.

- Lương: $\{30, 36, 47, 50, 52, 52, 56, 60, 62, 70, 110, 215\}$

Range = 215 − 30 = 185 nghìn USD.

# Phân vị *(quantiles)*

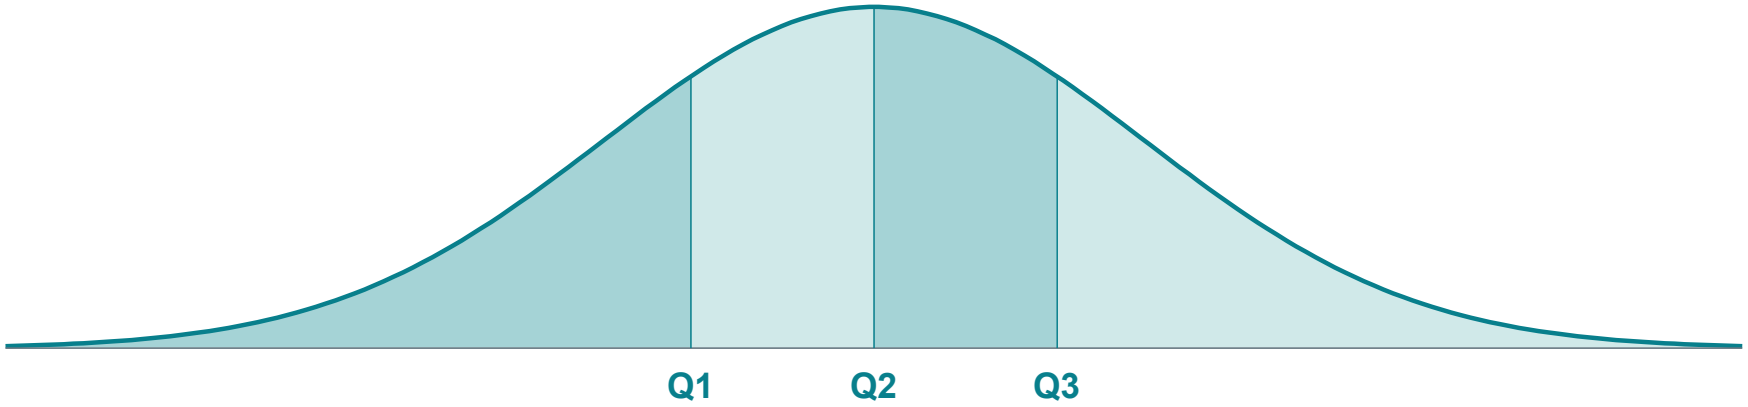
- Giả sử các điểm dữ liệu/giá trị trong mẫu dữ liệu $D$ được sắp xếp theo thứ tự số tăng dần.
- Chọn một số điểm [dữ liệu] nhất định để chia $D$ thành các phần liên tiếp có kích thước bằng nhau.
- **Phân vị (quantiles) là các điểm được lấy tại những vị trí cách đều, nhằm chia mẫu thành các phần liên tiếp có kích thước về cơ bản là bằng nhau.**
- Phân vị thứ $k$ trong $q$-quantile của một mẫu dữ liệu là giá trị $x$ sao cho:
  - có nhiều nhất $k/q$ số giá trị dữ liệu nhỏ hơn $x$;
  - có nhiều nhất $(q-k)/q$ số giá trị dữ liệu lớn hơn $x$;
  - trong đó $k$ là số nguyên thỏa mãn $0 \leq k < q$.
- Có tất cả $q-1$ điểm phân vị.

# Phân vị (tiếp)

## Những trường hợp thường gặp

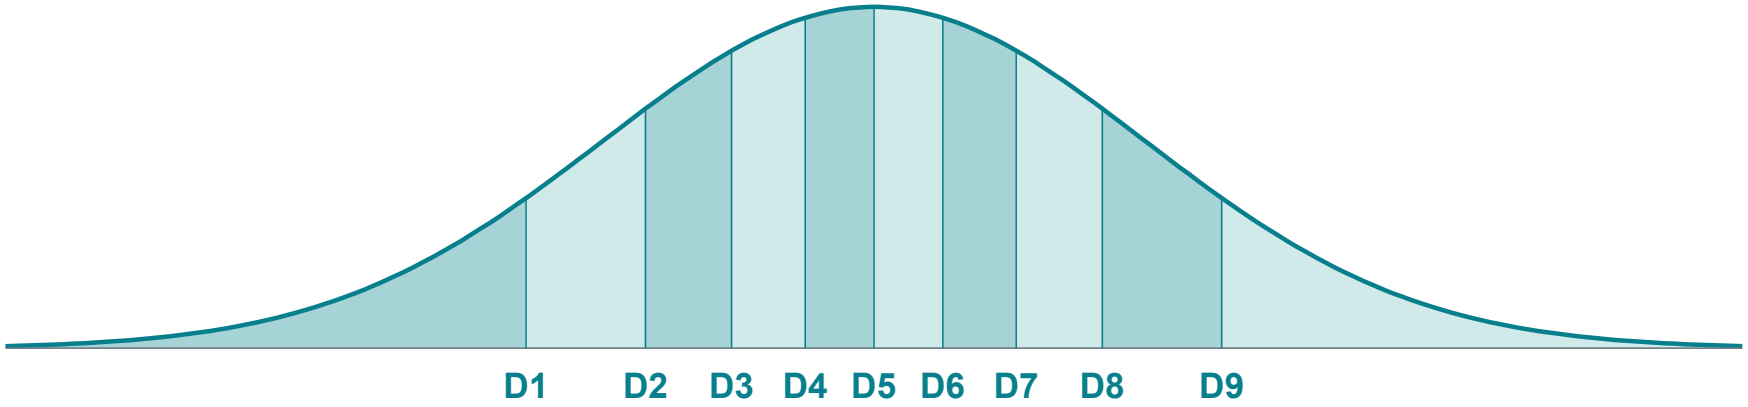
- Tứ phân vị (quartiles): 3 điểm cắt, chia thành 4 phần.
- Thập phân vị (deciles): 9 điểm cắt, chia thành 10 phần.
- Bách phân vị (percentiles): 99 điểm cắt, chia thành 100 phần.

# Tứ phân vị




Ba giá trị $Q_1$, $Q_2$ và $Q_3$ chia phân bố thành bốn phần liên tiếp.

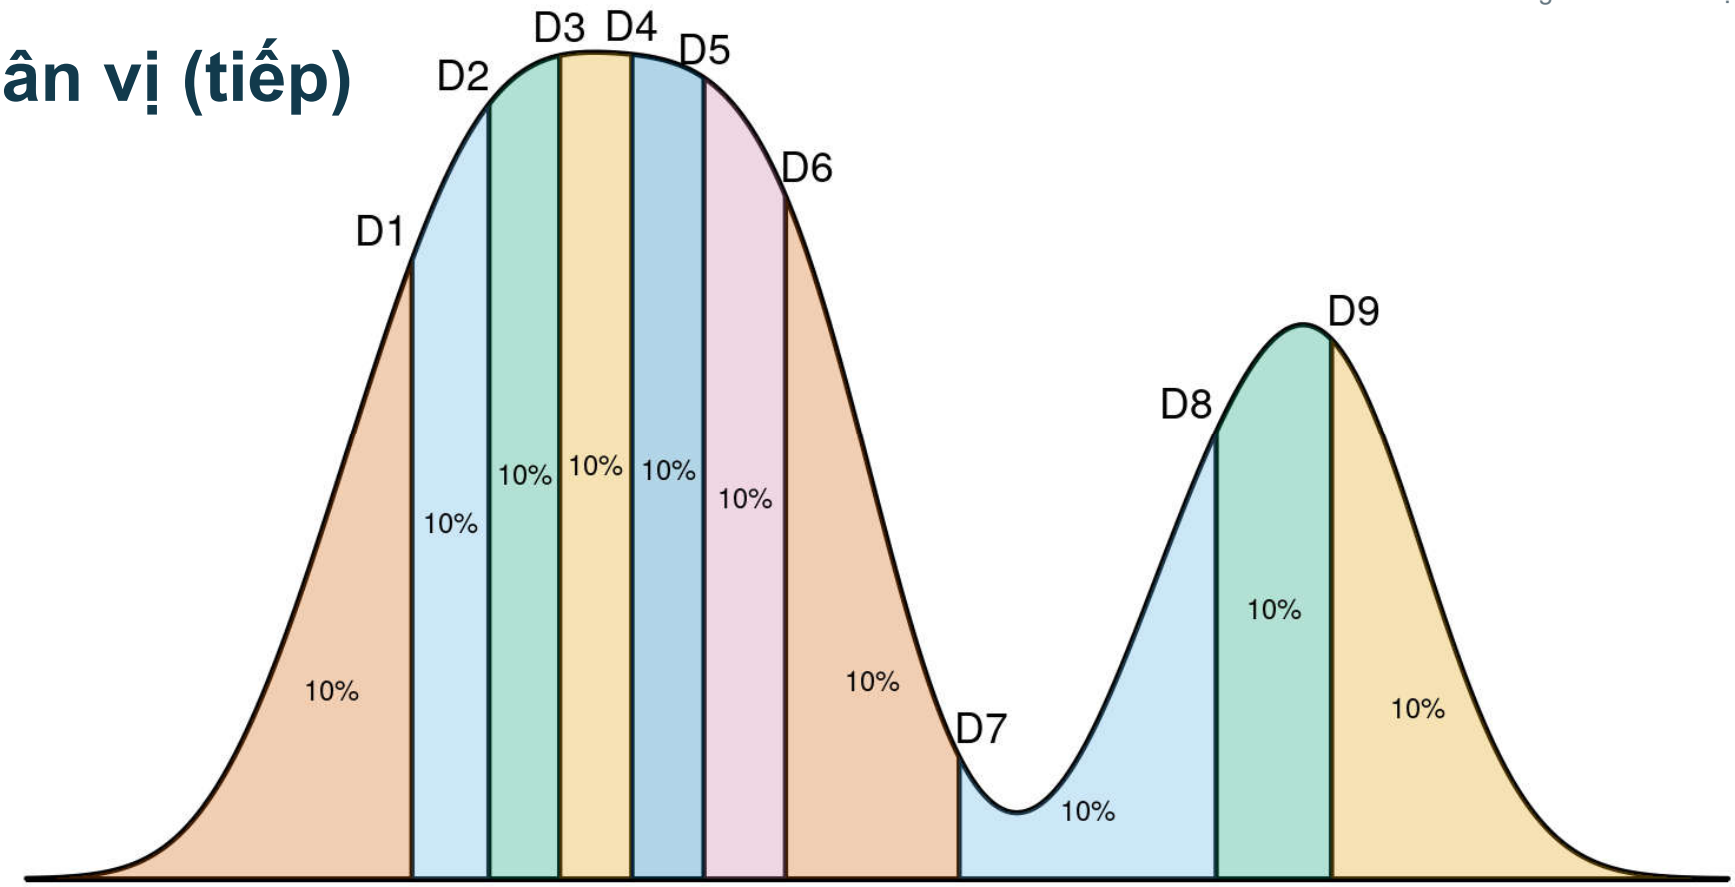
# Thập phân vị




Chín giá trị $D_1$, $D_2$, …, $D_9$ chia phân bố thành 10 phần liên tiếp.

Mỗi phần chiếm 10% xác suất của phân bố.

# Thập phân vị (tiếp)




Chín giá trị $D_1$, $D_2$, …, $D_9$ chia phân bố thành 10 phần liên tiếp.

Mỗi phần chiếm 10% xác suất của phân bố.

# Khoảng tứ phân vị *(interquartile range, IQR)*

- Khoảng cách giữa tứ phân vị thứ nhất $Q_1$ và tứ phân vị thứ ba $Q_3$ là một thước đo đơn giản về độ phân tán của dữ liệu, biểu thị khoảng giá trị chứa 50% dữ liệu ở giữa.
- Khoảng cách này được gọi là khoảng tứ phân vị (IQR) và được định nghĩa: **$IQR = Q_3 - Q_1$**
- Lương: $\{30, 36, 47, 50, 52, 52, 56, 60, 62, 70, 110, 215\}$
  - Q2 = 54
  - Q1 = 48.5
  - Q3 = 66
  - IQR = 17.5

(9)

# Khoảng tứ phân vị *(interquartile range, IQR)*

- Nếu lấy phân vị là một điểm dữ liệu "**Phân vị (quantiles) là các điểm dữ liệu được lấy tại những vị trí cách đều**"

- Lương: $\{30, 36, 47, 50, 52, 52, 56, 60, 62, 70, 110, 215\}$
  - Q2 = 52
  - Q1 = 47
  - Q3 = 32
  - IQR = 15

(9)

# Tóm tắt năm số *(five-number summary)*

- Không có một thước đo độ phân tán đơn lẻ nào có thể mô tả đầy đủ và hữu ích các phân phối lệch (skewed distributions).
- Trung vị chia các quan sát thành hai nửa có số lượng xấp xỉ bằng nhau.
  - Với phân phối lệch, hai nửa có thể rất khác nhau về độ phân tán và hình dạng.

➔ Đưa thêm hai tứ phân vị $Q_1$ và $Q_3$ để cung cấp thêm thông tin.

- Tuy nhiên, $Q_1$, trung vị và $Q_3$ không cung cấp thông tin về hai đầu (ví dụ: các đuôi) của dữ liệu.
- ➔ Để mô tả đầy đủ hơn hình dạng của phân phối, ta bổ sung thêm giá trị nhỏ nhất và giá trị lớn nhất.
- Tóm tắt năm số (five-number summary) của một phân phối gồm:

**{min, $Q_1$, trung vị, $Q_3$, max}**

# Biểu đồ hộp *(boxplots / box-and-whisker plots )*

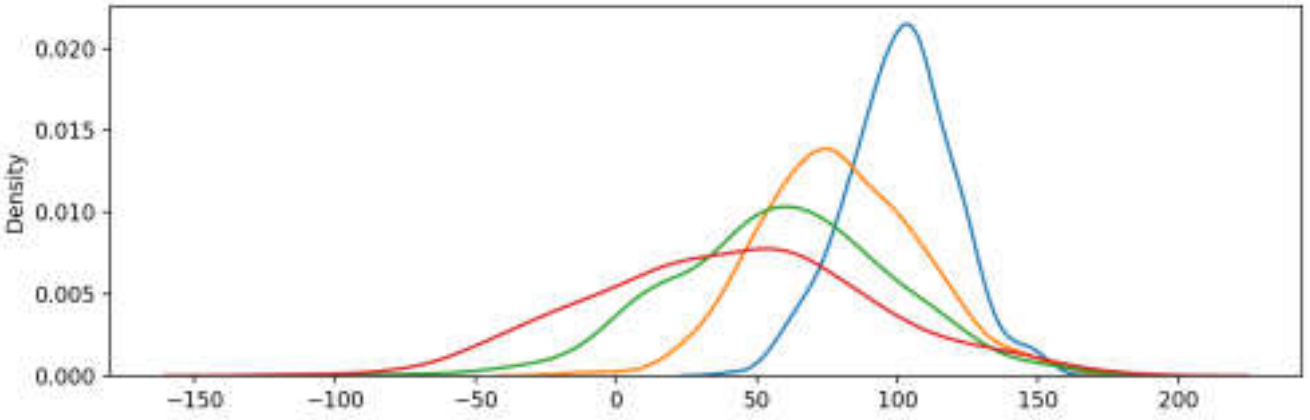
## Hộp và đường trung vị

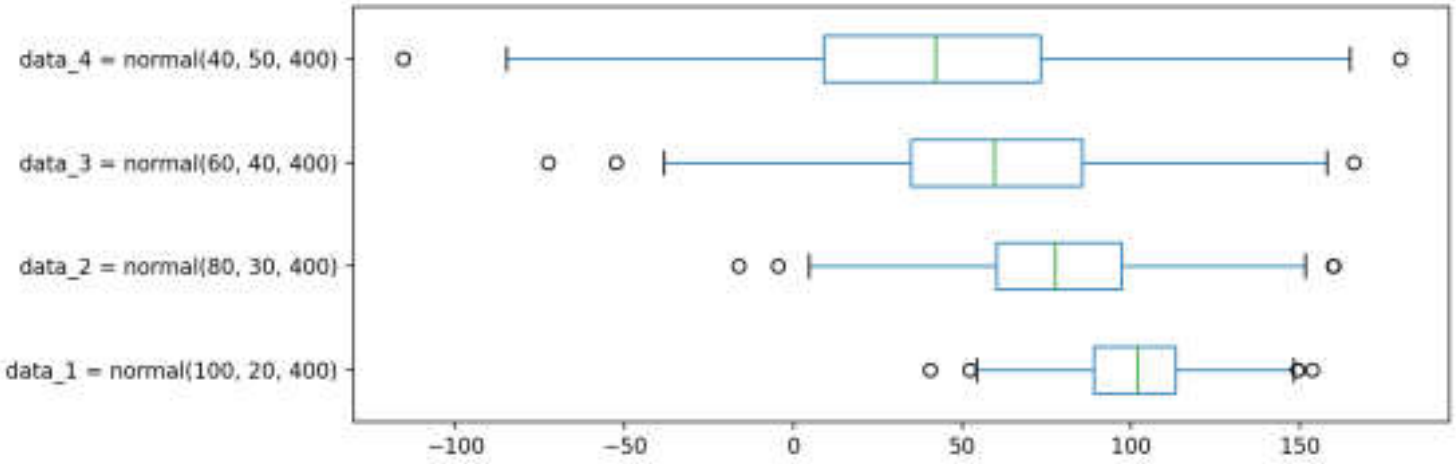
- Hộp trải từ $Q_1$ đến $Q_3$.
- Đường trong hộp đánh dấu trung vị.
- Chiều dài hộp bằng IQR.

## Râu (whiskers) và giá trị ngoại lai (outliners)

- Biểu diễn đơn giản có thể kéo râu tới min và max.
- Theo quy tắc 1.5 × IQR, râu tới các quan sát xa nhất vẫn nằm trong hai ngưỡng.
- Các điểm ngoài [$Q_1$ − 1.5 × IQR, $Q_3$ + 1.5 × IQR] được vẽ riêng là ngoại lai.

# Ví dụ biểu đồ hộp



# Biểu đồ hộp: Bàn thắng của Messi

D = {1, 8, 17, 16, 38, 47, 53, 73, 60, 41, 58, 41, 54, 45, 51, 31, 38}.

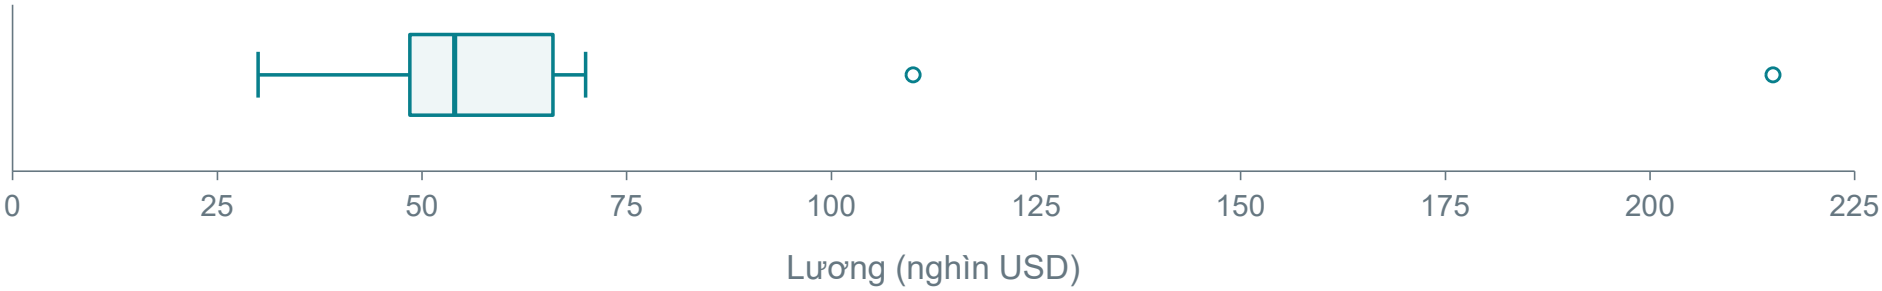
D′ = {1, 8, 16, 17, 31, 38, 38, 41, 41, 45, 47, 51, 53, 54, 58, 60, 73}.




| Min | $Q_1$ | Trung vị | $Q_3$ | Max |
|---|---|---|---|---|
| 1 | 31 | 41 | 53 | 73 |

# Biểu đồ hộp: Lương của 12 nhân viên

D = {30, 36, 47, 50, 52, 52, 56, 60, 62, 70, 110, 215}, đơn vị nghìn USD.

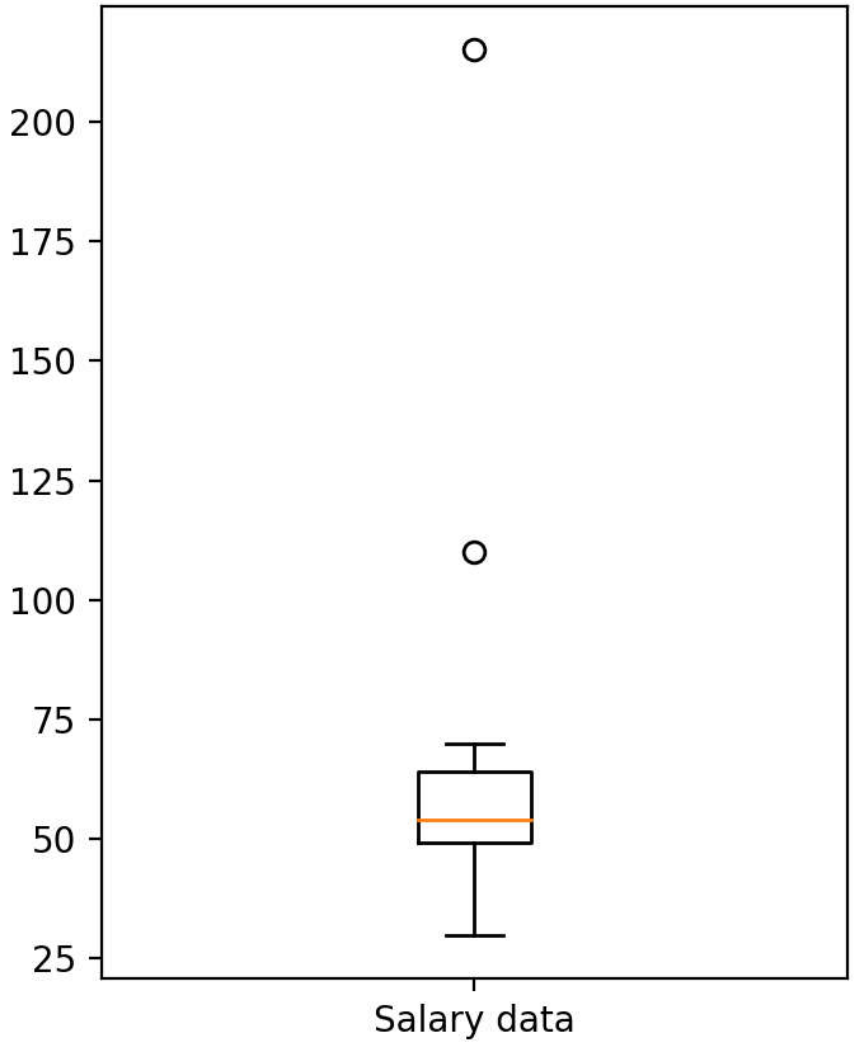



| Min | $Q_1$ | Trung vị | $Q_3$ | Max |
|---|---|---|---|---|
| 30 | 48.5 | 54 | 66 | 215 |

**IQR = 17.5 1.5 × IQR = 26.25 Ngoại lai: 110 và 215**

D = {30, 36, 47, 50, 52, 52, 56, 60, 62, 70, 110, 215}

- $Minimum = \$30,000$
- $Q_1 = \$48,500$
- $Median\ (Q_2) = \$54,000$
- $Q_3 = \$66,000$
- $Maximum = \$215,000$
- $IQR = Q_3 - Q_1 = \$17{,}500$
- $1.5 \times IQR = \$26{,}250$
- $Outliers$ are 110 and 215

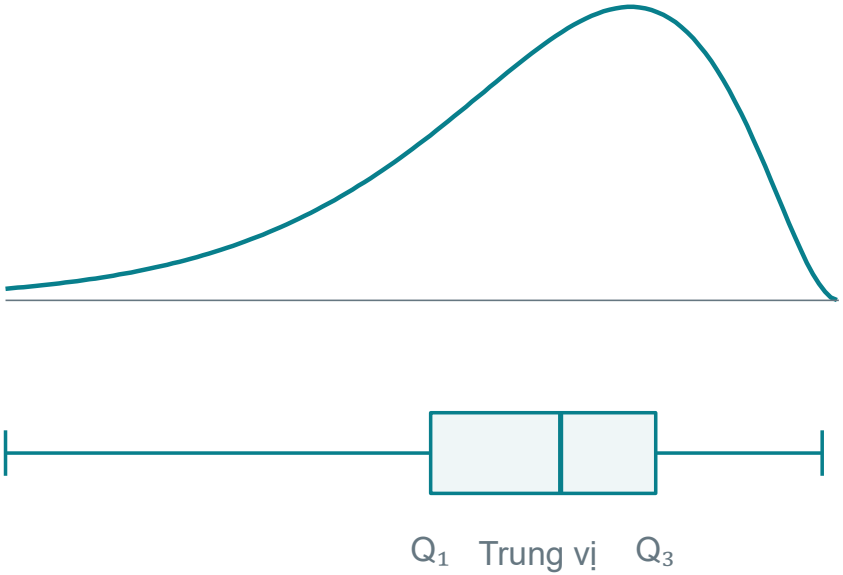


# Đọc thông tin từ biểu đồ hộp

- Vị trí trung tâm: quan sát đường trung vị.
- Độ phân tán: quan sát chiều dài hộp và râu.
- Độ lệch: so sánh hai phần của hộp và chiều dài hai râu.
- Ngoại lai: tìm các điểm nằm ngoài ngưỡng 1.5 × IQR.
- Khi so sánh nhiều nhóm, nên dùng cùng một thang đo.

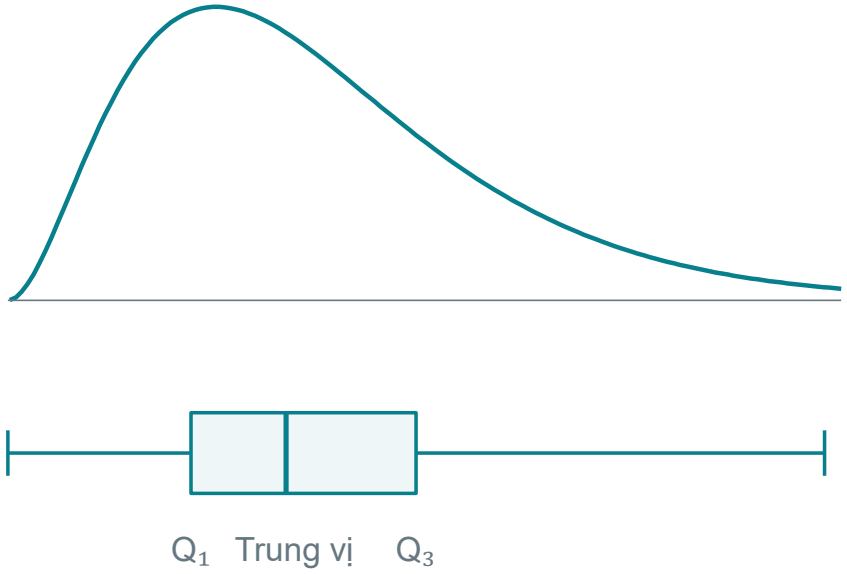
# Biểu đồ hộp thể hiện phân bố lệch

## Phân bố lệch trái




**Đuôi dài về phía giá trị nhỏ**

## Phân bố lệch phải




**Đuôi dài về phía giá trị lớn**