Tiền xử lý và chuẩn bị dữ liệu

(Data Preprocessing and Preparation)

Bài giảng Khai phá dữ liệu

Trường Đại học Công nghệ, Đại học Quốc gia Hà Nội

TS. Lê Hoàng Quỳnh

lhquynh@vnu.edu.vn

04

Làm sạch dữ liệu
Tích hợp dữ liệu
Chuyển dạng dữ liệu
Giảm cỡ dữ liệu
Lấy mẫu dữ liệu

Nội dung

1. Giới thiệu
2. Làm sạch dữ liệu (data cleaning)
3. Tích hợp dữ liệu (data integration)
4. Chuyển dạng dữ liệu (data transformation)
5. Giảm cỡ dữ liệu (data reduction)
6. Lấy mẫu dữ liệu (data sampling)
7. Tài liệu tham khảo và tổng kết

Nội dung

01 **Giới thiệu**

02 Làm sạch dữ liệu
(data cleaning)

03 Tích hợp dữ liệu
(data integration)

04 Chuyển dạng dữ liệu
(data transformation)

05 Giảm cỡ dữ liệu
(data reduction)

06 Lấy mẫu dữ liệu
(data sampling)

07 Tài liệu tham khảo và tổng kết

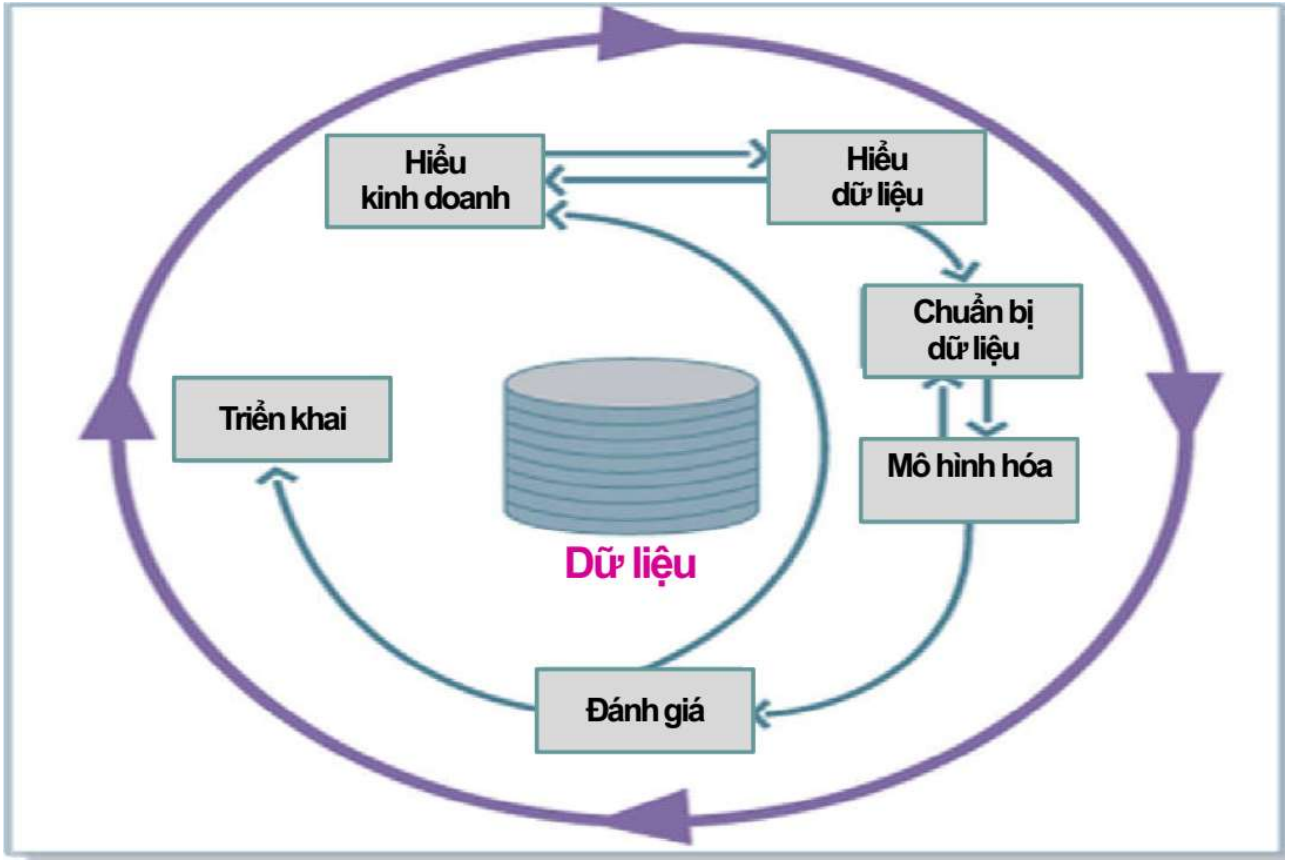
TRONG PHẦN NÀY

Vì sao cần tiền xử lý dữ liệu

Vị trí của tiền xử lý dữ liệu trong quy trình CRISP-DM

Các tác vụ chính trong tiền xử lý dữ liệu

Giới thiệu


Hiểu
kinh doanh
Hiểu
dữ liệu
Chuẩn bị
dữ liệu
Mô hình hóa
Đánh giá
Triển khai
Dữ liệu

CRISP-DM Giai đoạn 2: Hiểu dữ liệu

Thu thập dữ liệu ban đầu (Collect)

Lấy dữ liệu từ các nguồn và nạp vào môi trường phân tích.

Mô tả dữ liệu (Describe)

Xem định dạng, số lượng bản ghi, số trường và đặc điểm của từng trường.

Khám phá dữ liệu (Explore)

Dùng truy vấn và trực quan hóa để phát hiện các quan hệ, xu hướng và nhóm dữ liệu.

Kiểm tra chất lượng (Verify data quality)

Nhận diện lỗi, thiếu dữ liệu và các vấn đề cần xử lý ở bước chuẩn bị dữ liệu.

Vì sao cần tiền xử lý dữ liệu (data preprocessing)?

- Các cơ sở dữ liệu thực tế rất dễ chứa:
  - Dữ liệu nhiễu (noisy),
  - Dữ liệu khuyết thiếu (missing),
  - Dữ liệu không nhất quán (inconsistent)
- Dữ liệu ban đầu thường ở định dạng thô (raw formats), chưa sẵn sàng cho các mô hình phân tích và khai phá dữ liệu.
- Dữ liệu chất lượng thấp sẽ dẫn tới kết quả khai phá chất lượng thấp.
- Dữ liệu là đạt chất lượng nếu nó đáp ứng yêu cầu của mục đích sử dụng dự kiến:
  - Độ chính xác (accuracy),
  - Độ đầy đủ (completeness),
  - Tính nhất quán (consistency),
  - Tính kịp thời (timeliness),
  - Độ tin cậy (believability),
  - Khả năng diễn giải (interpretability).

➔ Có thể tiền xử lý dữ liệu (preprocess data) như thế nào để cải thiện chất lượng của dữ liệu và từ đó cải thiện kết quả khai phá?

➔ Có thể tiền xử lý dữ liệu như thế nào để tăng hiệu quả và độ thuận tiện của quá trình khai phá dữ liệu?

CRISP-DM Giai đoạn 3: Chuẩn bị dữ liệu

Lựa chọn

Chọn dữ liệu phù hợp, nêu lý do lựa chọn hoặc loại bỏ.

Làm sạch

Sửa lỗi, điền giá trị thiếu hoặc loại dữ liệu không phù hợp. Chất lượng đầu vào quyết định chất lượng đầu ra.

“garbage in, garbage out”

Xây dựng/suy diễn

Tạo thuộc tính mới, ví dụ chỉ số BMI.

Tích hợp

Tích hợp dữ liệu từ nhiều nguồn.

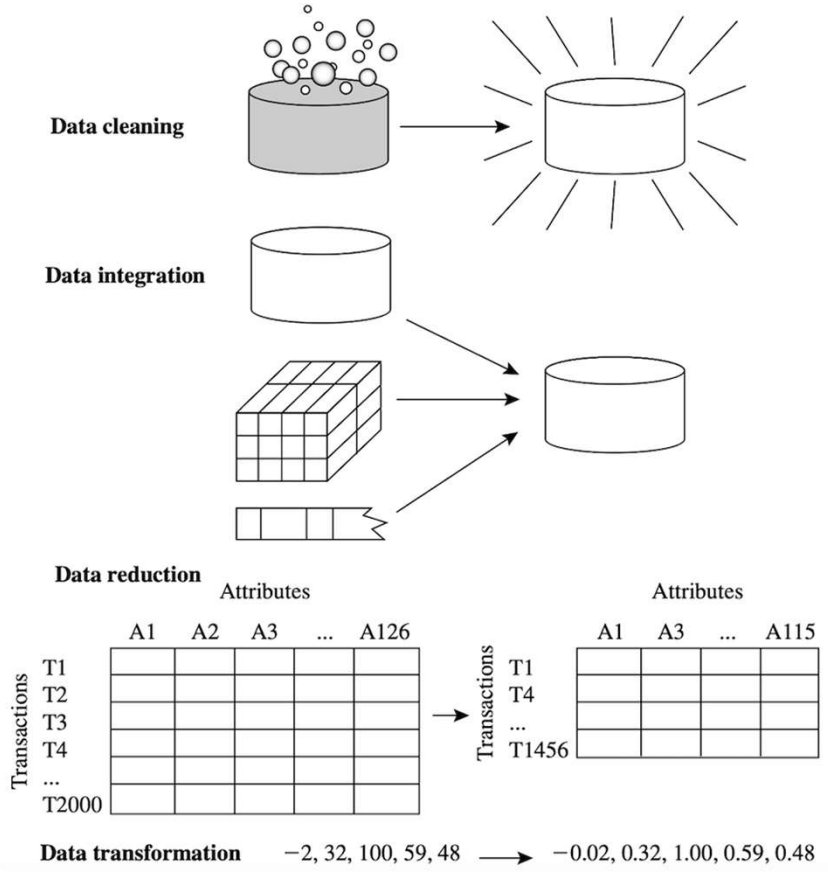
Chuyển dạng

Định dạng lại dữ liệu cho mô hình, ví dụ chuyển biểu diễn số và chuỗi.

Các tác vụ chính trong tiền xử lý dữ liệu (data preprocessing)

- **Lựa chọn dữ liệu**
- **Làm sạch dữ** liệu (data cleaning): Điền giá trị thiếu, làm mịn dữ liệu nhiễu, xác định hoặc loại bỏ ngoại lệ (outliers) và xử lý các điểm không nhất quán.
- **Tích hợp dữ liệu (data integration)**: gồm việc hợp nhất dữ liệu từ nhiều nguồn, ví dụ cơ sở dữ liệu, khối dữ liệu (data cubes), hoặc tệp vào một kho dữ liệu nhất quán như kho dữ liệu (data warehouse).
- **Giảm cỡ dữ liệu (data reduction)**: giảm cỡ dữ liệu theo nhiều cách, ví dụ giảm chiều (dimensionality reduction), loại bỏ các biến/thuộc tính không liên quan, giảm cỡ dữ liệu bằng lấy mẫu (sampling), v.v.
- **Chuyển dạng dữ liệu (data transformation)**: thực hiện chuyển đổi kiểu dữ liệu, rời rạc hóa (discretization), làm mịn dữ liệu, co giãn dữ liệu và chuẩn hóa (normalization), v.v.

Các tác vụ chính trong tiền xử lý dữ liệu (tiếp)



Nội dung

01 Giới thiệu

02 **Làm sạch dữ liệu (data cleaning)**

03 Tích hợp dữ liệu (data integration)

04 Chuyển dạng dữ liệu (data transformation)

05 Giảm cỡ dữ liệu (data reduction)

06 Lấy mẫu dữ liệu (data sampling)

07 Tài liệu tham khảo và tổng kết

TRONG PHẦN NÀY

Xử lý giá trị thiếu

Xử lý giá trị sai và không nhất quán

Xử lý dữ liệu nhiễu

Làm sạch dữ liệu (data cleaning)

1. Xử lý giá trị thiếu

(missing values)

2. Xử lý giá trị sai và không nhất quán

(incorrect and inconsistent values)

3. Xử lý dữ liệu nhiễu

(noisy data)

Xử lý giá trị thiếu (missing values)

1. Bỏ qua các bộ có giá trị thiếu
2. Điền giá trị thiếu thủ công
3. Dùng một hằng toàn cục để điền giá trị thiếu
4. Dùng thước đo xu hướng trung tâm cho thuộc tính
5. Dùng trung bình hoặc trung vị của thuộc tính cho tất cả các mẫu thuộc cùng lớp với bộ đang xét
6. Dùng giá trị có khả năng xảy ra cao nhất để điền giá trị thiếu

Bỏ qua các bộ có giá trị thiếu

- Việc này thường được thực hiện khi thiếu nhãn lớp (giả sử tác vụ khai phá liên quan đến phân lớp).
- Phương pháp này không thật sự hiệu quả, trừ khi bộ dữ liệu chứa nhiều thuộc tính có giá trị thiếu.
- Phương pháp này đặc biệt kém khi tỷ lệ giá trị thiếu trên từng thuộc tính thay đổi đáng kể.
- Khi bỏ qua các bộ, ta không tận dụng được giá trị của các thuộc tính còn lại trong các bộ đó.

Điền giá trị thiếu thủ công

- Nhìn chung, cách tiếp cận này tốn thời gian và có thể không khả thi đối với một tập dữ liệu lớn có nhiều giá trị thiếu.

Dùng một hằng toàn cục để điền giá trị thiếu

- Thay thế tất cả các giá trị thuộc tính bị thiếu bằng cùng một hằng, chẳng hạn một nhãn như “Unknown” hoặc $-\infty$.
- Nếu các giá trị thiếu được thay bằng “Unknown”, mô hình/phần mềm khai phá có thể nhầm tưởng rằng chúng tạo thành một khái niệm/thông tin thú vị, vì tất cả đều có chung một giá trị là “Unknown”.
- Do đó, mặc dù phương pháp này đơn giản, nó không đáng tin cậy.

Dùng thước đo xu hướng trung tâm cho thuộc tính

- Dùng một thước đo xu hướng trung tâm của thuộc tính, ví dụ trung bình (mean) hoặc trung vị (median), để điền các giá trị thiếu.

- Với các phân bố dữ liệu chuẩn/đối xứng, có thể dùng trung bình; còn với phân bố dữ liệu lệch, nên dùng trung vị.

Điền theo lớp (class-based filling)

- Dùng trung bình hoặc trung vị của thuộc tính cho tất cả các mẫu thuộc cùng lớp với bộ đang xét.
- Ví dụ, khi phân lớp khách hàng theo credit_risk, có thể thay giá trị bị thiếu bằng giá trị thu nhập trung bình của các khách hàng trong cùng nhóm rủi ro tín dụng với bộ đang xét.
- Nếu phân bố dữ liệu của một lớp bị lệch, trung vị là lựa chọn tốt hơn.

Dùng giá trị có khả năng xảy ra cao nhất để điền giá trị thiếu

- Giá trị này có thể được xác định bằng hồi quy, các công cụ suy luận dựa trên hình thức Bayes, hoặc quy nạp cây quyết định.
  - Ví dụ, dùng các thuộc tính khác của khách hàng trong tập dữ liệu để xây dựng một cây quyết định nhằm dự đoán các giá trị thu nhập bị thiếu.
- Đây là một chiến lược phổ biến. So với các phương pháp khác, nó sử dụng nhiều thông tin nhất từ dữ liệu hiện có để dự đoán giá trị thiếu.
  - Bằng cách xét các giá trị của những thuộc tính khác khi ước lượng giá trị thu nhập bị thiếu, khả năng bảo toàn các quan hệ giữa thu nhập và các thuộc tính khác sẽ cao hơn.

Giá trị thiếu có thể không phải lỗi trong dữ liệu

- Trong một số trường hợp, giá trị thiếu không nhất thiết hàm ý lỗi trong dữ liệu.
- Lý tưởng nhất, mỗi thuộc tính nên có một hoặc nhiều quy tắc liên quan đến điều kiện null:
  - null có được phép hay không,
  - các giá trị như vậy nên được xử lý hoặc chuyển dạng như thế nào.
- Các trường cũng có thể được cố ý để trống nếu chúng sẽ được cung cấp ở một bước sau của quy trình nghiệp vụ.

➔ Mặc dù có thể cố gắng làm sạch dữ liệu sau khi thu nhận, thiết kế tốt về cơ sở dữ liệu và quy trình nhập dữ liệu có thể giúp giảm thiểu số lượng giá trị thiếu hoặc lỗi ngay từ đầu.

Xử lý giá trị sai và không nhất quán (incorrect and inconsistent values)

Các phương pháp chính được dùng để loại bỏ hoặc sửa các mục nhập sai và không nhất quán:

- Phát hiện không nhất quán (inconsistency detection)
- Tri thức miền (domain knowledge)
- Các phương pháp lấy dữ liệu làm trung tâm (data-centric methods)

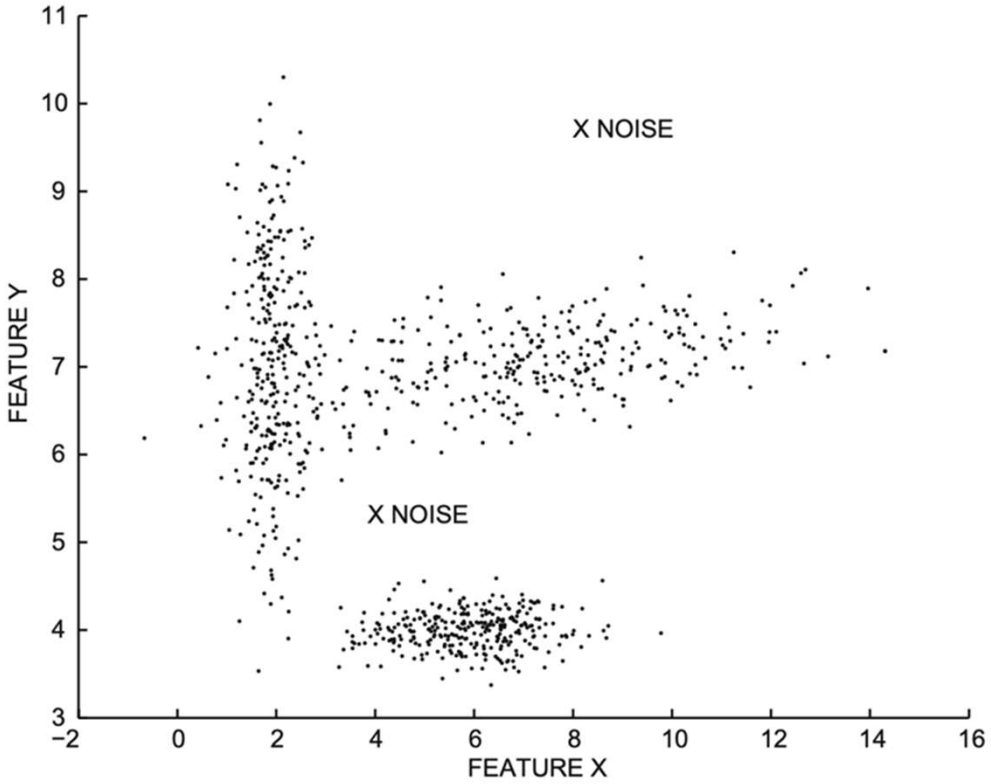
Phát hiện không nhất quán

- Thường được thực hiện khi dữ liệu có từ nhiều nguồn khác nhau và ở các định dạng khác nhau.
  - Ví dụ, tên của một người có thể được viết đầy đủ trong một nguồn, trong khi nguồn khác chỉ chứa chữ cái đầu và họ.
- Các vấn đề chính:
  - Phát hiện trùng lặp (duplicate detection)
  - Phát hiện không nhất quán.
- Các chủ đề này được nghiên cứu dưới phạm vi chung của tích hợp dữ liệu trong lĩnh vực cơ sở dữ liệu.

Tri thức miền (domain knowledge)

- Một lượng đáng kể tri thức miền thường tồn tại dưới **dạng miền giá trị** của các thuộc tính hoặc các **quy tắc chỉ định quan hệ** giữa các thuộc tính khác nhau.
  - Ví dụ, nếu trường quốc gia là “United States” thì trường thành phố không thể là “Shanghai”.
- Nhiều công cụ làm sạch dữ liệu (data scrubbing) và kiểm tra dữ liệu (data auditing) đã được phát triển để dùng tri thức miền và các ràng buộc như vậy nhằm phát hiện các mục nhập sai.

Các phương pháp lấy dữ liệu làm trung tâm (data-centric methods)



- Đặc điểm/hành vi thống kê của dữ liệu được dùng để phát hiện ngoại lệ.
  - Ví dụ, hai điểm dữ liệu tách biệt trong hình được đánh dấu là “noise” là các ngoại lệ.
  - Các điểm này có thể phát sinh do lỗi trong quá trình thu thập dữ liệu.
- Tuy nhiên, điều này không phải lúc nào cũng đúng, vì các bất thường có thể là kết quả của hành vi thú vị/đáng chú ý của hệ thống đang nghiên cứu

➔ Mọi ngoại lệ được phát hiện có thể cần được kiểm tra thủ công trước khi bị loại bỏ.

Xử lý dữ liệu nhiễu (noisy data)

- Nhiễu (noise) là sai số ngẫu nhiên hoặc sự biến thiên ngẫu nhiên trong một biến được đo lường.
- Một số kỹ thuật làm mịn (smoothing) để xử lý dữ liệu nhiễu:
  - Chia thùng (binning)
  - Hồi quy (regression)
  - Phân tích ngoại lệ (outlier analysis)

Xử lý dữ liệu nhiễu: chia thùng (binning)

- Các phương pháp chia thùng (binning) làm mịn một giá trị dữ liệu đã sắp xếp bằng cách tham chiếu "vùng lân cận" của nó, tức là các giá trị xung quanh nó.
- Các giá trị đã sắp xếp được đưa vào một số "nhóm" (buckets) hoặc thùng (bins).
- Vì các phương pháp chia thùng tham chiếu vùng lân cận của các giá trị, chúng thực hiện làm mịn cục bộ (local smoothing).
- Làm mịn bằng trung bình thùng (smoothing by bin means), mỗi giá trị trong một thùng được thay bằng giá trị trung bình của thùng đó.
- Làm mịn bằng trung vị thùng (smoothing by bin medians), trong đó mỗi giá trị trong thùng được thay bằng trung vị của thùng.
- Làm mịn bằng biên thùng (smoothing by bin boundaries), các giá trị nhỏ nhất và lớn nhất trong một thùng được xác định là biên của thùng. Mỗi giá trị trong thùng sau đó được thay bằng giá trị biên gần nhất. Nhìn chung, độ rộng càng lớn thì hiệu ứng làm mịn càng mạnh.

Xử lý dữ liệu nhiễu: ví dụ chia thùng

Sorted data for *price* (in dollars): 4, 8, 15, 21, 21, 24, 25, 28, 34

Partition into (equal-frequency) bins:

Bin 1: 4, 8, 15
Bin 2: 21, 21, 24
Bin 3: 25, 28, 34

Smoothing by bin means:

Bin 1: 9, 9, 9
Bin 2: 22, 22, 22
Bin 3: 29, 29, 29

Smoothing by bin boundaries:

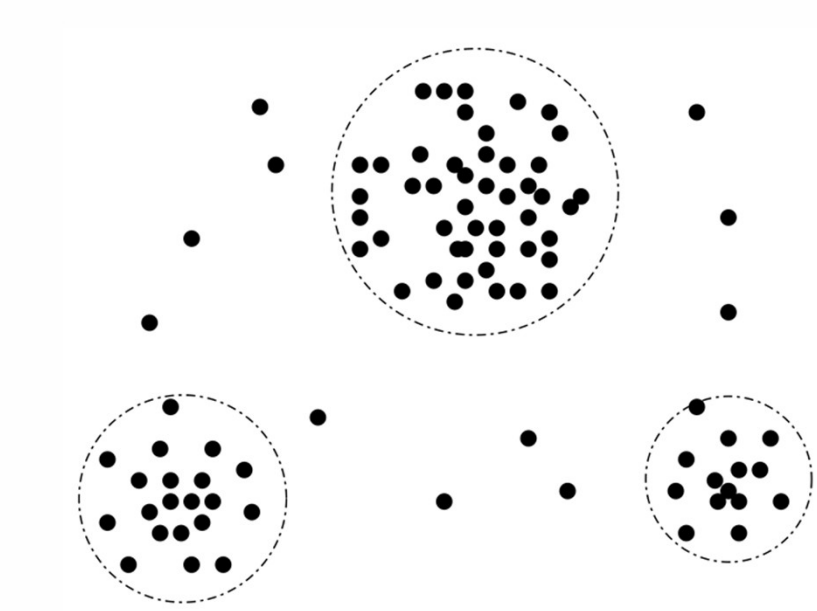
Bin 1: 4, 4, 15
Bin 2: 21, 21, 24
Bin 3: 25, 25, 34

Binning methods for data smoothing [1]

Xử lý dữ liệu nhiễu: hồi quy (regression)

- Làm mịn dữ liệu cũng có thể được thực hiện bằng hồi quy, một kỹ thuật điều chỉnh các giá trị dữ liệu theo một hàm.
- Hồi quy tuyến tính (linear regression) bao gồm việc tìm đường thẳng “tốt nhất” để khớp hai thuộc tính hoặc biến, sao cho một thuộc tính có thể được dùng để dự đoán thuộc tính kia.
- Hồi quy tuyến tính bội (multiple linear regression) là phần mở rộng của hồi quy tuyến tính, trong đó có hơn hai thuộc tính và dữ liệu được khớp với một mặt đa chiều.

Xử lý dữ liệu nhiễu: phân tích ngoại lệ (outlier analysis)



Removing noisy data (outliers) using clustering [1]

- Các ngoại lệ có thể được phát hiện bằng phân cụm
- Theo trực giác, các giá trị nằm ngoài tập các cụm có thể được xem là ngoại lệ.

Nội dung

01 Giới thiệu

02 Làm sạch dữ liệu (data cleaning)

03 Tích hợp dữ liệu (data integration)

04 Chuyển dạng dữ liệu (data transformation)

05 Giảm cỡ dữ liệu (data reduction)

06 Lấy mẫu dữ liệu (data sampling)

07 Tài liệu tham khảo và tổng kết

TRONG PHẦN NÀY

Bài toán định danh thực thể

Phân tích dư thừa và tương quan

Trùng lặp bản ghi

Phát hiện và xử lý xung đột giá trị

Tích hợp dữ liệu (data integration)

- Khai phá dữ liệu thường yêu cầu tích hợp dữ liệu.
- Tích hợp dữ liệu là hợp nhất dữ liệu từ nhiều nguồn dữ liệu.
- Tích hợp dữ liệu cẩn thận giúp:
  - giảm và tránh dư thừa cũng như không nhất quán,
  - cải thiện độ chính xác và tốc độ của quá trình khai phá dữ liệu tiếp theo.
- Các tác vụ chính trong tích hợp dữ liệu:
  - Bài toán định danh thực thể
  - Phân tích dư thừa và tương quan
  - Trùng lặp bản ghi
  - Phát hiện và xử lý xung đột giá trị dữ liệu

Bài toán định danh thực thể (entity identification problem)

- Tích hợp lược đồ (schema integration) và khớp đối tượng (object matching) có thể rất phức tạp.
  - Làm thế nào để khớp các thực thể tương đương trong thế giới thực từ nhiều nguồn dữ liệu?
  - Điều này được gọi là bài toán định danh thực thể.
- Ví dụ: customer_id và cust_number trong hai cơ sở dữ liệu có tham chiếu đến cùng một thuộc tính không?
- Siêu dữ liệu (metadata) có thể được dùng để khớp lược đồ. Siêu dữ liệu của một thuộc tính dữ liệu có thể bao gồm:
  - Tên thuộc tính
  - Ý nghĩa hoặc mô tả của thuộc tính
  - Kiểu dữ liệu và miền giá trị
  - Quy tắc null để xử lý giá trị trống, bằng 0 hoặc null

Dư thừa và phân tích tương quan (redundancy and correlation analysis)

- Dư thừa là một vấn đề quan trọng khác trong tích hợp dữ liệu.
  - Ví dụ: annual_revenue có thể là thừa nếu nó có thể được "suy diễn" từ các thuộc tính khác.
- Cách đặt tên thuộc tính không nhất quán cũng có thể gây ra dư thừa trong dữ liệu kết quả.
- Một số dư thừa có thể được phát hiện bằng phân tích tương quan.
  - Phân tích tương quan có thể đo mức độ một thuộc tính hàm ý thuộc tính kia mạnh đến đâu.
  - Phân tích tương quan cho dữ liệu định danh/phân loại: dùng kiểm định độc lập χ^2 (chi-square).
  - Phân tích tương quan cho thuộc tính số: dùng hiệp phương sai hoặc hệ số tương quan, ví dụ tương quan Pearson.

Trùng lặp (duplication)

- Trùng lặp cần được phát hiện ở mức hàng/bộ/bản ghi/…
  - Ví dụ, khi có hai hoặc nhiều bộ giống hệt nhau cho cùng một trường hợp dữ liệu duy nhất.
- Sự không nhất quán thường phát sinh giữa các bản trùng lặp
  - do nhập dữ liệu không chính xác
  - do cập nhật một số nhưng không phải tất cả các lần xuất hiện dữ liệu.
- Ví dụ: Cơ sở dữ liệu đơn đặt hàng chứa các thuộc tính về tên và địa chỉ người mua thay vì khóa đến thông tin này trong CSDL người mua → có thể xuất hiện sai khác: chẳng hạn cùng một tên người mua xuất hiện với các địa chỉ khác nhau trong cơ sở dữ liệu đơn đặt hàng.

Phát hiện và xử lý xung đột giá trị dữ liệu

- Tích hợp dữ liệu cũng bao gồm phát hiện và xử lý các xung đột giá trị dữ liệu.
- Điều này có thể do khác biệt về biểu diễn, thang đo hoặc mã hóa.
  - Thuộc tính cân nặng có thể được lưu bằng kg trong một hệ thống và pound trong hệ thống khác.
  - Với một chuỗi khách sạn, giá phòng ở các thành phố khác nhau có thể không chỉ liên quan đến đơn vị tiền tệ khác nhau mà còn liên quan các dịch vụ khác nhau (ví dụ bữa sáng miễn phí) và thuế.
  - Khi trao đổi thông tin giữa các trường, mỗi trường có thể có chương trình đào tạo và thang điểm riêng.

Nội dung

01 Giới thiệu

02 Làm sạch dữ liệu (data cleaning)

03 Tích hợp dữ liệu (data integration)

04 Chuyển dạng dữ liệu (data transformation)

05 Giảm cỡ dữ liệu (data reduction)

06 Lấy mẫu dữ liệu (data sampling)

07 Tài liệu tham khảo và tổng kết

TRONG PHẦN NÀY

Chuyển đổi và rời rạc hóa dữ liệu

Làm mịn dữ liệu

Tổng hợp và xây dựng thuộc tính

Phân cấp khái niệm cho dữ liệu định danh

Chuyển dạng dữ liệu (data transformation)

1. Chuyển đổi dữ liệu và rời rạc hóa
2. Làm mịn dữ liệu
3. Tổng hợp dữ liệu
4. Xây dựng thuộc tính
5. Co giãn và chuẩn hóa dữ liệu
6. Sinh phân cấp khái niệm cho dữ liệu định danh

Chuyển đổi dữ liệu và rời rạc hóa

- Dữ liệu số sang dữ liệu phân loại: rời rạc hóa
- Dữ liệu phân loại sang dữ liệu số: nhị phân hóa
- Dữ liệu văn bản sang dữ liệu số
- Dữ liệu chuỗi thời gian sang dữ liệu chuỗi rời rạc

Dữ liệu số sang dữ liệu phân loại: rời rạc hóa (discretization)

- Rời rạc hóa là tác vụ chia miền giá trị của một thuộc tính số thành *k* khoảng con (sub-ranges).
- Sau đó, thuộc tính được giả định chứa *k* giá trị nhãn phân loại khác nhau từ 1 đến *k*, tùy thuộc vào khoảng chứa giá trị thuộc tính gốc.
  - Xét thuộc tính tuổi.
  - Có thể tạo các khoảng con [0, 10], [11, 20], [21, 30], v.v.
  - Giá trị ký hiệu cho mọi bản ghi trong khoảng [11, 20] là “2”
  - Giá trị ký hiệu cho bản ghi trong khoảng [21, 30] là “3”.
  - Vì đây là các giá trị ký hiệu, không giả định có thứ tự giữa các giá trị “2” và “3”.
- Các biến thiên trong một khoảng con không còn phân biệt được sau khi rời rạc hóa. Do đó, quá trình rời rạc hóa làm mất một phần thông tin đối với quá trình khai phá.
- Tuy nhiên, với một số ứng dụng, sự mất mát thông tin này không phải là vấn đề lớn.

Thách thức và kỹ thuật rời rạc hóa

- Một thách thức của rời rạc hóa là dữ liệu có thể phân bố không đều trên các khoảng khác nhau.
  - Ví dụ, với thuộc tính lương, một tập con lớn của tổng thể có thể nằm trong khoảng [40.000, 80.000], nhưng rất ít phần tử nằm trong khoảng [1.040.000, 1.080.000] mặc dù hai khoảng có cùng kích thước.
  - Do đó, dùng các khoảng con có kích thước bằng nhau có thể không hữu ích trong việc phân biệt các đoạn dữ liệu khác nhau.
- Quá trình rời rạc hóa có thể được thực hiện theo nhiều cách tùy mục tiêu ứng dụng cụ thể:
  - Khoảng con đồng độ rộng (equi-width sub-ranges)
  - Khoảng con equi-log (equi-log sub-ranges)
  - Khoảng con đồng độ sâu (equi-depth sub-ranges)
  - Rời rạc hóa dựa trên phân cụm (clustering-based discretization)

Rời rạc hóa: khoảng con đồng độ rộng (equi-width sub-ranges)

- Mỗi khoảng con ***[a, b]*** được chọn sao cho ***b − a*** là như nhau đối với mọi khoảng con.
- Cách tiếp cận này có nhược điểm là không hiệu quả với các tập dữ liệu phân bố không đều trên các khoảng con khác nhau.
- Để xác định giá trị thực tế của các khoảng con, cần xác định giá trị nhỏ nhất và lớn nhất của từng thuộc tính. Khoảng ***[min, max]*** này sau đó được chia thành ***k*** khoảng con có độ dài bằng nhau.

Rời rạc hóa: khoảng con equi-log (equi-log sub-ranges)

- Mỗi khoảng con **[a, b]** được chọn sao cho **log(b) − log(a)** có cùng giá trị.
- Cách lựa chọn khoảng con này tạo ra các khoảng có độ rộng tăng theo cấp số nhân (với $\alpha > 1$): $[a, a\alpha], [a\alpha, a\alpha^2], [a\alpha^2, a\alpha^3]$
- Kiểu khoảng con này có thể hữu ích khi thuộc tính có phân bố hàm mũ trên một miền.
- Thực tế, nếu phân bố tần suất của một thuộc tính có thể được mô hình hóa dưới dạng hàm, một cách tự nhiên là chọn các khoảng con [a, b] sao cho **f(b) − f(a) là như nhau với một hàm f(·).**
- Ý tưởng là chọn hàm f(·) sao cho mỗi khoảng con chứa số bản ghi xấp xỉ tương tự nhau. Tuy nhiên, trong hầu hết trường hợp, khó tìm được hàm f(·) như vậy ở dạng đóng.

Rời rạc hóa: khoảng con đồng độ sâu (equi-depth sub-ranges)

- Các khoảng con được chọn sao cho mỗi khoảng con có số bản ghi bằng nhau.
- Ý tưởng là cung cấp cùng mức độ chi tiết cho mỗi khoảng con.
- Có thể chia một thuộc tính thành các khoảng con đồng độ sâu bằng cách:
  - Sắp xếp thuộc tính đó,
  - Chọn các điểm chia trên các giá trị thuộc tính đã sắp xếp sao cho mỗi khoảng con chứa số bản ghi bằng nhau.

Rời rạc hóa dựa trên phân cụm

- Phân tích cụm là một phương pháp rời rạc hóa dữ liệu phổ biến.
- Có thể áp dụng một thuật toán phân cụm để rời rạc hóa thuộc tính số X bằng cách chia các giá trị của X thành các cụm hoặc nhóm.
- Phân cụm xét đến phân bố của X cũng như độ gần nhau của các điểm dữ liệu, do đó có thể tạo ra kết quả rời rạc hóa chất lượng cao.

Dữ liệu phân loại sang dữ liệu số: nhị phân hóa (binarization)

- Trong một số trường hợp, ta muốn dùng các thuật toán khai phá dữ liệu số trên dữ liệu phân loại.
- Vì dữ liệu nhị phân là một dạng đặc biệt của cả dữ liệu số và dữ liệu phân loại, có thể chuyển các thuộc tính phân loại sang dạng nhị phân rồi dùng các thuật toán số trên dữ liệu đã nhị phân hóa.
  - Nếu một thuộc tính phân loại có *k* giá trị khác nhau, *k* thuộc tính nhị phân khác nhau sẽ được tạo ra.
  - Mỗi thuộc tính nhị phân tương ứng với một giá trị có thể có của thuộc tính phân loại.
  - Đúng một trong *k* thuộc tính nhận giá trị 1, còn các thuộc tính còn lại nhận giá trị 0.

Dữ liệu phân loại sang dữ liệu số: nhị phân hóa (tiếp)

ID	Male	Female	IsStudent	IsEmployee	IsRetired
001	1	0	1	0	0
002	0	1	1	0	0
003	1	0	0	1	0
004	1	0	0	0	1
005	0	1	0	1	0

Dữ liệu văn bản sang dữ liệu số

- Mô hình không gian vector (còn gọi là túi từ - bag of words): chuyển tài liệu, đoạn văn, câu thành các vector thưa. Số chiều vector là kích thước từ vựng của tập văn bản. Trọng số trong vector có thể là nhị phân, tần suất thô, tần suất chuẩn hóa hoặc TF-IDF.
- Mô hình n-gram: đây là trường hợp đặc biệt của mô hình không gian vector, trong đó các từ hoặc token liên tiếp có thể được kết hợp để tạo thành n-gram (unigram, bigram, trigram, v.v.).
- Mô hình ngữ nghĩa tiềm ẩn và chủ đề: chuyển tài liệu, đoạn văn, câu thành các vector ngữ nghĩa/chủ đề. Số chiều nhỏ hơn nhiều, ví dụ 50, 100, 200, 300. Các mô hình quen thuộc gồm LSA, LDA và nhiều mô hình chủ đề khác.
- Nhúng văn bản (text embeddings): dùng các mô hình học biểu diễn sâu để chuyển văn bản (từ, câu, đoạn văn, tài liệu) thành các vector nhúng dày đặc. Các kỹ thuật quen thuộc gồm Word2Vec, GloVe, Doc2Vec, v.v.
- Thư viện phổ biến: NLTK, Gensim, CoreNLP và spaCy. Với tiếng Việt: VnCoreNLP, underthesea, v.v.

Dữ liệu chuỗi thời gian sang chuỗi rời rạc

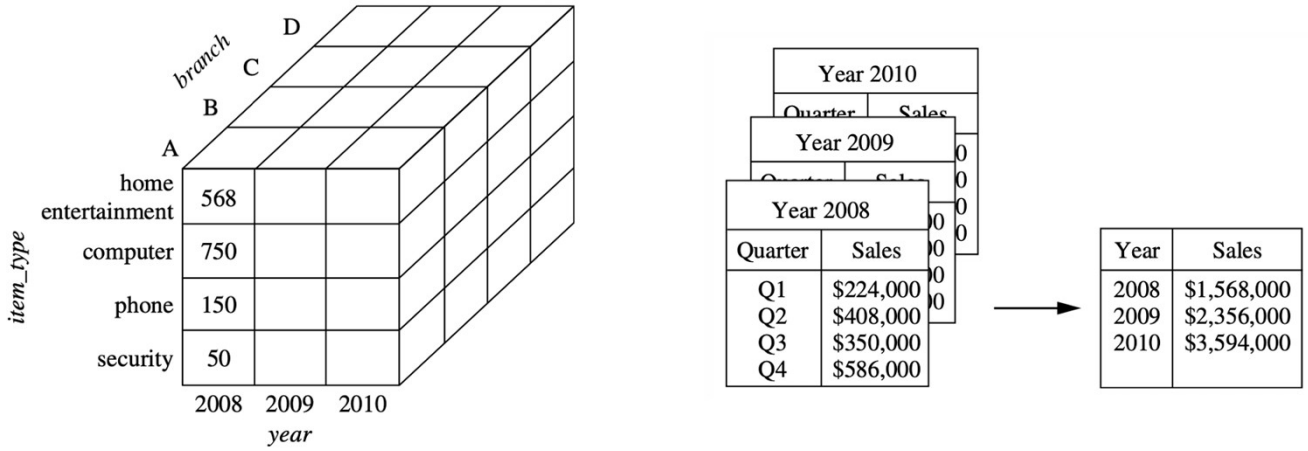
Xấp xỉ tổng hợp ký hiệu (symbolic aggregate approximation - SAX) gồm hai bước:

- Trung bình hóa theo cửa sổ (window–based averaging): Chuỗi thời gian được chia thành các cửa sổ có độ dài *w*, sau đó tính giá trị trung bình của chuỗi thời gian trong mỗi cửa sổ.
- Rời rạc hóa theo giá trị (value-based discretization): Các giá trị trung bình của chuỗi thời gian sau đó được rời rạc hóa thành một số lượng nhỏ hơn các khoảng có tần suất bằng nhau (equi-depth intervals).
  - Mục đích là đảm bảo rằng mỗi ký hiệu xuất hiện với tần suất xấp xỉ bằng nhau trong chuỗi thời gian.
  - Xác định ranh giới các khoảng: Ranh giới của các khoảng được xây dựng dựa trên giả định rằng các giá trị của chuỗi thời gian tuân theo phân phối Gaussian (phân phối chuẩn).
  - Các phân vị (quantiles) của phân phối Gaussian được sử dụng để xác định ranh giới giữa các khoảng. Số lượng khoảng thường nằm trong khoảng từ 3 đến 10.

Làm mịn dữ liệu (data smoothing)

- Làm mịn có tác dụng loại bỏ nhiễu khỏi dữ liệu.
- Các kỹ thuật bao gồm chia thùng (binning), hồi quy (regression) và phân cụm (clustering).
- Làm mịn dữ liệu đã được trình bày trong phần Làm sạch dữ liệu, mục Xử lý dữ liệu nhiễu.

Tổng hợp dữ liệu (data aggregation)



- Tổng hợp là bước áp dụng các phép toán tóm tắt hoặc tổng hợp lên dữ liệu.
- Bước này thường được dùng khi xây dựng khối dữ liệu để phân tích dữ liệu ở nhiều mức trừu tượng.
- Khối dữ liệu (data cube) là một khái niệm phổ biến trong kho dữ liệu,
  - Biểu diễn tập dữ liệu đa chiều, trong đó mỗi thuộc tính có thể có một phân cấp khái niệm.
  - Ví dụ, thuộc tính Thời gian có thể ở các mức độ chi tiết khác nhau như {năm > quý > tháng > tuần > ngày > giờ}.

Xây dựng thuộc tính (construction of attributes)

- Trong xây dựng thuộc tính hoặc xây dựng đặc trưng (feature construction), các thuộc tính mới được xây dựng và thêm vào để hỗ trợ quá trình khai phá, ví dụ cải thiện độ chính xác và khả năng hiểu cấu trúc trong dữ liệu nhiều chiều.
- Ví dụ, ta có thể muốn thêm thuộc tính diện tích dựa trên các thuộc tính chiều cao và chiều rộng.
- Các thuộc tính mới cũng có thể giúp người khai phá dữ liệu và nhà phân tích khám phá, quan sát và hiểu dữ liệu dễ dàng hơn.

Co giãn và chuẩn hóa dữ liệu (data scaling and normalization)

- Các đặc trưng khác nhau biểu diễn các thang đo tham chiếu khác nhau và vì vậy có thể không so sánh được với nhau.
  - Ví dụ, thuộc tính tuổi được đo trên thang rất khác so với thuộc tính lương.
  - Do đó, mọi hàm tổng hợp tính trên các đặc trưng khác nhau (ví dụ khoảng cách Euclid) sẽ bị chi phối bởi thuộc tính có độ lớn lớn hơn.
- Để xử lý vấn đề này, các giá trị thuộc tính thường được co giãn lại hoặc chuẩn hóa về một miền phù hợp hơn.
- Có ba kỹ thuật chuẩn hóa chính:
  - Chuẩn hóa min-max (min-max normalization)
  - Chuẩn hóa điểm chuẩn (standard score normalization)
  - Co giãn thập phân (decimal scaling)

Chuẩn hóa min–max (min–max normalization)

- Cho $D = \{x_1, x_2, ..., x_n\}$ là một mẫu dữ liệu một biến gồm n quan sát của biến/thuộc tính X.
- Trong chuẩn hóa min–max, mỗi giá trị được chuẩn hóa như sau:

$$x'_i = \frac{x_i - min_X}{max_X - min_X}(max_X^{new} - min_X^{new}) + min_X^{new}$$

- Trong đó:
  - min_X và max_X lần lượt là giá trị nhỏ nhất và lớn nhất trong D, tức trước khi chuẩn hóa.
  - min_X^{new} và max_X^{new} lần lượt là giá trị nhỏ nhất và lớn nhất của thuộc tính dữ liệu sau khi chuẩn hóa.
- Sau chuyển đổi, tất cả các giá trị mới x'_i $(i = 1..n)$ nằm trong $[min_X^{new}, max_X^{new}]$.
- Thông thường, miền mới là [0, 1].
- Chuẩn hóa min–max còn được gọi là chuẩn hóa theo miền giá trị (range normalization).
- Kỹ thuật này cũng có thể áp dụng cho mọi thuộc tính dữ liệu số.

Chuẩn hóa chuẩn (standard score normalization, z-normalization)

- Cho $D = \{x_1, x_2, ..., x_n\}$ là một mẫu dữ liệu một biến gồm n quan sát của biến/thuộc tính X.
- Trong chuẩn hóa điểm z, mỗi giá trị được thay bằng điểm z của nó như sau:

$$x'_i = \frac{x_i - \hat{\mu}}{\hat{\sigma}}$$

- Trong đó:
  - $\hat{\mu}$ là trung bình cộng.
  - $\hat{\sigma}$ là độ lệch chuẩn.
- Sau chuẩn hóa, thuộc tính mới có trung bình = 0 và độ lệch chuẩn = 1.
- Phần lớn các giá trị đã chuẩn hóa thường nằm trong khoảng [−3, 3] theo giả định phân bố chuẩn.

Chuẩn hóa thập phân (decimal scaling)

- Chuẩn hóa bằng co giãn thập phân thực hiện chuẩn hóa bằng cách dịch chuyển dấu thập phân của các giá trị thuộc tính số X.
- Số vị trí thập phân cần dịch chuyển phụ thuộc vào giá trị tuyệt đối lớn nhất của X.
- Mỗi giá trị x_i của X được chuẩn hóa thành x'_i bằng cách tính: $x'_i = \frac{x_i}{10^j}$

Trong đó *j* là số nguyên nhỏ nhất sao cho $max(|x'_i|) < 1$

• Ví dụ:

  - Giả sử các giá trị ghi nhận của X nằm trong khoảng từ 986 đến 917.
  - Giá trị tuyệt đối lớn nhất của X là 986.
  - Để chuẩn hóa thập phân, ta chia mỗi giá trị cho 1000 (tức j = 3),
  - Do đó 986 được chuẩn hóa thành 0,986 và 917 được chuẩn hóa thành 0,917.

Ví dụ với dữ liệu hai biến

Cho D là một mẫu dữ liệu hai biến gồm 10 quan sát của hai biến/thuộc tính: Age (X1) và Income (X2) [4].

$$\mathcal{D} = \begin{pmatrix} \mathbf{x}_i & Age\ (X_1) & Income\ (X_2) \\ \hline \mathbf{x}_1 & 12 & 300 \\ \mathbf{x}_2 & 14 & 500 \\ \mathbf{x}_3 & 18 & 1000 \\ \mathbf{x}_4 & 23 & 2000 \\ \mathbf{x}_5 & 27 & 3500 \\ \mathbf{x}_6 & 28 & 4000 \\ \mathbf{x}_7 & 34 & 4300 \\ \mathbf{x}_8 & 37 & 6000 \\ \mathbf{x}_9 & 39 & 2500 \\ \mathbf{x}_{10} & 40 & 2700 \end{pmatrix}$$

Khoảng cách giữa các điểm trước và sau chuẩn hóa

Tính khoảng cách Euclid giữa x_1 và x_2

- Theo dữ liệu gốc: (12, 300) và (14, 500)

$$\begin{aligned}\|\mathbf{x}_1 - \mathbf{x}_2\| &= \|(-2, -200)^T\| \\ &= \sqrt{(-2)^2 + (-200)^2} = \sqrt{40004} = \mathbf{200.01}\end{aligned}$$

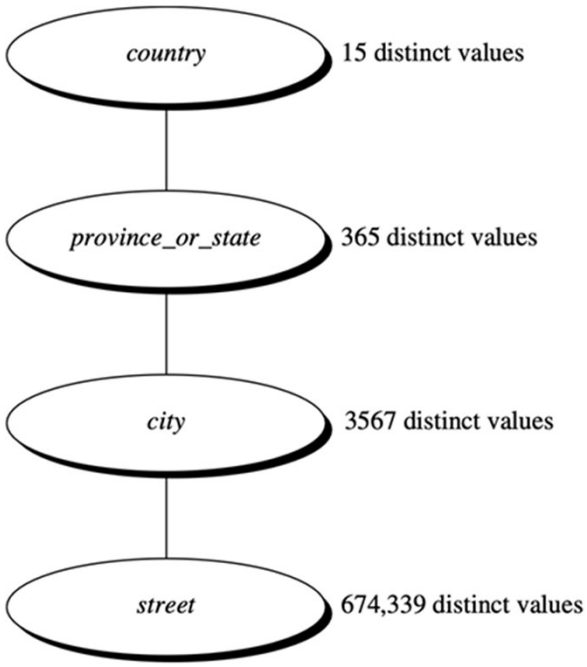
- Theo dữ liệu sau chuẩn hóa min–max: (0, 0) và (0.071, 0.035)

$$\begin{aligned}\|\mathbf{x}'_1 - \mathbf{x}'_2\| &= \|(0, 0)^T - (0.071, 0.035)^T\| \\ &= \|(-0.071, -0.035)^T\| = \mathbf{0.079}\end{aligned}$$

- Theo dữ liệu sau chuẩn hóa z: (-1.56, -1.38) và (-1.35, -1.26)

$$\begin{aligned}\|\mathbf{x}'_1 - \mathbf{x}'_2\| &= \|(-1.56, -1.38)^T - (1.35, -1.26)^T\| \\ &= \|(-0.21, -0.12)^T\| = \mathbf{0.242}\end{aligned}$$

Sinh phân cấp khái niệm cho dữ liệu định danh (nominal data)



Example of concept hierarchy [1]

- Sinh phân cấp khái niệm cho dữ liệu định danh, trong đó các thuộc tính như đường phố (street) có thể được khái quát hóa lên các khái niệm mức cao hơn, chẳng hạn thành phố (city) hoặc quốc gia (country).
- Nhiều phân cấp cho thuộc tính định danh được ngầm thể hiện trong lược đồ cơ sở dữ liệu và có thể được tự động xác định ở mức định nghĩa lược đồ.

Nội dung

01 Giới thiệu

02 Làm sạch dữ liệu (data cleaning)

03 Tích hợp dữ liệu (data integration)

04 Chuyển dạng dữ liệu (data transformation)

05 Giảm cỡ dữ liệu (data reduction)

06 Lấy mẫu dữ liệu (data sampling)

07 Tài liệu tham khảo và tổng kết

TRONG PHẦN NÀY

Tổng quan giảm cỡ dữ liệu

Phân tích thành phần chính

Lựa chọn tập con thuộc tính

Biểu đồ tần suất, phân cụm, khối dữ liệu

Giảm cỡ dữ liệu (data reduction)

- Các kỹ thuật giảm cỡ dữ liệu có thể được áp dụng để thu được một biểu diễn rút gọn của tập dữ liệu, có kích thước nhỏ hơn (nhiều) nhưng vẫn duy trì gần sát tính toàn vẹn của dữ liệu gốc.
- Khai phá trên tập dữ liệu rút gọn sẽ hiệu quả hơn nhưng vẫn tạo ra kết quả phân tích giống hoặc gần giống như trên dữ liệu ban đầu.
- Giảm chiều (dimensionality reduction): giảm số biến ngẫu nhiên hoặc thuộc tính được xem xét.
  - Biến đổi wavelet và phân tích thành phần chính: Dữ liệu gốc được chuyển sang một không gian nhỏ hơn.
  - Lựa chọn tập con thuộc tính: xác định và loại bỏ các thuộc tính không liên quan, liên quan yếu hoặc dư thừa.
- Giảm số lượng (numerosity reduction): thay thế dữ liệu bằng các dạng biểu diễn thay thế nhỏ hơn, ví dụ mô hình tham số hoặc các phương pháp phi tham số như cụm, lấy mẫu và biểu đồ tần suất.

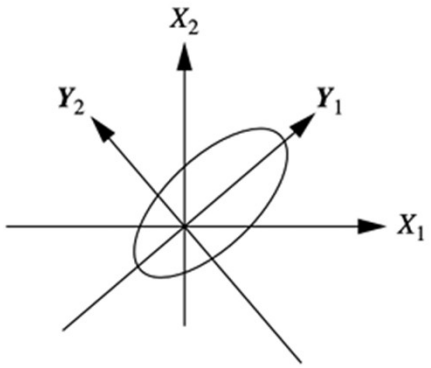
Các phương pháp giảm cỡ dữ liệu (data reduction methods)

1. Phân tích thành phần chính (principal component analysis - PCA)
2. Lựa chọn tập con thuộc tính (attribute subset selection)
3. Biểu đồ tần suất (histograms)
4. Phân cụm (clustering)
5. Lấy mẫu dữ liệu (data sampling)
6. Tổng hợp khối dữ liệu (data cube aggregation)

Phân tích thành phần chính (principal component analysis - PCA)

- Phân tích thành phần chính là một phương pháp giảm chiều.
- PCA tìm một phép chiếu đưa dữ liệu vào không gian chiều thấp hơn.
- Dữ liệu mới được biểu diễn bằng một số thành phần chính đầu tiên.
- Các thành phần chính là các hướng có phương sai lớn nhất trong dữ liệu.
- PCA thường được dùng để giảm số chiều, trực quan hóa dữ liệu và khử nhiễu.

Các bước của PCA



PCA: Y_1 and Y_2 are the first two principal components for the given data. [1]

1. Chuẩn hóa dữ liệu đầu vào sao cho mỗi thuộc tính nằm trong cùng một miền giá trị.
2. Tính *k* vector trực chuẩn (orthonormal vectors), hay các thành phần chính, làm cơ sở cho dữ liệu đầu vào đã chuẩn hóa. Đây là các vector đơn vị chỉ theo những hướng có phương sai lớn nhất trong dữ liệu.

Các bước của PCA (tiếp)

3. Các thành phần chính được sắp xếp theo thứ tự “ý nghĩa” hoặc độ mạnh giảm dần.
4. Vì các thành phần được sắp xếp theo độ mạnh giảm dần, có thể loại bỏ những thành phần yếu hơn, qua đó giảm kích thước dữ liệu.
5. Dữ liệu đầu vào có thể được chiếu lên không gian nhỏ hơn gồm các thành phần chính đã chọn.

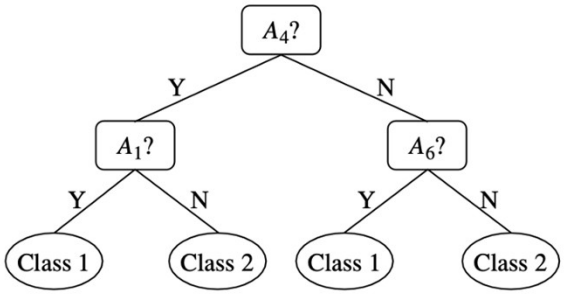
Lựa chọn tập con thuộc tính (attribute subset selection)

- Các tập dữ liệu dùng cho phân tích có thể chứa hàng trăm thuộc tính, trong đó nhiều thuộc tính có thể không liên quan đến nhiệm vụ khai phá dữ liệu hoặc bị dư thừa.
- Mặc dù chuyên gia lĩnh vực có thể xác định được một số thuộc tính hữu ích, nhưng đây có thể là một công việc khó khăn và tốn thời gian, đặc biệt khi đặc điểm của dữ liệu chưa được hiểu rõ.
- Việc loại bỏ nhầm các thuộc tính liên quan hoặc giữ lại các thuộc tính không liên quan đều có thể gây bất lợi, làm cho thuật toán khai phá dữ liệu bị nhiễu. Điều này có thể dẫn đến việc phát hiện ra các mẫu có chất lượng kém.
- Ngoài ra, khối lượng dữ liệu tăng thêm do các thuộc tính không liên quan hoặc dư thừa có thể làm chậm quá trình khai phá dữ liệu.

Lựa chọn tập con thuộc tính (tiếp)

- Lựa chọn tập con thuộc tính làm giảm kích thước tập dữ liệu bằng cách loại bỏ các thuộc tính (hoặc chiều) không liên quan hoặc dư thừa.
- Mục tiêu của lựa chọn tập con thuộc tính là tìm ra một tập thuộc tính tối thiểu, sao cho phân phối xác suất của các lớp dữ liệu thu được gần nhất có thể với phân phối ban đầu khi sử dụng tất cả các thuộc tính.
- Khai phá dữ liệu trên một tập thuộc tính đã được rút gọn còn mang lại một lợi ích khác: giảm số lượng thuộc tính xuất hiện trong các mẫu được phát hiện, từ đó giúp các mẫu dễ hiểu hơn.

Làm thế nào để tìm một tập con "tốt" của các thuộc tính ban đầu?

Forward selection	Backward elimination	Decision tree induction
Initial attribute set: $\{A_1, A_2, A_3, A_4, A_5, A_6\}$ Initial reduced set: $\{\}$ $\Rightarrow \{A_1\}$ $\Rightarrow \{A_1, A_4\}$ $\Rightarrow$ Reduced attribute set: $\{A_1, A_4, A_6\}$	Initial attribute set: $\{A_1, A_2, A_3, A_4, A_5, A_6\}$ $\Rightarrow \{A_1, A_3, A_4, A_5, A_6\}$ $\Rightarrow \{A_1, A_4, A_5, A_6\}$ $\Rightarrow$ Reduced attribute set: $\{A_1, A_4, A_6\}$	Initial attribute set: $\{A_1, A_2, A_3, A_4, A_5, A_6\}$  $\Rightarrow$ Reduced attribute set: $\{A_1, A_4, A_6\}$

Greedy (heuristic) methods for attribute subset selection. [1]

- Với n thuộc tính, có 2^n tập con có thể có. Việc tìm kiếm vét cạn để tìm tập con tối ưu có thể có chi phí tính toán quá lớn. Vì vậy, thông thường sử dụng phương pháp tham lam (greedy).
- Các thuộc tính "tốt nhất" (và "tệ nhất") thường được xác định bằng các kiểm định thống kê (statistical tests). Nhiều thuộc tính khác cần sử dụng các thước đo khác, chẳng hạn độ lợi thông tin (information gain), được sử dụng trong cây quyết định.

Các phương pháp lựa chọn tập con thuộc tính

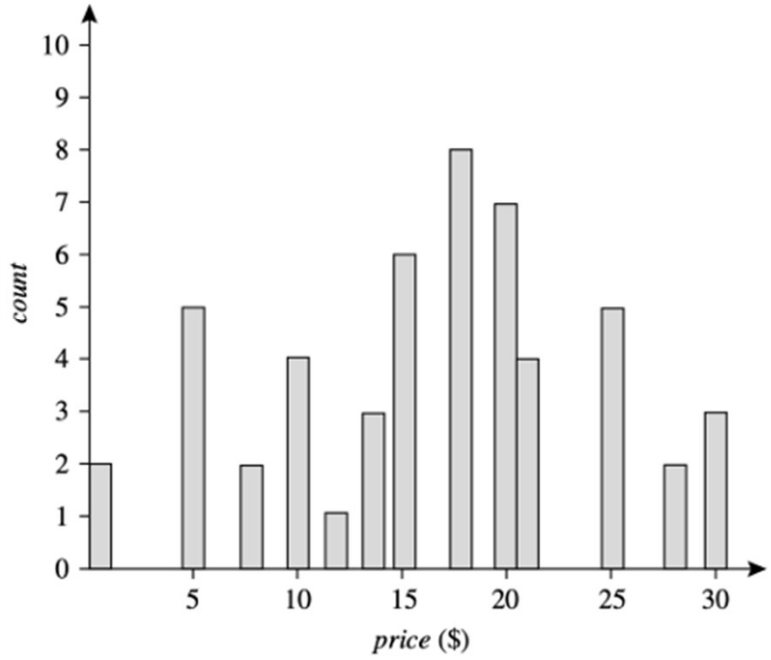
1. Lựa chọn tiến từng bước (stepwise forward selection): Quá trình bắt đầu với một tập thuộc tính rút gọn rỗng. Thuộc tính tốt nhất trong các thuộc tính ban đầu được xác định và thêm vào tập rút gọn; sau đó tiếp tục xác định thuộc tính tốt nhất thứ hai và thêm vào, cứ tiếp tục như vậy.
2. Loại bỏ lùi từng bước (stepwise backward elimination): Quá trình bắt đầu với toàn bộ tập thuộc tính. Ở mỗi bước, phương pháp loại bỏ thuộc tính tệ nhất còn lại trong tập.
3. Kết hợp lựa chọn tiến và loại bỏ lùi: Hai phương pháp lựa chọn tiến từng bước và loại bỏ lùi từng bước có thể được kết hợp tại mỗi bước.
4. Xây dựng cây quyết định (decision tree induction): Các thuật toán cây quyết định (ví dụ: ID3, C4.5 và CART) ban đầu được thiết kế cho bài toán phân loại. Tất cả các thuộc tính xuất hiện trong cây được xem là các thuộc tính có liên quan.

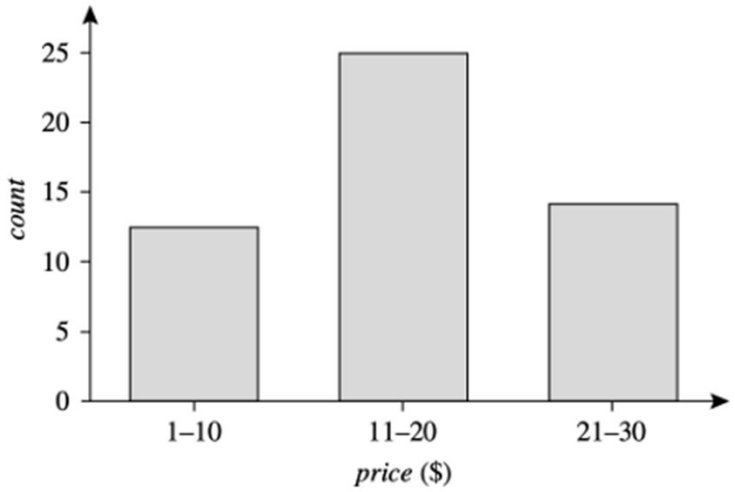
Tiêu chí dừng (stopping criteria) của các phương pháp có thể khác nhau. Quá trình có thể sử dụng một ngưỡng (threshold) trên thước đo được dùng để xác định khi nào nên dừng quá trình lựa chọn thuộc tính.

Biểu đồ tần suất (histograms)

- Biểu đồ tần suất (histogram) sử dụng phương pháp chia thùng (binning) để xấp xỉ phân phối dữ liệu và là một dạng phổ biến của giảm cỡ dữ liệu.
- Một biểu đồ tần suất cho một thuộc tính X chia phân phối dữ liệu của X thành các tập con rời nhau, được gọi là các nhóm hoặc thùng.
- Nếu mỗi nhóm chỉ biểu diễn một cặp giá trị thuộc tính/tần suất duy nhất, các nhóm đó được gọi là nhóm đơn (singleton buckets). Thông thường, các nhóm biểu diễn các khoảng liên tục của thuộc tính đã cho.
- Các nhóm được xác định và các giá trị thuộc tính được phân chia như thế nào? Có một số cách phân chia:
  - **Cùng độ rộng** (equal-width): độ rộng miền của mỗi nhóm là như nhau.
  - **Cùng tần suất** (equal-frequency, hoặc cùng độ sâu equal-depth): mỗi nhóm chứa xấp xỉ cùng số mẫu dữ liệu liên tiếp.
- Biểu đồ tần suất rất hiệu quả trong việc xấp xỉ cả dữ liệu thưa (sparse) và dữ liệu dày (dense), cũng như dữ liệu lệch mạnh và dữ liệu phân bố đều. Biểu đồ tần suất có thể được mở rộng cho nhiều thuộc tính.

Ví dụ về biểu đồ tần suất





Danh sách giá của các mặt hàng bán phổ biến tại AllElectronics [1]:

{1, 1, 5, 5, 5, 5, 5, 8, 8, 10, 10, 10, 10, 12, 14, 14, 14, 15, 15, 15, 15, 15, 15, 18, 18, 18, 18, 18, 18, 18, 18, 20, 20, 20, 20, 20, 20, 20, 21, 21, 21, 21, 25, 25, 25, 25, 25, 28, 28, 30, 30, 30}

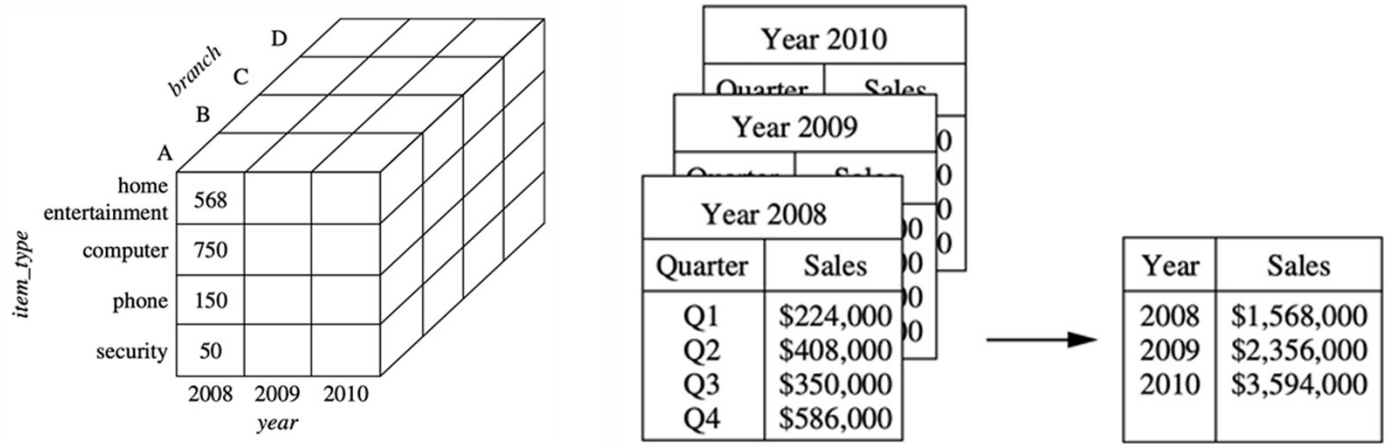
Phân cụm (clustering)

- Các kỹ thuật phân cụm (clustering) phân chia các đối tượng dữ liệu thành các nhóm, hay cụm (clusters), sao cho các đối tượng trong cùng một cụm “tương tự” nhau và “khác biệt” với các đối tượng thuộc những cụm khác.
- Độ tương tự thường được xác định dựa trên mức độ “gần nhau” của các đối tượng trong không gian, thông qua một hàm khoảng cách.
- Trong giảm dữ liệu, các đại diện của cụm được sử dụng để thay thế cho dữ liệu thực tế. Hiệu quả của kỹ thuật này phụ thuộc vào đặc điểm của dữ liệu. Kỹ thuật này hiệu quả hơn nhiều đối với dữ liệu có thể được tổ chức thành các cụm rõ ràng, so với dữ liệu phân tán/trải rộng.
- Các phương pháp và kỹ thuật phân cụm khác nhau sẽ được trình bày sau trong bài phân cụm dữ liệu.

Lấy mẫu dữ liệu (data sampling)

- Lấy mẫu dữ liệu có thể được dùng như một phương pháp giảm cỡ dữ liệu vì cho phép biểu diễn một tập dữ liệu lớn bằng một mẫu dữ liệu nhỏ hơn nhiều.
- Nếu mẫu dữ liệu có tính đại diện, khai phá trên mẫu có thể cho kết quả gần với khai phá trên toàn bộ dữ liệu.
- Lấy mẫu đặc biệt hữu ích khi dữ liệu quá lớn để xử lý trực tiếp hoặc khi cần ước lượng nhanh.

Tổng hợp khối dữ liệu (data cube aggregation)



- Khối dữ liệu (data cube) là một khái niệm phổ biến trong kho dữ liệu (data warehousing).
- Một khối dữ liệu biểu diễn tập dữ liệu đa chiều, trong đó mỗi thuộc tính có thể có một phân cấp khái niệm (concept hierarchy). Ví dụ, thuộc tính thời gian có thể ở các mức độ chi tiết khác nhau như {năm > quý > tháng > tuần > ngày > giờ}.
- Thao tác drill-down cho phép xem dữ liệu ở mức chi tiết hơn, trong khi roll-up cho phép xem dữ liệu ở mức tổng quát/tóm tắt hơn.

Nội dung

01 Giới thiệu

02 Làm sạch dữ liệu (data cleaning)

03 Tích hợp dữ liệu (data integration)

04 Chuyển dạng dữ liệu (data transformation)

05 Giảm cỡ dữ liệu (data reduction)

06 Lấy mẫu dữ liệu (data sampling)

07 Tài liệu tham khảo và tổng kết

TRONG PHẦN NÀY

Tổng quan lấy mẫu

Lấy mẫu ngẫu nhiên

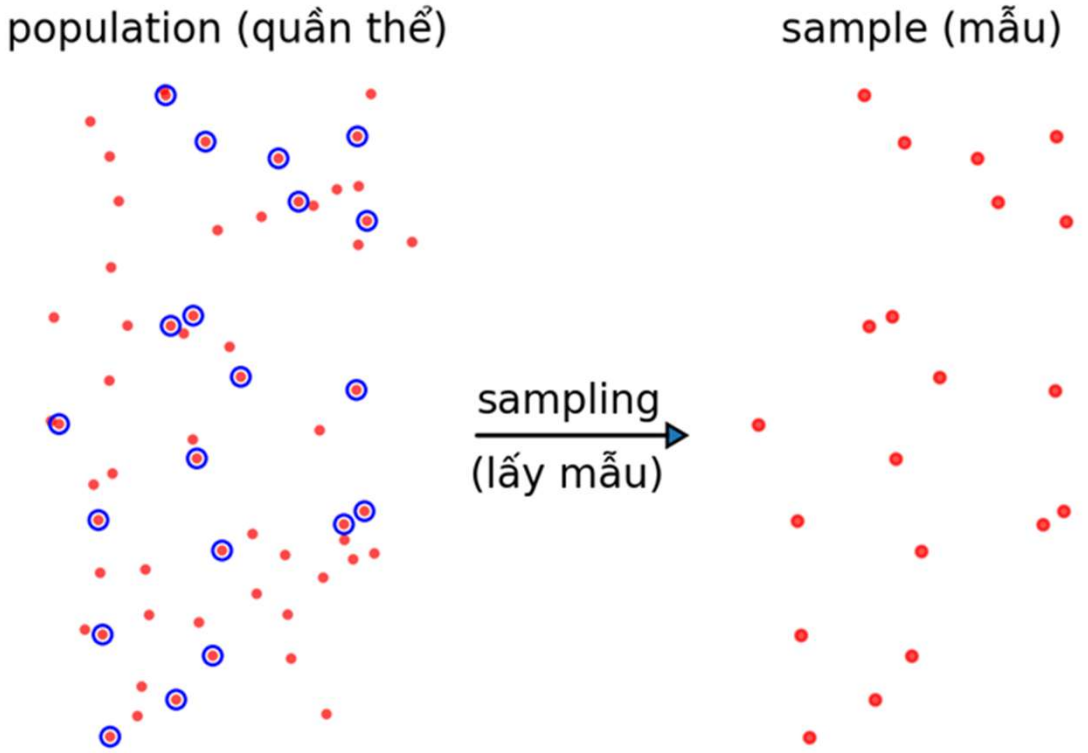
Lấy mẫu phân tầng/cụm/hệ thống/bootstrap

Lấy mẫu không ngẫu nhiên

Lấy mẫu dữ liệu (data sampling)

- Lấy mẫu dữ liệu là quá trình chọn một tập con các quan sát dữ liệu (đối tượng/phần tử/thể hiện/điểm dữ liệu), gọi là mẫu dữ liệu, từ một tổng thể dữ liệu lớn.
- Mẫu dữ liệu kết quả thường gồm các điểm dữ liệu đại diện tốt cho tổng thể, phản ánh đúng bản chất và đặc điểm của tổng thể.
- Lấy mẫu dữ liệu là quan trọng vì hầu hết các tác vụ phân tích dữ liệu được thực hiện trên mẫu dữ liệu thay vì trên toàn bộ tổng thể.
- Lấy mẫu dữ liệu có thể được xem là một kỹ thuật giảm cỡ dữ liệu vì cho phép biểu diễn một tập dữ liệu lớn bằng một tập nhỏ hơn nhiều.

Lấy mẫu dữ liệu (tiếp)



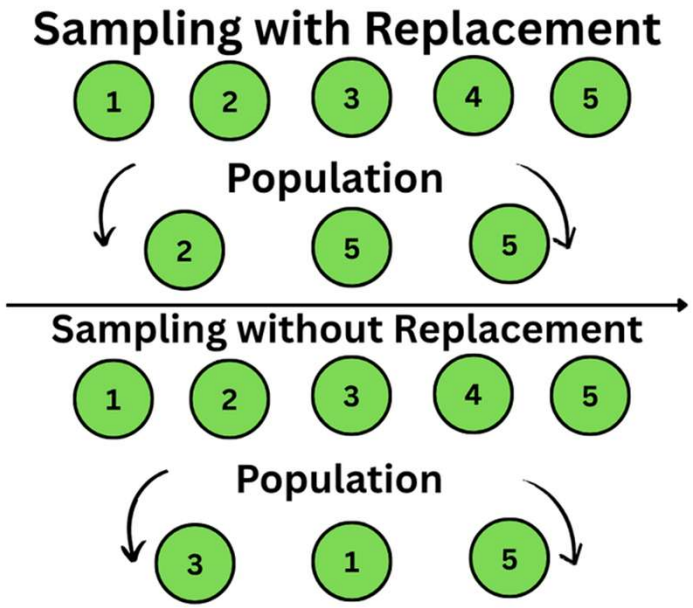
Các phương pháp lấy mẫu ngẫu nhiên (random sampling methods)

- Trong lấy mẫu ngẫu nhiên, mọi phần tử dữ liệu trong tổng thể đều có cơ hội được chọn thông qua một thủ tục/hàm ngẫu nhiên.
- Các kỹ thuật lấy mẫu ngẫu nhiên phổ biến:
  - Lấy mẫu ngẫu nhiên đơn giản (simple random sampling)
  - Lấy mẫu lại bootstrap (bootstrap resampling)
  - Lấy mẫu phân tầng (stratified sampling)
  - Lấy mẫu cụm (cluster sampling)
  - Lấy mẫu hệ thống (systematic sampling)
  - Lấy mẫu nhiều giai đoạn (multi-stage sampling)

Lấy mẫu ngẫu nhiên đơn giản (simple random sampling)

- Một mẫu ngẫu nhiên đơn giản là một tập con của một tổng thể thống kê, trong đó mỗi phần tử của tập con có xác suất được chọn bằng nhau.
- Đây là kỹ thuật lấy mẫu ngẫu nhiên cơ bản nhất.
- Không sử dụng (hoặc sử dụng rất ít) thông tin về quần thể.
- Ví dụ: chọn ngẫu nhiên 30 nhân viên từ toàn bộ 100 nhân viên của một công ty.
- Có thể thực hiện lấy mẫu ngẫu nhiên có hoàn lại hoặc không hoàn lại (có thay thế và không thay thế).

Lấy mẫu có hoàn lại và không hoàn lại



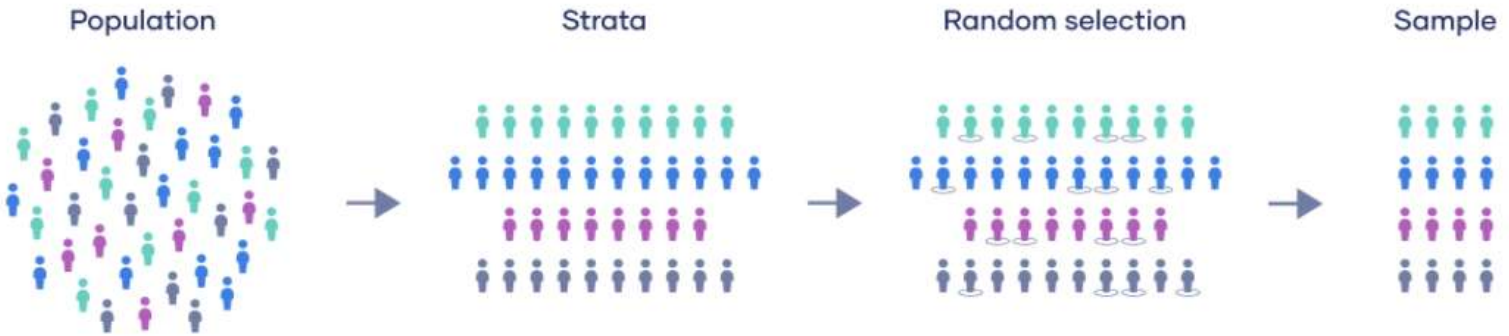
Lấy mẫu bootstrap (bootstrap resampling)

- Cho $D = \{x_1, x_2, ..., x_n\}$ là tập dữ liệu gồm n phần tử dữ liệu.
- Lấy mẫu bootstrap tạo một tập dữ liệu mới D′ bằng cách lấy mẫu ngẫu nhiên có hoàn lại n lần từ D.
- Vì lấy mẫu có hoàn lại, một phần tử có thể xuất hiện nhiều lần trong D′, trong khi một số phần tử khác có thể không xuất hiện.
- Xác suất một phần tử x_i không được chọn sau n lần lấy mẫu có hoàn lại là

$$P(x_i \notin \mathcal{D}') = (1 - \tfrac{1}{n})^n \approx e^{-1} = 0.368$$

- Do đó, xác suất một phần tử x_i được chọn ít nhất một lần xấp xỉ 0,632.
- Thực hiện kỹ thuật này k lần để thu được $D_1, D_2, ..., D_k$ được gọi là lấy mẫu lại bootstrap. Kỹ thuật này thường dùng trong thống kê, phân tích dữ liệu và học máy.

Lấy mẫu phân tầng (stratified sampling)



- Trong kỹ thuật này, các phần tử dữ liệu trước hết được chia thành các nhóm hoặc tầng khác nhau.
- Các phần tử trong mỗi nhóm/tầng tương tự nhau theo một cách nào đó và khác với các phần tử ở các tầng khác.
- Sau khi chia, lấy mẫu ngẫu nhiên đơn giản được áp dụng cho từng nhóm/tầng để chọn các phần tử ngẫu nhiên vào mẫu dữ liệu cuối cùng.
- Với kỹ thuật này, cần hiểu tổng thể để có thể chia các phần tử thành các tầng.

Ví dụ lấy mẫu phân tầng

- Yêu cầu: Chọn ngẫu nhiên 30 nhân viên từ toàn bộ 100 nhân viên của một công ty.
- Ràng buộc: Một nửa trong số 30 nhân viên được chọn là nữ → Lấy mẫu ngẫu nhiên đơn giản không phải lúc nào cũng đáp ứng ràng buộc này.

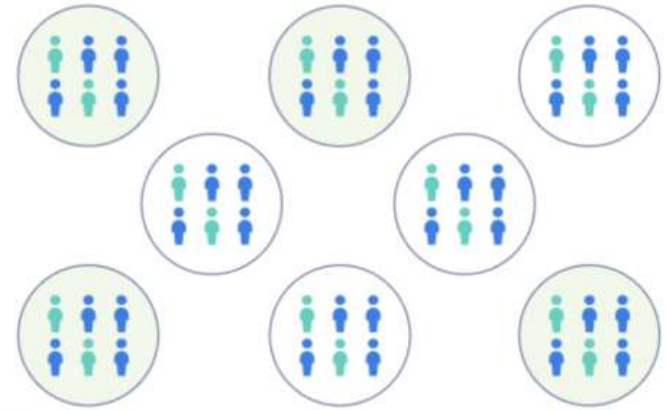
- Giả sử trong 100 nhân viên của công ty có 25 nữ.

- Chia 100 nhân viên thành hai nhóm/tầng:
  - 75 nam và 25 nữ.
- Áp dụng lấy mẫu ngẫu nhiên đơn giản cho từng nhóm. Với mỗi nhóm, chọn ngẫu nhiên 15 nhân viên.

➔ Mẫu dữ liệu cuối cùng gồm 30 nhân viên và một nửa là nữ.

- Kỹ thuật này thường được áp dụng khi có một số ràng buộc đối với mẫu dữ liệu kết quả và phân bố tổng thể bị lệch.

Lấy mẫu cụm (cluster sampling)

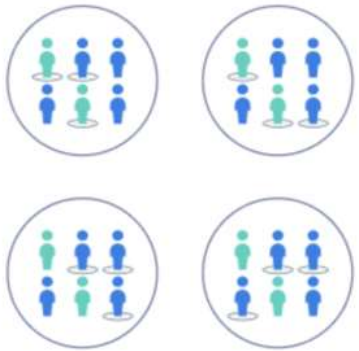


- Bước 1: xác định quần thể
- Bước 2: chia các phần tử dữ liệu trong quần thể thành các cụm.
  - Mỗi cụm nên đa dạng nhất có thể; mọi đặc điểm của toàn bộ tổng thể nên được biểu diễn trong mỗi cụm.
  - Mỗi cụm nên có phân bố đặc điểm tương tự như phân bố của toàn bộ tổng thể.
  - Các cụm gộp lại nên bao phủ toàn bộ tổng thể và không chồng lấn.

Lấy mẫu cụm (tiếp)

- Bước 3: chọn ngẫu nhiên các cụm để dùng làm mẫu.
  - Nếu mỗi cụm là một biểu diễn thu nhỏ của tổng thể lớn hơn, việc chọn ngẫu nhiên và lấy mẫu từ các cụm cho phép mô phỏng lấy mẫu ngẫu nhiên đơn giản, từ đó hỗ trợ tính hợp lệ của kết quả.
  - Ngược lại, nếu các cụm không có tính đại diện, lấy mẫu ngẫu nhiên vẫn cho phép thu thập dữ liệu trên nhiều cụm đa dạng, qua đó cung cấp cái nhìn tổng quan về toàn bộ tổng thể.
- Bước 4: thu thập tất cả các phần tử dữ liệu trong mỗi cụm được chọn để tạo thành mẫu dữ liệu kết quả.

Lấy mẫu cụm nhiều giai đoạn (multi-stage cluster sampling)



- Thay vì thu thập dữ liệu từ từng phần tử đơn lẻ trong các cụm được chọn, ta chọn ngẫu nhiên các phần tử riêng lẻ bên trong cụm để tạo thành mẫu dữ liệu cuối cùng → lấy mẫu cụm hai giai đoạn.
- Ta cũng có thể tiếp tục thủ tục này, lấy các mẫu ngẫu nhiên ngày càng nhỏ hơn; cách này thường được gọi là lấy mẫu cụm nhiều giai đoạn.

Ví dụ lấy mẫu nhiều giai đoạn (multi-stage sampling example)

- Để đánh giá kiến thức của học sinh trung học trên phạm vi toàn quốc và độc lập với kỳ thi tốt nghiệp THPT quốc gia, Bộ Giáo dục và Đào tạo muốn tổ chức phỏng vấn 10.000 học sinh từ các vùng khác nhau trong cả nước. Bộ không thể phỏng vấn học sinh từ tất cả các trường THPT ở mọi huyện/thành phố/tỉnh do ràng buộc về thời gian, nhân lực và chi phí.

Bộ sẽ thực hiện lấy mẫu nhiều giai đoạn như sau:

- Bước 1: tất cả các tỉnh/thành phố được đưa vào các cụm khác nhau dựa trên vùng địa lý. Các cụm gồm Tây Bắc, Đông Bắc, Đồng bằng sông Hồng, Bắc Trung Bộ, Nam Trung Bộ, Tây Nguyên, Đông Nam Bộ và Đồng bằng sông Cửu Long.
- Từ mỗi vùng, một số tỉnh/thành phố sẽ được chọn ngẫu nhiên. Ví dụ:
  - Sơn La, Lai Châu, Hà Giang từ Tây Bắc
  - Hà Nội, Hải Dương từ Đồng bằng sông Hồng
  - ...
  - Bạc Liêu, Cần Thơ, Trà Vinh từ Đồng bằng sông Cửu Long

Ví dụ lấy mẫu nhiều giai đoạn (multi-stage sampling) (tiếp)

- Bước 2: Tất cả các trường THPT từ các tỉnh/thành phố đã chọn ở trên sẽ được phân loại thành các cụm con khác nhau như Khu vực 1 (KV1), Khu vực 2 (KV2), Khu vực 2 nông thôn (KV2-NT) và Khu vực 3 (KV3). Từ mỗi cụm này, Bộ chọn ngẫu nhiên 25 trường THPT để thu được tổng cộng 100 trường. 100 trường này đại diện cho tất cả các vùng địa lý và có thể thuộc thành phố, thị trấn, nông thôn hoặc miền núi.
- Bước 3: Từ mỗi trong 100 trường THPT đã chọn, chọn 100 học sinh lớp 12 để tạo thành mẫu dữ liệu kết quả gồm 10.000 học sinh.
- Mẫu dữ liệu cuối cùng gồm 10.000 học sinh rất đa dạng, bao gồm học sinh từ nhiều vùng khác nhau của cả nước. Các em có thể sống ở thành phố, thị trấn, nông thôn hoặc là người dân tộc thiểu số. Đây rõ ràng là mẫu phù hợp để Bộ đánh giá chất lượng giáo dục THPT.
- Trên thực tế, Bộ còn có thể thực hiện lấy mẫu phức tạp hơn để đáp ứng các ràng buộc khác.

Lấy mẫu cụm: ưu điểm và nhược điểm

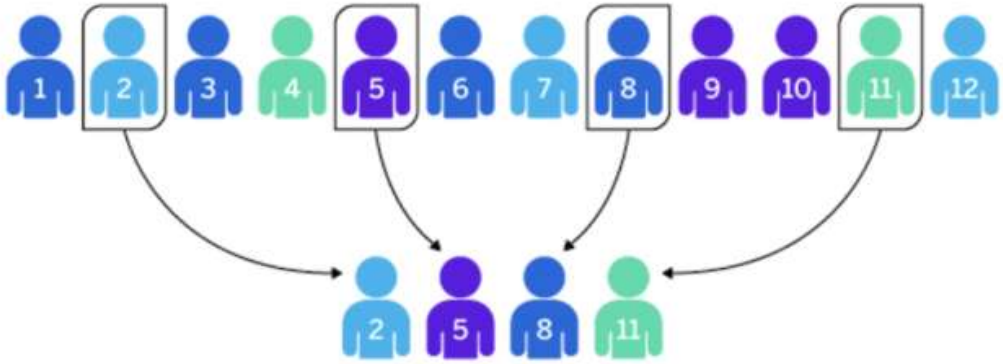
- Ưu điểm:
  - Giúp tiết kiệm thời gian và chi phí, đặc biệt đối với các quần thể phân bố rộng về mặt địa lý, vốn khó có thể lấy mẫu một cách phù hợp bằng các phương pháp khác.
  - Vì lấy mẫu theo cụm sử dụng lựa chọn ngẫu nhiên, nếu quần thể được chia cụm hợp lý, nghiên cứu sẽ có tính khái quát cao, do mẫu phản ánh được các đặc điểm của quần thể lớn hơn.
- Nhược điểm:
  - Tính hợp lệ nội tại thấp hơn so với lấy mẫu ngẫu nhiên đơn giản, đặc biệt khi sử dụng nhiều giai đoạn lấy mẫu theo cụm.
  - Nếu các cụm không phải là những đại diện thu nhỏ tốt của toàn bộ quần thể, thì sẽ khó đảm bảo rằng mẫu thu được có thể cung cấp kết quả đáng tin cậy/hợp lệ.
  - Lấy mẫu theo cụm phức tạp hơn trong khâu thiết kế và lập kế hoạch so với các hình thức lấy mẫu khác.

Lấy mẫu hệ thống (systematic sampling)

- Trong kỹ thuật này, chỉ phần tử đầu tiên được chọn ngẫu nhiên. Từ phần tử thứ hai trở đi, việc chọn dựa trên phần tử trước đó.
- Trước hết, tất cả các phần tử trong tổng thể được đặt thành một dãy theo thứ tự ngẫu nhiên.
- Giả sử kích thước tổng thể là N và kích thước mẫu kết quả là n (thường $n \ll N$). Khi đó chia dãy tổng thể thành n dãy con có độ dài $k = [N/n]$, trừ dãy con cuối có thể dài hơn k.
- Việc lấy mẫu bắt đầu bằng cách chọn ngẫu nhiên phần tử đầu tiên từ dãy con đầu tiên, giả sử ở vị trí/chỉ số i_1. Khi đó, vị trí phần tử thứ hai là $i_2 = i_1 + k$, phần tử thứ ba là $i_3 = i_2 + k = i_1 + 2k$.

  Tổng quát: $i_n = i_{n-1} + k = i_1 + (n-1)k$

Ví dụ lấy mẫu hệ thống



- Hình trên minh họa một ví dụ về lấy mẫu hệ thống với:
  - N = 12
  - n = 4
  - k = 3
- Phần tử đầu tiên được chọn ngẫu nhiên ở vị trí 2
- Các lựa chọn tiếp theo ở vị trí 5, 8 và 11

Các phương pháp lấy mẫu không ngẫu nhiên (non-random sampling methods)

- Lấy mẫu không ngẫu nhiên, hay lấy mẫu phi xác suất (non-probability sampling), là cách tiếp cận lấy mẫu trong đó việc chọn các phần tử từ tổng thể không dựa trên tính ngẫu nhiên. Thay vào đó, việc chọn dựa trên hiểu biết của con người về tổng thể. Vì vậy, mẫu dữ liệu kết quả có thể bị thiên lệch.
- Một số kỹ thuật lấy mẫu không ngẫu nhiên quen thuộc gồm:
  - Lấy mẫu thuận tiện (convenience sampling)
  - Lấy mẫu phán đoán (judgement sampling)
  - Lấy mẫu hạn ngạch (quota sampling)
  - Lấy mẫu quả cầu tuyết (snowball sampling)

Lấy mẫu thuận tiện (convenience sampling)

- Lấy mẫu thuận tiện là phương pháp trong đó nhà nghiên cứu thu thập dữ liệu nghiên cứu thị trường từ một nhóm người trả lời có sẵn một cách thuận tiện.
- Đây là kỹ thuật lấy mẫu thường dùng vì rất nhanh, đơn giản và tiết kiệm. Trong nhiều trường hợp, các thành viên dễ tiếp cận để tham gia mẫu.
- Trong hầu hết trường hợp, kiểm tra toàn bộ cộng đồng gần như không khả thi vì khó tiếp cận. Nhà nghiên cứu cũng dùng lấy mẫu thuận tiện trong các tình huống không cần thêm đầu vào. Không có tiêu chí bắt buộc để trở thành một phần của mẫu này. Do đó, việc đưa phần tử vào mẫu trở nên rất đơn giản. Tất cả thành phần của tổng thể đều đủ điều kiện và phụ thuộc vào mức độ gần gũi/tiện tiếp cận của nhà nghiên cứu.
- Nhà nghiên cứu chọn thành viên chỉ dựa trên sự gần gũi/tiện tiếp cận và không xét liệu họ có đại diện cho toàn bộ tổng thể hay không. Dùng kỹ thuật này, có thể quan sát thói quen, ý kiến và quan điểm theo cách dễ nhất có thể.

Ứng dụng của lấy mẫu thuận tiện

- Lấy mẫu thuận tiện được các thương hiệu và tổ chức áp dụng để đo nhận thức của thị trường về hình ảnh của họ. Dữ liệu được thu thập từ khách hàng tiềm năng để hiểu các vấn đề cụ thể hoặc quản lý ý kiến về một sản phẩm mới ra mắt.
- Một ví dụ cơ bản của lấy mẫu thuận tiện là khi các công ty phát tờ rơi quảng bá và đặt câu hỏi tại trung tâm thương mại hoặc trên đường phố đông người với những người tham gia được chọn ngẫu nhiên.
- Luôn có khả năng tổng thể được chọn ngẫu nhiên không đại diện chính xác cho tổng thể quan tâm, do đó làm tăng khả năng thiên lệch.

Ưu điểm của lấy mẫu thuận tiện

- Thu thập dữ liệu nhanh: trong các tình huống thời gian là ràng buộc, nhiều nhà nghiên cứu chọn phương pháp này để thu thập dữ liệu nhanh. Quy tắc thu thập phần tử cho mẫu ít phức tạp hơn so với các kỹ thuật như lấy mẫu ngẫu nhiên đơn giản, lấy mẫu phân tầng và lấy mẫu hệ thống.
- Chi phí tạo mẫu thấp: tiền bạc và thời gian đầu tư cho các phương pháp lấy mẫu xác suất khác khá lớn so với lấy mẫu thuận tiện.
- Dễ thực hiện nghiên cứu.
- Chi phí thấp: chi phí thấp là một trong những lý do chính khiến nhà nghiên cứu áp dụng kỹ thuật này.
- Mẫu sẵn có: thu thập dữ liệu dễ dàng và dễ tiếp cận. Hầu hết lấy mẫu thuận tiện xét đến tổng thể ngay trong tầm tay.
- Ít quy tắc phải tuân theo: không cần đi qua một danh sách kiểm tra để lọc các thành viên của đối tượng khảo sát.

Lấy mẫu phán đoán (judgement sampling)

- Lấy mẫu phán đoán, còn gọi là lấy mẫu mục đích (purposive sampling) hoặc lấy mẫu thẩm quyền (authoritative sampling), là một kỹ thuật lấy mẫu phi xác suất trong đó các thành viên mẫu chỉ được chọn dựa trên kiến thức và phán đoán của nhà nghiên cứu.
- Vì kiến thức của nhà nghiên cứu đóng vai trò then chốt trong việc tạo mẫu bằng kỹ thuật này, kết quả có khả năng rất chính xác với biên sai số tối thiểu.
- Quá trình chọn mẫu gồm việc nhà nghiên cứu cẩn thận chọn từng cá nhân để đưa vào mẫu. Kiến thức của nhà nghiên cứu là yếu tố chính trong quá trình này vì các thành viên của mẫu không được chọn ngẫu nhiên.
- Lấy mẫu phán đoán hiệu quả nhất trong các tình huống chỉ có một số lượng hạn chế người trong tổng thể sở hữu các đặc điểm mà nhà nghiên cứu kỳ vọng ở tổng thể mục tiêu.
- Lấy mẫu phán đoán thường được dùng khi tổng thể mục tiêu gồm những cá nhân có tính chuyên biệt cao.

Ưu điểm của lấy mẫu phán đoán

- Tốn ít thời gian thực hiện: trong cách lấy mẫu này, chuyên môn của nhà nghiên cứu là quan trọng và không có rào cản nào khác, nên việc chọn mẫu trở nên rất thuận tiện.
- Cho phép nhà nghiên cứu tiếp cận trực tiếp thị trường mục tiêu: không có tiêu chí chọn mẫu nào ngoài ưu tiên của nhà nghiên cứu. Vì vậy, họ có thể giao tiếp trực tiếp với đối tượng mục tiêu mà mình lựa chọn và tạo ra kết quả mong muốn.
- Kết quả gần thời gian thực: có thể thực hiện một cuộc thăm dò hoặc khảo sát nhanh với mẫu bằng lấy mẫu phán đoán vì các thành viên mẫu có kiến thức và hiểu biết phù hợp về chủ đề.

Lấy mẫu hạn ngạch (quota sampling)

- Trong kỹ thuật này, tổng thể được chia thành các nhóm con loại trừ lẫn nhau theo các tiêu chí cụ thể. Việc phân chia này có thể được thực hiện ở nhiều mức nếu cần.
- Sau đó, lấy mẫu được thực hiện cho từng nhóm con bằng lấy mẫu thuận tiện hoặc lấy mẫu phán đoán. Với mỗi nhóm con, việc chọn mẫu có một hạn ngạch cụ thể.
- Ví dụ, chính quyền địa phương muốn lấy phản hồi từ 200 người, bao gồm 50 người cao tuổi, 100 nhân viên và 50 nội trợ. Khi đó, người dân địa phương sẽ được phân loại thành ba nhóm con, rồi áp dụng lấy mẫu thuận tiện hoặc lấy mẫu phán đoán để chọn những người mong muốn theo hạn ngạch trên.

Lấy mẫu quả cầu tuyết (snowball sampling)

- Kỹ thuật này thường được dùng khi ta có ít thông tin hoặc khó tiếp cận các phần tử trong tổng thể.
- Khi tìm được phần tử phù hợp đầu tiên, ta sẽ yêu cầu phần tử đó, thường là một người, giới thiệu thêm các phần tử phù hợp khác trong tổng thể mà ta chưa biết hoặc không thể tiếp cận trực tiếp.
- Theo cách này, mẫu sẽ mở rộng nhanh chóng như một quả cầu tuyết.
- Ví dụ, nếu cần phỏng vấn một nhóm người LGBT nhưng không biết họ là ai, ta có thể tìm người đầu tiên để phỏng vấn và lịch sự đề nghị người đó giới thiệu những người LGBT khác trong cộng đồng của họ. Vì vậy, kỹ thuật này cũng được gọi là lấy mẫu giới thiệu (referral sampling).

Nội dung

01 Giới thiệu

02 Làm sạch dữ liệu
(data cleaning)

03 Tích hợp dữ liệu
(data integration)

04 Chuyển dạng dữ liệu
(data transformation)

05 Giảm cỡ dữ liệu
(data reduction)

06 Lấy mẫu dữ liệu
(data sampling)

07 Tài liệu tham khảo và tổng kết

Tài liệu tham khảo

[1] J. Han, M. Kamber, and J. Pei. Data Mining: Concepts and Techniques. Morgan Kaufmann, Elsevier, 2012 [Book1].

[2] C. Aggarwal. Data Mining: The Textbook. Springer, 2015 [Book2].

[3] J. Leskovec, A. Rajaraman, and J. D. Ullman. Mining of Massive Datasets. Cambridge University Press, 2014 [Book3].

[4] M. J. Zaki and W. M. Jr. Data Mining and Analysis: Fundamental Concepts and Algorithms. Cambridge University Press, 2013 [Book4].

[5] D. Easley and J. Kleinberg. Networks, Crowds, and Markets: Reasoning About a Highly Connected World. Cambridge University Press, 2010 [Book5].

[6] J. VanderPlas. Python Data Science Handbook: Essential Tools for Working with Data. O'Reilly, 2017 [Book6].

[7] J. Grus. Data Science from Scratch: First Principles with Python. O'Reilly, 2015 [Book7].

Tổng kết

- Giải thích vì sao tiền xử lý và chuẩn bị dữ liệu là quan trọng trong phân tích và khai phá dữ liệu; cũng như các tác vụ chính trong tiền xử lý dữ liệu như làm sạch dữ liệu, tích hợp dữ liệu, chuyển dạng dữ liệu, giảm cỡ dữ liệu, v.v.
- Các kỹ thuật làm sạch dữ liệu để xử lý giá trị thiếu, giá trị sai và không nhất quán, cũng như xử lý dữ liệu nhiễu.
- Giới thiệu một số khái niệm trong tích hợp dữ liệu như định danh thực thể, phân tích dư thừa và tương quan, trùng lặp bộ dữ liệu, v.v.
- Các khái niệm và kỹ thuật quan trọng trong chuyển dạng dữ liệu, bao gồm chuyển đổi dữ liệu, rời rạc hóa dữ liệu, làm mịn dữ liệu, tổng hợp dữ liệu, co giãn và chuẩn hóa dữ liệu, v.v.
- Các khái niệm và kỹ thuật quan trọng trong giảm cỡ dữ liệu như PCA, lựa chọn tập con thuộc tính, biểu đồ tần suất, phân cụm, tổng hợp khối dữ liệu, cũng như nhiều phương pháp lấy mẫu dữ liệu ngẫu nhiên và không ngẫu nhiên.