Học máy
(Machine Learning)

Tài liệu tham khảo

- Text book
  - Murphy (2012). Machine Learning: A Probabilistic Perspective
  - Bishop (2006). Pattern Recognition and Machine Learning
  - Mitchell (1997). Machine Learning
  - Tiếng Việt (2 cuốn)
- Online Courses and Course Videos
  - Andrew Ng (Stanford) on coursera and youtube

Học máy và AI

- Cải tiến hiệu quả của bài toán thông qua quan sát và sự dạy bảo
- Học máy như là một thành phần quan trọng của AI

Học máy và AI

Artificial Intelligence

Is the field of study

Machine Learning

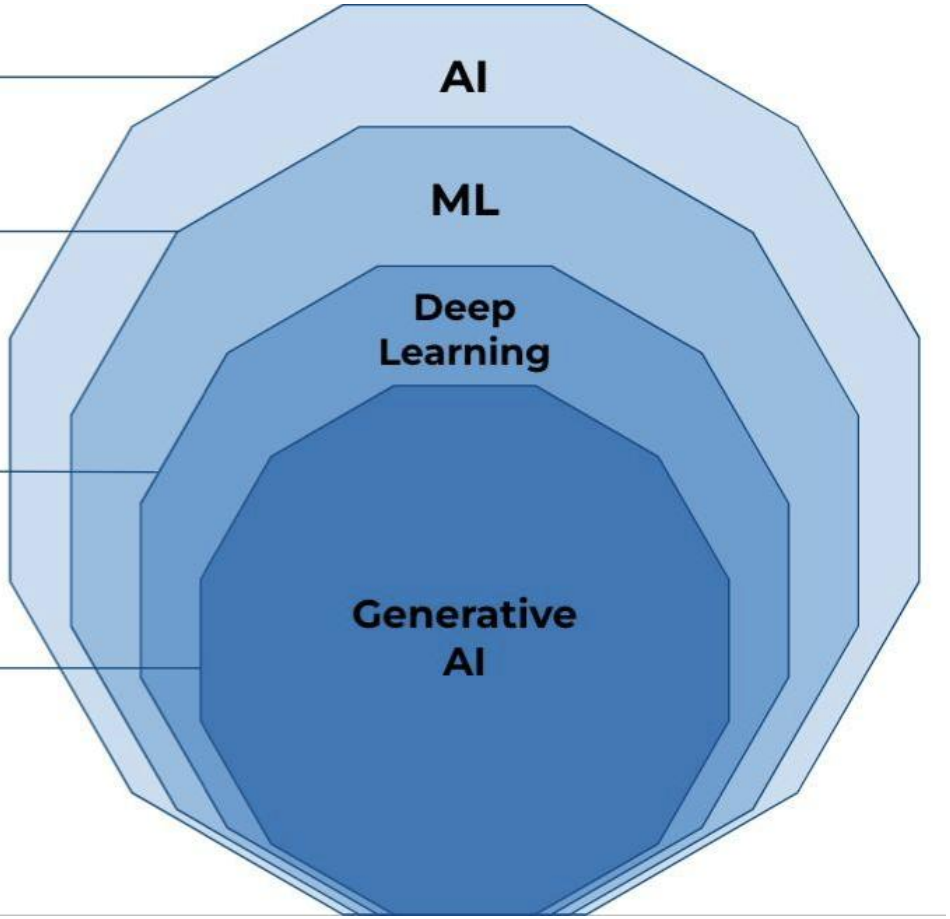
Is a branch of AI that focus on the creation of intelligent machines that learn from data. Another very well know branch inside AI is **Optimization**.

Deep Learning

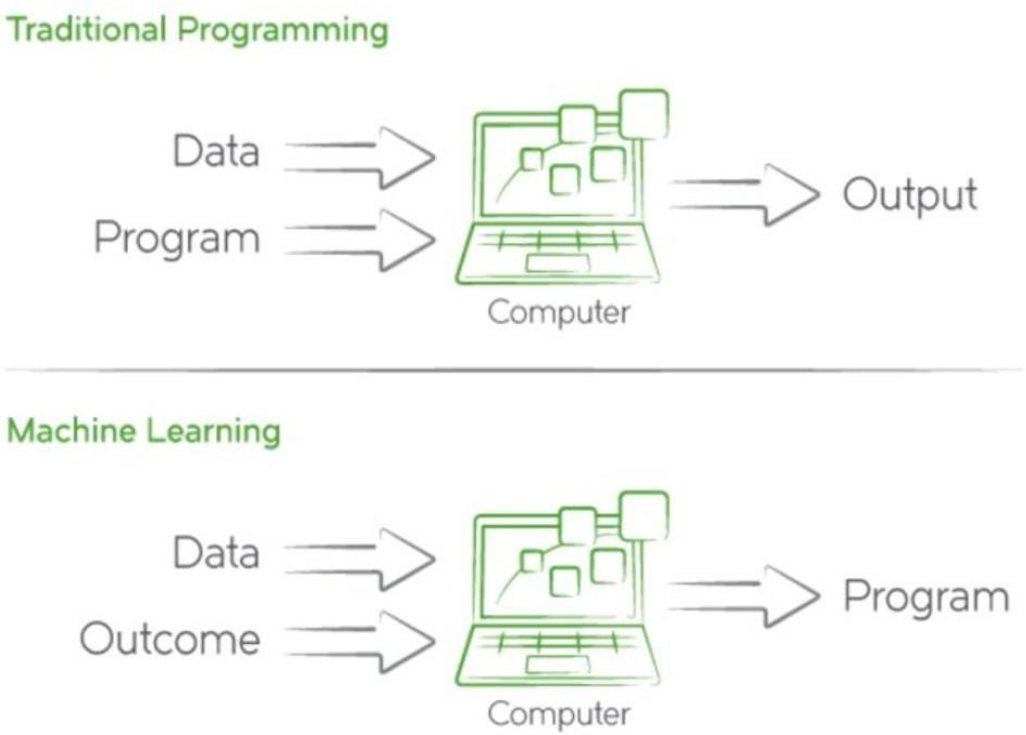
Is a subset of Machine Learning methods, based on **Artificial Neural Networks.** Examples: CNNs, RNNs

Generative AI

A type of ANNs that generate data that is similar to the data it was trained on. Examples: GANs, LLMs



Traditional Programming versus Machine Learning



Tại sao Học máy lại quan trọng

- Kỷ nguyên dữ liệu lớn (**Bigdata**)
  - Hàng nghìn tỉ trang web
  - Hàng giờ video được upload lên Youtobe mỗi giây
  - Walmart xử lý hơn 1M giao dịch trong một giờ và có CSDL hơn 2.5 petabytes (2.5×10^{15}) *lượng thông tin*
- Phát triển hệ thống là quá khó/đắt đỏ để xây dựng trí thức bằng tay bởi vì chúng yêu cầu các kỹ năng cụ thể và chi tiết hoặc điều chỉnh tri thức cho nhiệm vụ cụ thể (***knowledge engineering bottleneck***)

Học máy là gì?

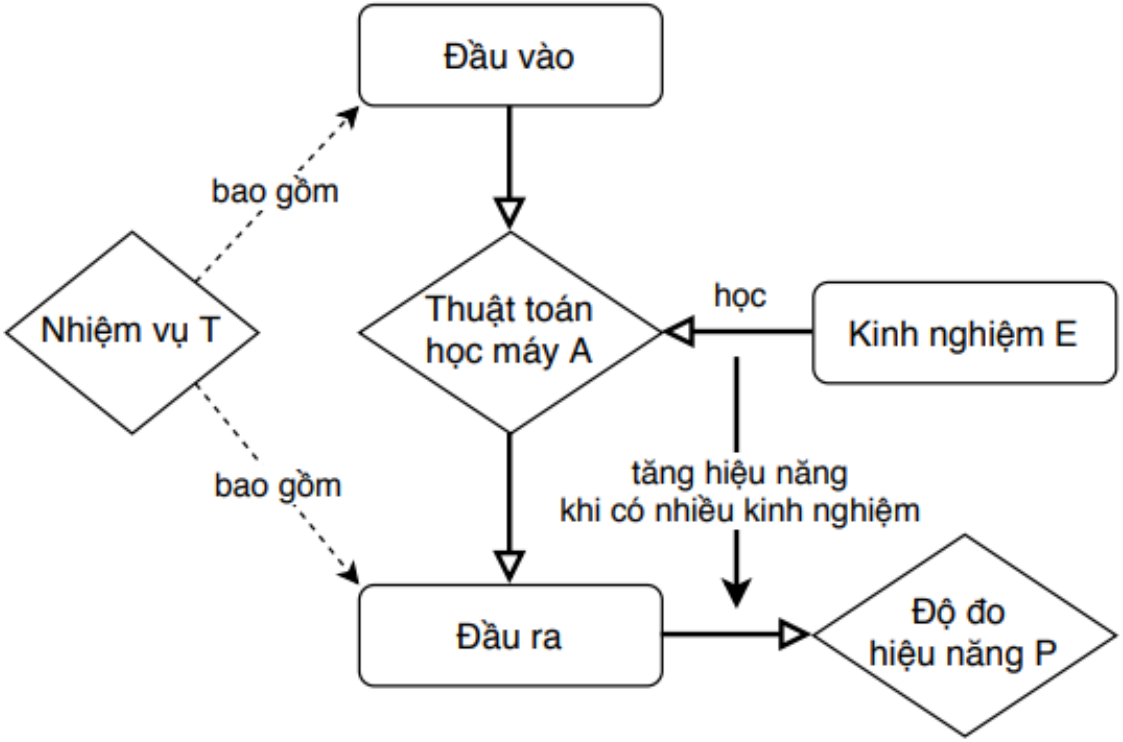
- Học máy (Machine Learning – ML) là một lĩnh vực nghiên cứu của Trí tuệ nhân tạo (Artificial Intelligence – AI)
- Một số định nghĩa về học máy
  - Một quá trình mà một chương trình máy tính cải thiện hiệu suất của nó trong một công việc thông qua kinh nghiệm [Mitchell, 1997]
  - Việc lập trình các máy tính để tối ưu hóa một tiêu chí hiệu suất dựa trên các dữ liệu ví dụ hoặc kinh nghiệm trong quá khứ [Alpaydin, 2004]
  - Học máy như tập các phương pháp có thể tự động xác định các mẫu trong dữ liệu và sau đó sử dụng các mẫu đã phát hiện để dự đoán dữ liệu trong tương lai [Murphy, 2012]
- Biểu diễn một bài toán học máy [Mitchell, 1997]
  - **Một công việc (nhiệm vụ) T**
  - **Đối với các tiêu chí đánh giá hiệu năng P**
  - **Thông qua (sử dụng) kinh nghiệm E**

Học máy là gì?

- Biểu diễn một bài toán học máy [Mitchell, 1997]
  - **Một công việc (nhiệm vụ) T**
  - **Đối với các tiêu chí đánh giá hiệu năng P**
  - **Thông qua (sử dụng) kinh nghiệm E**

- Thuật toán A được coi là học từ kinh nghiệm *E* đối với lớp bài toán (hoặc lớp nhiệm vụ) *T* và độ đo hiệu năng *P* *nếu* hiệu năng đo bằng *P* của A đối với nhiệm vụ trong *T* tăng với kinh nghiệm *E*.

Học máy là gì?

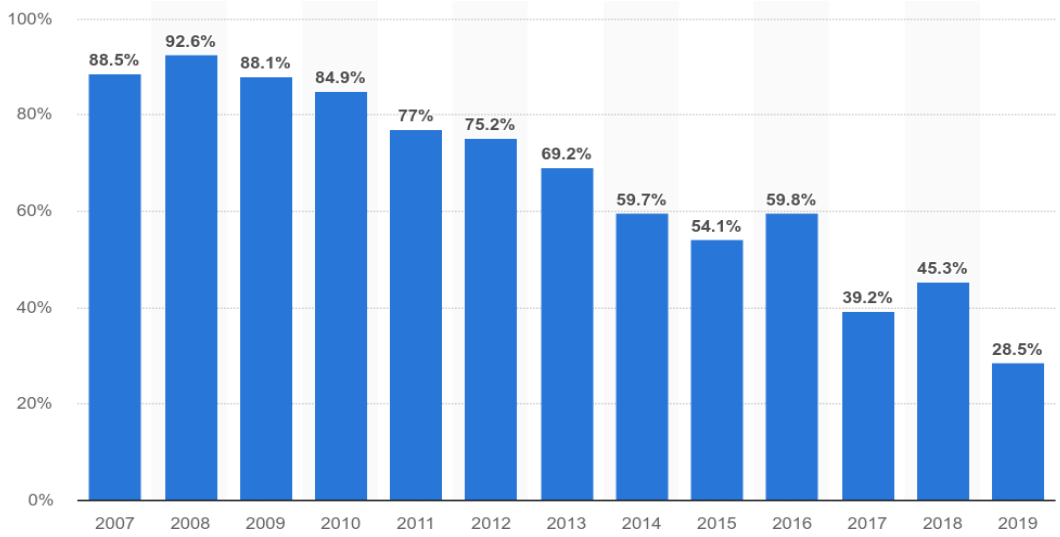


Hình: Giải quyết vấn đề bằng cách tiếp cận Học máy

Ví dụ bài toán học máy (1)

Phân loại thư rác:

- Các chương trình quản lý thư điện tử hiện nay không thể thiếu mô-đun phân loại và lọc thư rác do số lượng thư rác quá lớn.



Hình: Tỉ lệ băng thông email là thư rác.

- Thuật toán lọc thư quan sát và học từ một tập dữ liệu lớn gồm hàng triệu thư điện tử được gán nhãn là thư thường hoặc thư rác.

Ví dụ bài toán học máy (1)

- Lọc thư rác – Email spam filtering
  - ***T: Dự đoán (để lọc) những thư điện*** tử nào là thư rác (spam email)
  - ***P: % of các thư điện tử gửi đến được*** phân loại chính xác
  - ***E: Một tập các thư điện tử (emails)*** mẫu, mỗi thư điện tử được biểu diễn bằng một tập thuộc tính (vd: tập từ khóa) và nhãn lớp (thư thường/ thư rác) tương ứng.

Lọc thư rác (Spam mail Filtering)



Ví dụ bài toán học máy (2)

- Phân loại các trang Web
  - ***T: Phân loại các trang Web theo các chủ đề đã định trước***
  - ***P: Tỷ lệ (%) các trang Web được phân loại chính xác***
  - ***E: Một tập các trang Web, trong đó mỗi trang Web gắn với một* chủ đề**



Pháp luật



TTTM Hải Dương cháy: bà con tiểu thương mất gần 400...

Tuổi Trẻ

TTO - 14g chiều, chủ tịch UBND tỉnh Hải Dương Nguyễn Mạnh Hiển đã chủ trì cuộc họp để nghe...

Thanh Niên

Sau scandal xô xát với Andrea, Yanbi lại...

Infonet

Bị cáo hiếp dâm nằng nặc đòi...cưới nạn...

Thanh Niên

Cháy TTTM Hải Dương: Không loại trừ...

Tiền Phong

Xe khách bốc cháy, 30 người thoát chết

Thể thao



Lương tăng gấp đôi, Ronaldo tuyên bố M.U giờ là quá...

Báo Bóng Đá

Đúng như những gì đã được giới truyền thông Tây Ban Nha tiết lộ, cuối cùng thì BLĐ CLB Real...

Báo Bóng Đá

10 ngôi sao "ích kỉ" nhất làng bóng đá...

Khampha.vn

Công Vinh tiếp tục bị "đày" ở ghế dự bị

Khampha.vn

ĐT nữ Việt Nam thắng đậm Jordan 4-0

Sohanews

Chế - Vui - Độc: "Nhà hát" Old Trafford...

Giải trí



Quang Lê tái xuất sau tai nạn

Zing

Chưa đầy 24 tiếng sau vụ tai nạn trên đường cao tốc từ San Jose về Quận Cam, giọng ca "Đập vỡ cây đàn" đã quay lại sân khấu.



Sohanews

Thủy Tiên kéo áo, khoe chân dài thẳng tắp

Eva.vn

"Cười vỡ bụng" sao Việt bị dìm hàng tuần qua

Phunutoday.vn

Ngôi sao đen Yanbi, Phương Trinh còn trong sáng...

Zing

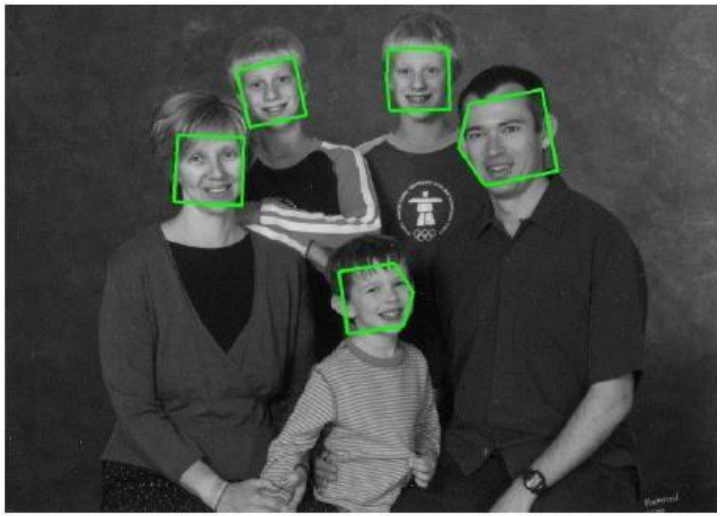
5 nhân vật đại hiệp hấp dẫn phụ nữ nhất phim...

Ví dụ bài toán học máy (3)

- Nhận dạng mặt người
  - ***T: Nhận dạng mặt người trên các bức ảnh đã cho trước***
  - ***P: Tỷ lệ (%) độ chính xác mặt người nhận dạng được các bức ảnh***
  - ***E: Một tập các khuôn mặt người đã được xác định trước.***

Nhận dạng khuôn mặt người



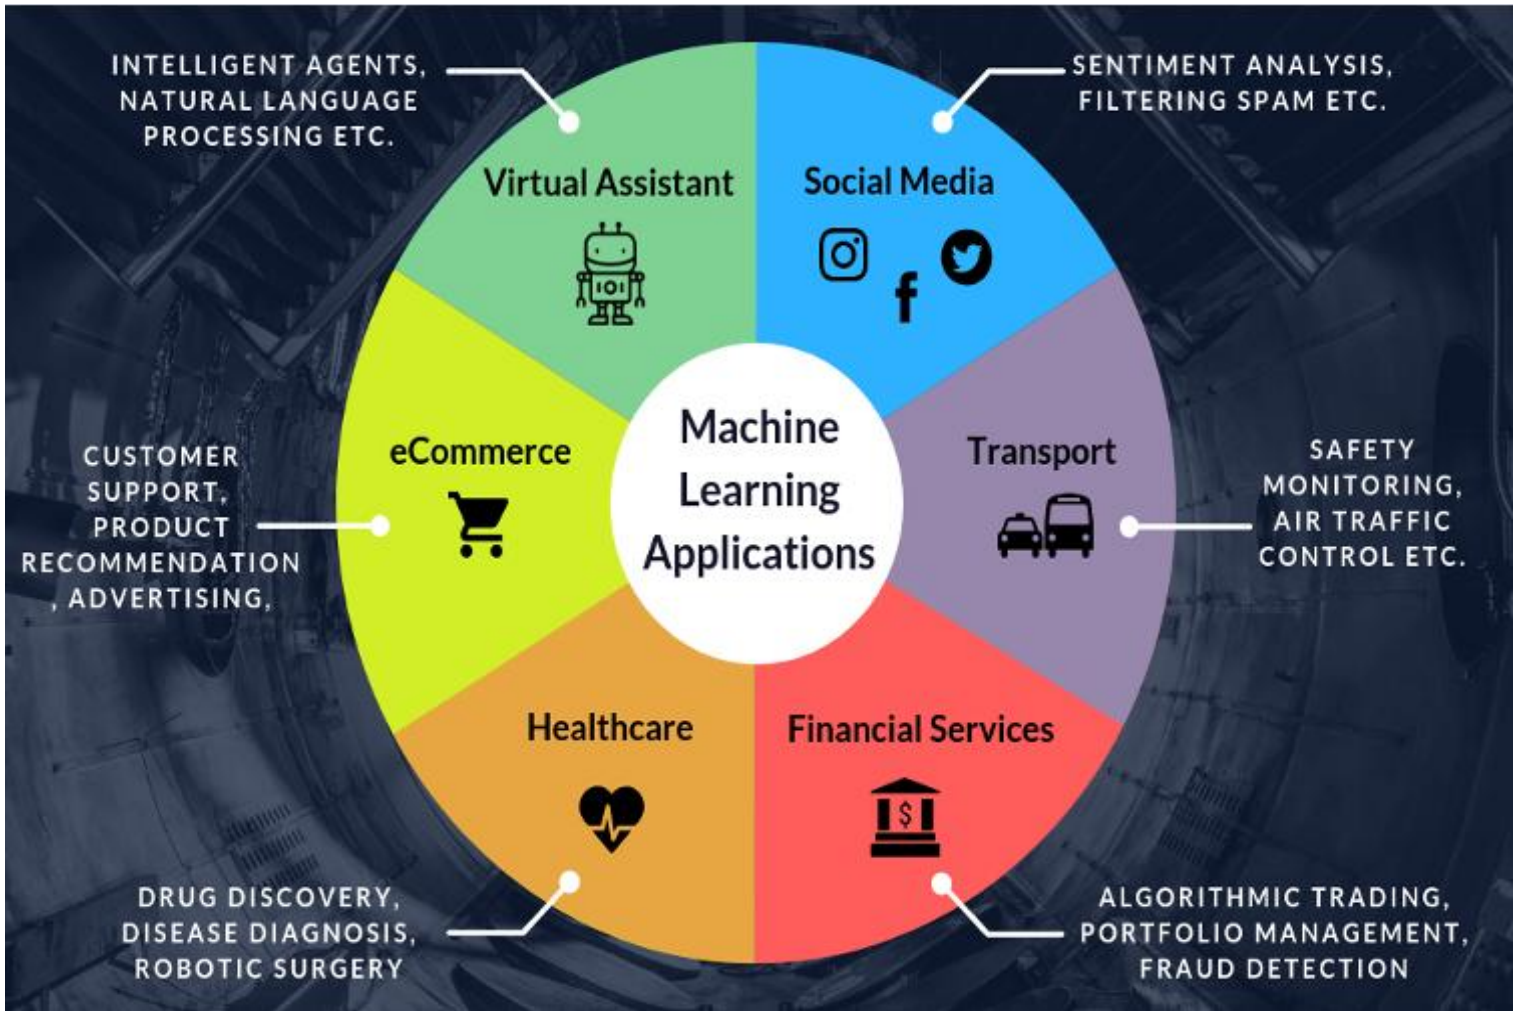


K. Murphy & Family



Based on classifiers trained from tens of thousands of example faces (Viola & Jones, 2004)

Ứng dụng của Học Máy



Ứng dụng của Học Máy

- **Viễn thám**: phân tích ảnh chụp từ trên cao …
- **Nhận dạng** (Pattern Recognition): nhận dạng tiếng nói, chữ viết tay, vân tay,
- **Thị giác máy** (Computer Vision) …
- **Xử lý ngôn ngữ tự nhiên** (Natural Language Processing): xử lý văn bản, giao tiếp người – máy, …
- **Tìm kiếm** (Search Engine, Ranking, Information Retrieve)
- **Chẩn đoán trong y tế**: phân tích ảnh X-quang, các hệ chuyên gia chẩn đoán tự động.
- **Tin sinh học**: phân loại chuỗi gene, quá trình hình thành gene/protein
- **Phát hiện gian lận tài chính** (financial fraud): gian lận thẻ tín dụng
- **Phân tích thị trường chứng khoán** (stock market analysis)
- **Chơi trò chơi**: tự động chơi cờ, hành động của các nhân vật ảo
- **Rôbốt**: là tổng hợp của rất nhiều ngành khoa học, trong đó *học máy* tạo nên hệ thần kinh/bộ não của người máy.

Khi nào thì Học máy là lựa chọn tốt?

- *Nhiệm vụ quá phức tạp để lập trình tường minh*
- *Nhiệm vụ thay đổi thường xuyên*: Một số bài toán thường xuyên thay đổi theo thời gian khiến cho chương trình phải cập nhật liên tục. Ví dụ như khi phân tích một trang web để tìm ra giá cả của sản phẩm
- *Nhiệm vụ là vấn đề nhận thức*: Ngày nay, khi làm việc với văn bản, ảnh, âm thanh hoặc phim, các mô hình Học máy đã thực hiện các nhiệm vụ nhận thức trên ở mức độ xấp xỉ khả năng của con người

Khi nào thì Học máy là lựa chọn tốt?

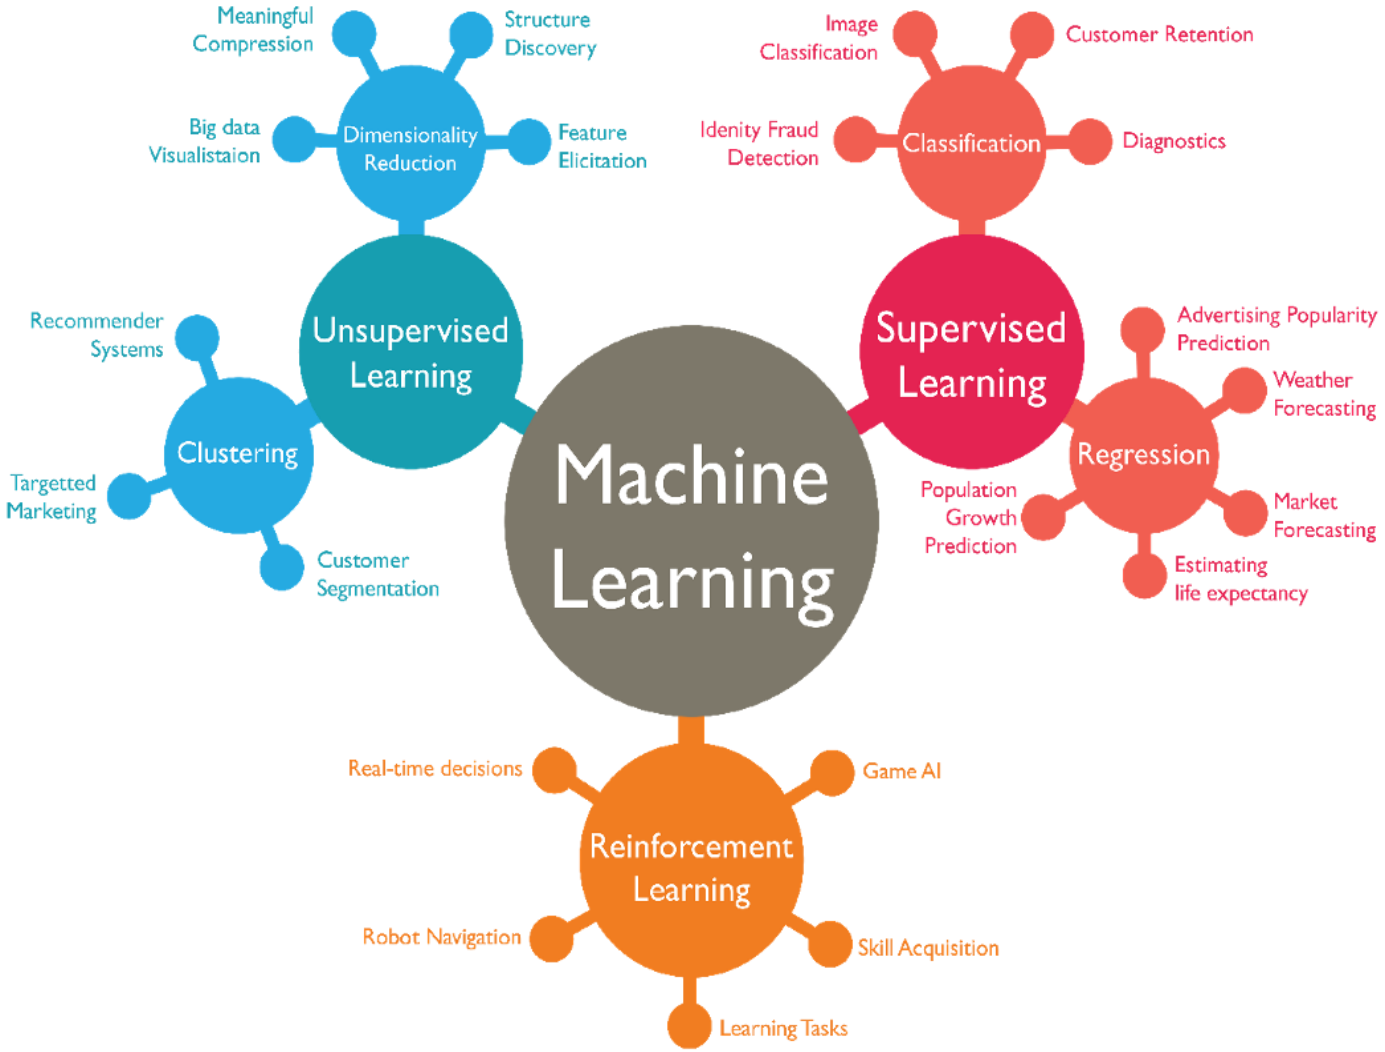
- *Nhiệm vụ quá phức tạp để lập trình tường minh*
- *Nhiệm vụ thay đổi thường xuyên*
- *Nhiệm vụ là vấn đề nhận thức*
- *Nhiệm vụ chưa được nghiên cứu kỹ lưỡng*: Với các hiện tượng chưa được khoa học giải thích kỹ nhưng lại có dữ liệu
- *Nhiệm vụ có mục tiêu đơn giản*: Học máy ngày nay đặc biệt tốt trong trường hợp đầu ra cần đạt của nhiệm vụ là các câu trả lời Có hoặc Không hoặc một con số.

❖Khi quyết định lựa chọn cách tiếp cận Học máy để giải quyết một bài toán thực tế, chúng ta cũng cần cần tính đến các chi phí khi sử dụng Học máy, bao gồm: chi phí thu thập, chuẩn bị và làm sạch dữ liệu; chi phí huấn luyện mô hình; và chi phí triển khai, sử dụng, giám sát và bảo trì mô hình.

Cách tiếp cận tổng quát

- Phát biểu bài toán (Formulate task)
- Mô hình học (tham số, cấu trúc)
- Thu thập dữ liệu
- Biểu diễn dữ liệu của bài toán như thế nào? (đặc trưng/ giá trị)
- Gán nhãn dữ liệu
- Học mô hình với dữ liệu (huấn luyện)
- Sử dụng mô hình để phân lớp hoặc đoán dữ liệu mới (kiểm thử)
- Đánh giá độ chính xác

Phân loại các hệ thống học máy?



Học có giám sát

- **Mục tiêu**: Học ánh xạ từ không gian đầu vào đến không gian mục tiêu.
- Dữ liệu là các cặp $E = \{(x_i, y_i)\}$ với x_i gọi là dữ liệu/đặc trưng đầu vào (input) và y_i là dữ liệu mục tiêu hoặc nhãn (target).
  - Phân lớp: Khi ($y \in \{1, 2, \ldots, C\} = C$))
  - Hồi qui: Khi ($y \in \mathrm{R}$)



(a) Coin Price Prediction

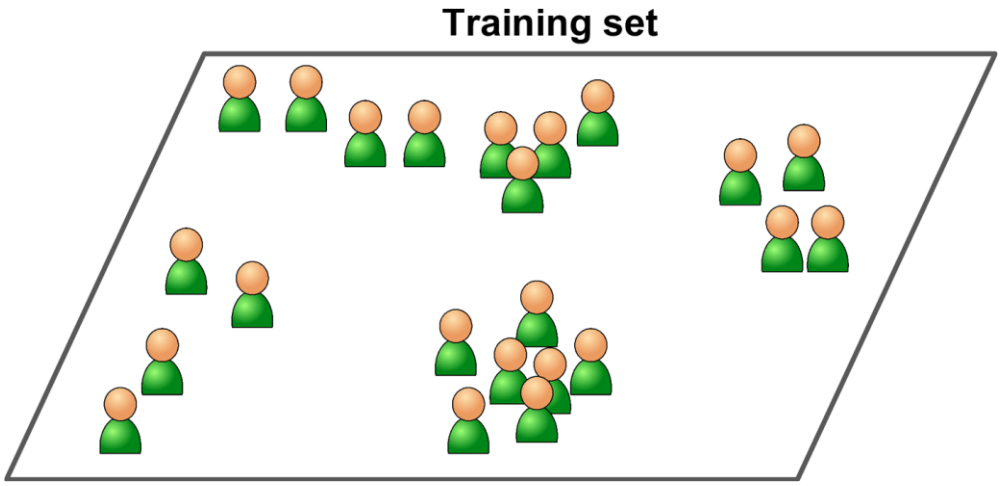


(b) Emotion Classification

Học không giám sát

Đặc điểm của các bài toán học không giám sát là không có dữ liệu về đầu ra mong muốn (tập Y). Có ba loại bài toán chính trong Học không giám sát, bao gồm:

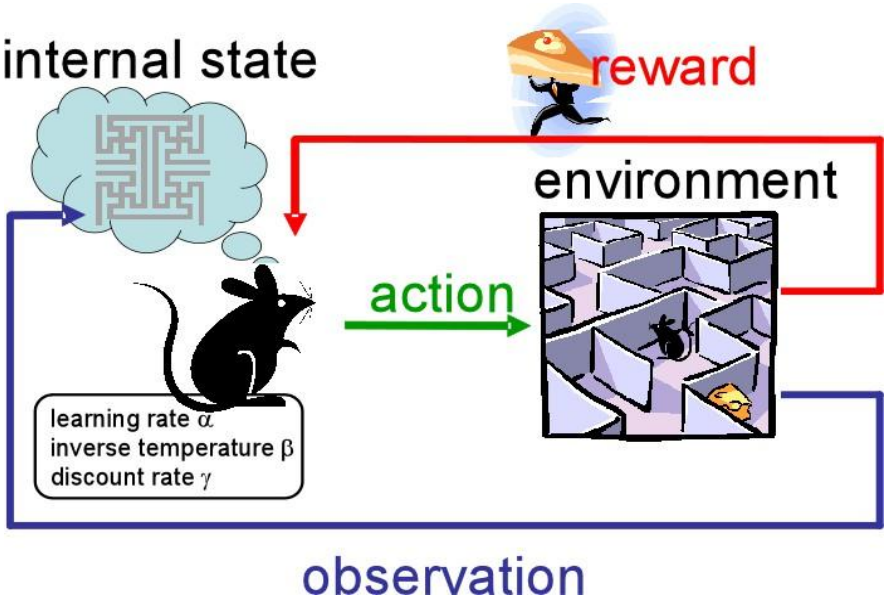
- *Phân cụm*: Tìm kiếm các nhóm, các cụm "gần nhau" trong dữ liệu;
- *Ước lượng mật độ*: Ước lượng phân bố xác suất của dữ liệu.
- *Trích xuất đặc trưng*: Tìm kiếm các đặc trưng quan trọng, các biểu diễn ẩn của dữ liệu.



An unlabeled training set for unsupervised learning

Học tăng cường

- Đưa ra các quyết định để tối ưu hoá một hàm mục tiêu dựa trên thông tin đầu vào.
- So với học có giám sát: các hành động có tính thứ tự, nguyên nhân-hệ quả.
- So với học không giám sát: có thông tin trả về để định hướng kết quả cần thiết của mô hình.

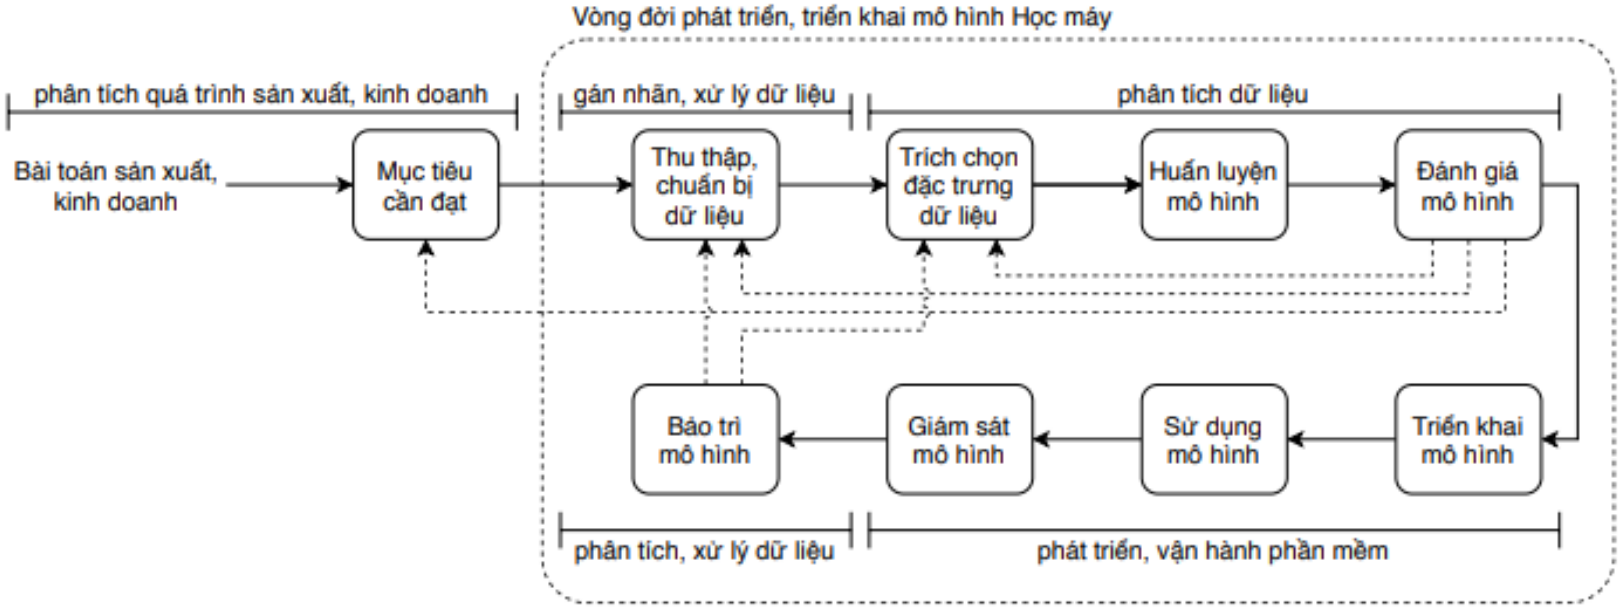


Một số bài toán khác

- Học bán giám sát: có cả dữ liệu có nhãn và dữ liệu chưa gán nhãn.
- Học tự giám sát: sử dụng chính dữ liệu đầu vào x để chế tạo ra đầu ra $y = f(x)$ (có thể $y = x$). Sau đó sử dụng Học có giám sát trên tập dữ liệu gồm các cặp (x, y).
- Học đa nhiệm vụ: với cùng một đầu vào, mô hình tính toán ra nhiều đầu ra khác nhau, với
  $y = (y_1, y_2, \ldots, y_K) \in \mathcal{Y} = \mathcal{Y}_1 \times \mathcal{Y}_2 \ldots \mathcal{Y}_K$ với
  $\mathcal{Y}_k, k = 1, \ldots, K$ là tập đầu ra của nhiệm vụ thứ k.
- Học chủ động: Đây là kỹ thuật Học máy cho phép mô hình đưa ra yêu cầu gán nhãn hoặc làm rõ thông tin về những dữ liệu mà mô hình còn cảm thấy mơ hồ, khó đưa ra dự đoá
- Học trực tuyến: Đây là kỹ thuật huấn luyện, cập nhật tham số của mô hình học máy ngay khi có dữ liệu mới.

Quá trình phát triển mô hình học máy

Một vòng đời phát triển và triển khai mô hình học máy



Hình: Quá trình phát triển, triển khai mô hình Học máy.

Quá trình phát triển mô hình học máy

Một vòng đời phát triển và triển khai mô hình học máy:

1. *Thu thập và chuẩn bị*: Dữ liệu được thu thập, lưu trữ và làm sạch.
2. *Trích chọn đặc trưng dữ liệu*: Tìm kiếm, trích xuất các đặc tính quan trọng từ dữ liệu thu thập được.
3. *Huấn luyện mô hình*: Dữ liệu được chia thành hai phần: một phần dùng để huấn luyện mô hình, một phần dùng để đánh giá hiệu năng của mô hình. Mô hình được huấn luyện trên dữ liệu huấn luyện, sau đó được đánh giá hiệu năng trên dữ liệu đánh giá.
4. *Đánh giá mô hình*: Mô hình được đánh giá hiệu năng dựa trên các tiêu chí như độ chính xác, độ hài lòng, thời gian chạy, độ phức tạp, độ tin cậy, độ ổn định.

Quá trình phát triển mô hình học máy

Một vòng đời phát triển và triển khai mô hình học máy:

5. *Triển khai mô hình*: Mô hình được triển khai vào môi trường thực tế, sẵn sàng phục vụ người dùng. Cần chú ý đến các vấn đề như hiệu năng, bảo mật và tính ổn định của mô hình.
6. *Sử dụng mô hình*: Mô hình được sử dụng để giải quyết các vấn đề thực tế, đưa ra dự đoán, phân loại, gợi ý, tối ưu hóa, phân cụm, phân tích dữ liệu.
7. *Giám sát mô hình*: Mô hình cần được giám sát thường xuyên theo các tiêu chí đề ra ban đầu của mô hình.
8. *Bảo trì mô hình*: Mô hình cần được bảo trì, cập nhật để đảm bảo giữ được hiệu suất. Đặc biệt, khi dữ liệu thay đổi.

Ví dụ: Phân loại ảnh

input	desired output
	apple
	pear
	tomato
	cow
	dog
	horse

Dữ liệu huận luyện (Training data)



apple

pear

tomato

cow

dog

horse

Kiến trúc hệ thống học máy

Learning(Học)

Training Samples



Training Labels



Features

Training

Learned model

Inference(Dự đoán)



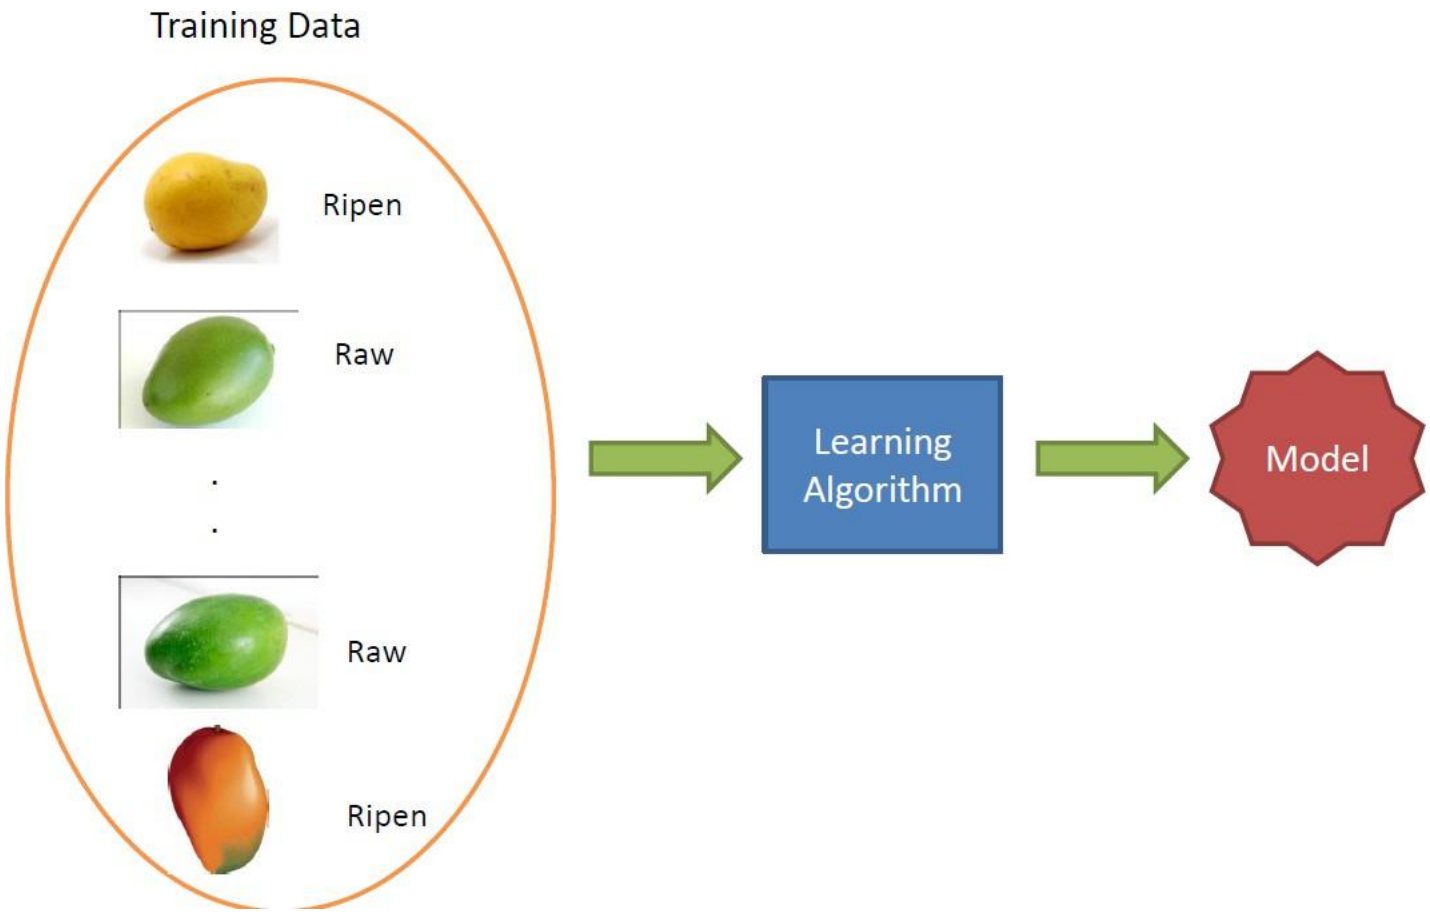
Test Sample

Features

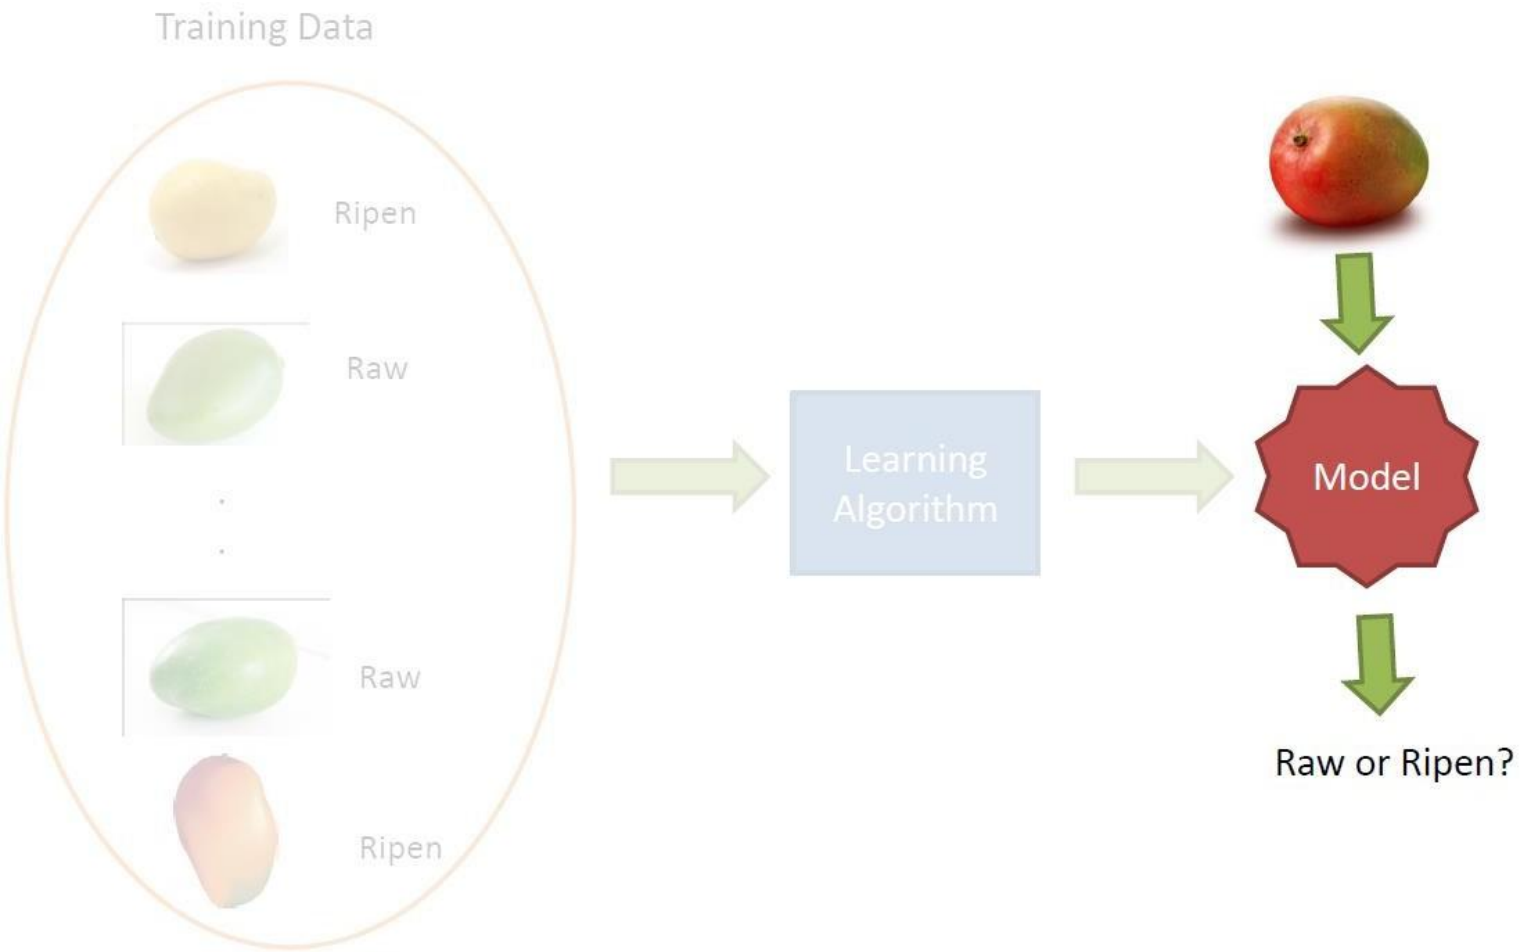
Learned model

Prediction

Ví dụ (chín hay xanh)



Ví dụ (chín hay xanh)



D_n Training data set (training set)

Number of examples: n

inputs: (what we observe) | targets: (what we must predict)



"horse"



"cat"

etc...



"horse"

Turn it into a nice data matrix...

preprocessing, feature extraction

dimensionality: d

	inputs: X (input feature vector)	targets: Y (label)	
X_1	(3.5, -2, ... , 127, 0, ...)	+1	Y
	(-9.2, 32, ... , 24, 1, ...)	-1	
	etc...		
X_n	(6.8, 54, ... , 17, -3, ...)	+1	Y_n

$X_{n,2}$

New test point:



→ ?

$\mathbf{x} = (5.7, -27, \ldots, 64, 0, \ldots) \xrightarrow{f_\theta} +1$

$\mathbf{x} \in \mathbb{R}^d$

Importance of the Problem dimensions

⇨ Détermines which learning algorithms will be practically applicable (based on their algorithmic complexity and memory requirements).

- Number of examples: **n**
  (sometimes several millions)
- Input dimensionality: **d**
  number of input features characterizing each example
  (often 100 to 1000, sometimes 10000 or much more)
- Target dimensionality ex. number of classes **m**
  (often small, sometimes huge)

→ Data suitable for ML will often be organized as a matrix: n x (d+1) ou n x (d+m)

Learning phases

- **Training:** we learn a predictive function f_θ by optimizing it so that it predicts well on the training set.
- **Use for prediction:** we can then use f_θ on new (test) inputs that were not part of the training set.

➡ The GOAL of learning is NOT to learn perfectly (memorize) the training set.

➡ What's important is the ability for the predictor to **generalize** well on new (future) cases.

Expected risk v.s. Empirical risk

- **Generalization error = Expected risk**

$$R(f) = \mathbb{E}_{p(\mathbf{x},\mathbf{y})}[L(f(\mathbf{x}), \mathbf{y})]$$

- **Empirical risk:** average loss on a finite dataset.

$$\hat{R}(f, D) = \frac{1}{|D|} \sum_{(\mathbf{x},\mathbf{y}) \in D} L(f(\mathbf{x}), \mathbf{y})$$

Learning Function f_θ

Supervised task:

predict y from x

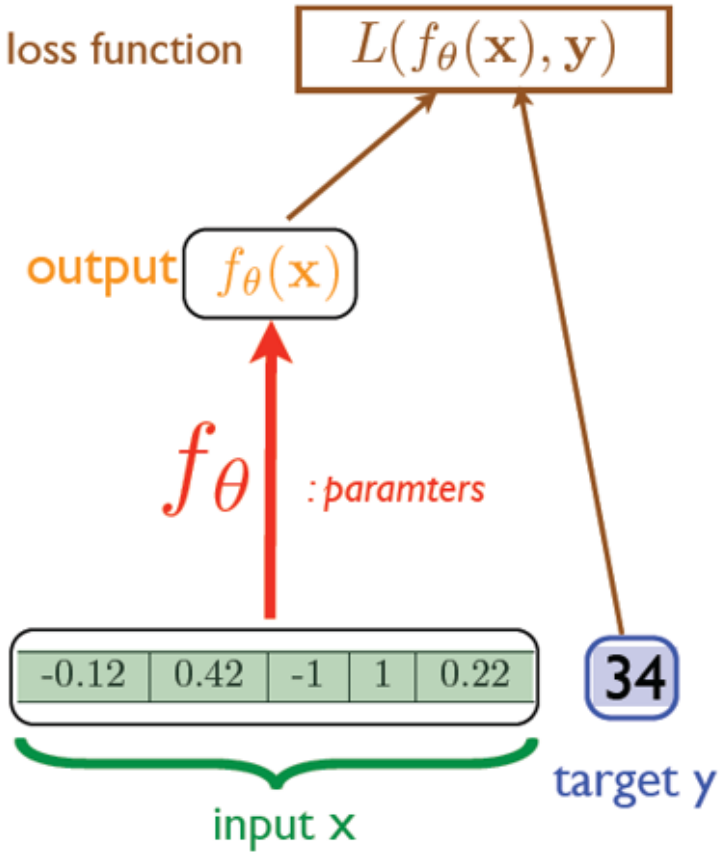
input $\mathbf{x} \in \mathbb{R}^d$ | target (label) y

n examples

x_1	x_2	x_3	x_4	x_5	t
0.32	-0.27	+1	0	0.82	113
-0.12	0.42	-1	1	0.22	34
0.06	0.35	-1	1	-0.37	56
0.91	-0.72	+1	0	-0.63	77
...	...	...	...	...	...

Training set D_n

Learn a function f_θ that will minimize prediciton errors as measured by cost (loss) L



Đánh giá hệ thống học máy

- **Độ chính xác của phân lớp** (Classification Accuracy)
- Tính đúng đắn của giải pháp (Solution correctness)
- Chất lượng của giải pháp (Solution quality (length, efficiency))
- Tốc độ thực hiện (Speed of performance)

Đánh giá hệ thống học máy

- **Độ chính xác của phân lớp** (Classification Accuracy)
- Tính đúng đắn của giải pháp (Solution correctness)
- Chất lượng của giải pháp (Solution quality (length, efficiency))
- Tốc độ thực hiện (Speed of performance)

Các vấn đề trong Học máy (2)

- Các ví dụ học (Training examples)
  - Bao nhiêu ví dụ học là đủ?
  - Kích thước của tập học (tập huấn luyện) ảnh hưởng thế nào đối với độ chính xác của hàm mục tiêu học được?
  - Các ví dụ lỗi (nhiễu) và/hoặc các ví dụ thiếu giá trị thuộc tính (missing-value) ảnh hưởng thế nào đối với độ chính xác?

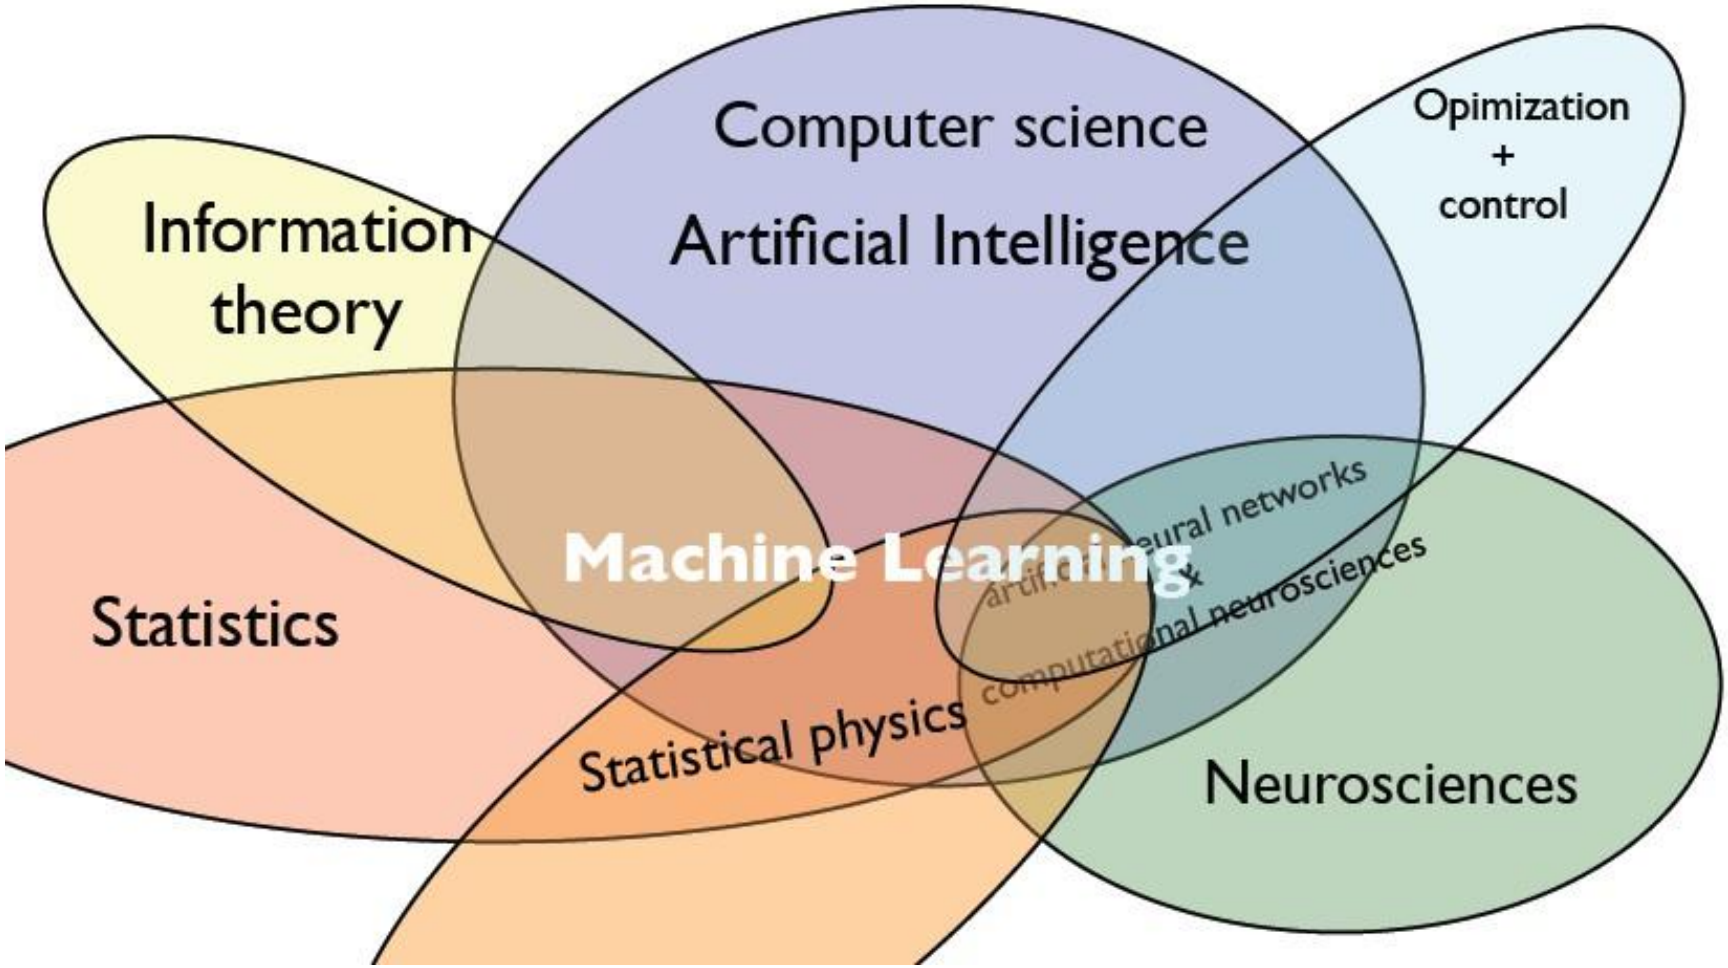
Các vấn đề trong Học máy (3)

- Quá trình học (Learning process)
  - Chiến lược tối ưu cho việc lựa chọn thứ tự sử dụng (khai thác) các ví dụ học?
  - Các chiến lược lựa chọn này làm thay đổi mức độ phức tạp của bài toán học máy như thế nào?
  - Các tri thức cụ thể của bài toán (ngoài các ví dụ học) có thể đóng góp thế nào đối với quá trình học?

Các vấn đề trong Học máy (4)

- Khả năng/giới hạn học (Learning capability)
  - Hàm mục tiêu nào mà hệ thống cần học?
    - Biểu diễn hàm mục tiêu: Khả năng biểu diễn (vd: hàm tuyến tính / hàm phi tuyến) vs. Độ phức tạp của giải thuật và quá trình học
  - Các giới hạn (trên lý thuyết) đối với khả năng học của các giải thuật học máy?
  - Khả năng khái quát hóa (generalize) của hệ thống từ các ví dụ học?
    - Để tránh vấn đề "over-fitting" (đạt độ chính xác cao trên tập học, nhưng đạt độ chính xác thấp trên tập thử nghiệm)
  - Khả năng hệ thống tự động thay đổi (thích nghi) biểu diễn (cấu trúc) bên trong của nó?
    - Để cải thiện khả năng (của hệ thống đối với việc) biểu diễn và học

Current view of ML founding disciplines



Môn học liên quan

- Artificial Intelligence
- Data Mining
- Probability and Statistics
- Information theory
- Numerical optimization
- Computational complexity theory
- Control theory (adaptive)
- Psychology (developmental, cognitive) (Tâm lý học)
- Neurobiology (Thần kinh học)
- Linguistics
- Philosophy (Triết học)

Tài liệu tham khảo

- Slides bài giảng Học Máy – Nguyễn Nhật Quang – ĐHBK Hà Nội
- Slides bài giảng của một số trường đại học trên thế giới.