XỬ LÝ NGÔN NGỮ TỰ NHIÊN

Trắc nghiệm

Câu 1. Mô hình CBOW học ra biểu diễn vector của từ dựa trên bài toán phân lớp nào?
a) Dự đoán từ xuất hiện kế tiếp biết các từ đằng trước nó.
b) Dự đoán việc đồng xuất hiện của cặp từ bao gồm từ trung tâm và từ ngữ cảnh của nó (trong một cửa sổ nhất định, ví dụ ± 2 từ).
c) Dự đoán từ trung tâm biết các từ ngữ cảnh (trong một cửa sổ nhất định, ví dụ ± 2 từ).
d) Che đi (mask) một số từ trong input và dự đoán nó dựa vào một trong các kiến trúc encoder, encoder-decoder, decoder.

Câu 2. Trong công thức sau đây (theo mô hình CBOW), nhận định trực quan nào sau đây về giá trị của tích vô hướng $u_c^T \bar{v}_o$ là đúng:

$$P(w_c|W_o) = \frac{\exp(u_c^T \bar{v}_o)}{\sum_{i \in V} \exp(u_i^T \bar{v}_o)}$$

$$W_o = \{w_{o1}, \dots, w_{o2m}\} \text{ and } \bar{v} = (v_{o1} + \cdots + v_{o2m})/(2m)$$

a) Giá trị tích vô hướng trên là lớn, thể hiện sự tương tự cao giữa hai vector từ, nếu W_o không là ngữ cảnh của w_c.
b) Giá trị tích vô hướng trên là lớn, thể hiện sự tương tự cao giữa hai vector từ, nếu W_o là ngữ cảnh của w_c.
c) Giá trị tích vô hướng trên là nhỏ, thể hiện sự tương tự cao giữa hai vector từ, nếu W_o là ngữ cảnh của w_c.
d) Giá trị tích vô hướng trên không liên quan đến sự tương tự giữa hai vector từ (biểu diễn W_o và w_c).

Câu 3. Hàm loss cross entropy có được sử dụng huấn luyện mô hình CBOW không?
a) Có, vì đầu ra là softmax và nhãn chuẩn được convert sang biểu diễn vector dạng one-hot nên dùng hàm loss cross entropy thuận tiện cho việc đo lường độ chênh lệch và tối ưu hóa nó trong quá trình huấn luyện.
b) Không cần, vì đã biết trước từ trung tâm nên không cần tính loss, chỉ cần tính likelihood.
c) Không cần, vì bài toán phân lớp là nhị phân.
d) Không cần, vì người ta hay sử dụng hàm loss bình phương trung bình hoặc hàm loss 0-1.

Câu 4. Phát biểu nào sau đây về độ đo BLEU là chính xác nhất:

a) BLEU so sánh kết quả dịch của máy với câu dịch chuẩn (do người dịch), và tính ra độ tương tự dựa trên khoảng cách soạn thảo (edit distance) giữa cặp câu này.
b) BLEU so sánh kết quả dịch của máy với câu dịch chuẩn (do người dịch), và tính ra độ tương tự cosine giữa vector biểu diễn câu máy dịch với vector biểu diễn câu người dịch.
c) BLEU so sánh kết quả dịch của máy với câu dịch chuẩn (do người dịch), và tính ra độ tương tự dựa trên mức độ trùng khớp các ngram (n thường từ 1 đến 3, 4) giữa cặp câu này.

d) BLEU so sánh kết quả dịch của máy với câu dịch chuẩn (do người dịch), và tính ra độ tương tự dựa trên mức độ trùng khớp các ngram (n thường từ 1 đến 3, 4) giữa cặp câu này. BLEU cũng phạt các câu dịch quá ngắn.

Câu 5. Hệ dịch máy nơ-ron (NMT) thường sử dụng thuật toán giải mã dựa vào tìm kiếm beam (beam search). Giả sử kích thước từ vựng là V, kích thước beam là k. Ở bước giải mã thứ t (t>1), số từ dịch phải xem xét sẽ là:

a) V^t
b) $k \times V$
c) k^t
d) $t \times V$

Câu 6. Phát biểu nào sau đây về họ các mô hình pretrain GPT là hợp lý nhất:

a) Kiến trúc huấn luyện là decoder, mô hình học máy thường là Transformer, quá trình pretrain về bản chất là huấn luyện mạng nơ-ron Transformer để học mô hình ngôn ngữ, cụ thể học ra $p_\theta(w_t|w_{1:t-1})$ để dự đoán từ tiếp theo w_t biết các từ trước đó $w_{1:t-1}$.
b) Kiến trúc huấn luyện là encoder, mô hình học máy thường là Transformer, quá trình pretrain về bản chất là huấn luyện mạng nơ-ron Transformer để học mô hình ngôn ngữ có mặt nạ (masked language model), cụ thể học ra $p_\theta(x|\tilde{x})$, trong đó $\tilde{x}$ là phiên bản đã bị che đi một số phần của *x*.
c) Kiến trúc huấn luyện là encoder-decoder, mô hình học máy là Transformer, quá trình pretrain về bản chất là huấn luyện hai mạng nơ-ron Transformer để học cách biến đổi sequence-to-sequence. Dữ liệu huấn luyện có thể là các cặp văn bản bị che-phần bị che, hoặc là các cặp câu song ngữ, hoặc là các cặp câu hỏi-câu trả lời, …
d) Kiến trúc huấn luyện có thể theo một trong các kiến trúc encoder, encoder-decoder, decoder.

Tự luận

Bài 1. *Ngram*

a) Giả sử bạn huấn luyện một mô hình ngôn ngữ bigram trên một corpus có V từ khác nhau. Hãy viết công thức tính xác suất P(w2|w1) trong đó w2 là từ đi sau w1 trong bigram w1w2. Sử dụng hàm c để thể hiện tần suất của một từ hay một bigram. Trong trường hợp sử dụng kỹ thuật add-one smoothing, hãy viết lại công thức tính P(w2|w1).
b) Cho corpus sau đây:
<s> con kiến mà leo cành đa </s>
<s> leo phải cành cụt leo ra leo vào </s>
<s> con kiến mà leo cành đào </s>
<s> leo phải cành cụt leo vào leo ra </s>
Sử dụng mô hình ngôn ngữ bigram với kỹ thuật add-one smoothing, hãy tính xác suất câu "<s> *con kiến leo cành cụt* </s>". Lưu ý <s> và </s> được đếm như các từ khác.

Bài 2. *Văn phạm phi ngữ cảnh (CFG)*

Cho văn phạm phi ngữ cảnh sau:

S -> NP VP | NP AP	P -> *chúng tôi*
NP -> N | N PP | P	N -> *hàng* | *thuyền* | *ông* | *ông già*
VP -> V NP | V NP PP | V AP | R V NP R	V -> *chuyển* | *đi*

PP -> E NP AP -> A R | A R AP	E -> *xuống* A -> *già* | *nhanh* R -> *đi* | *quá*

Hãy vẽ cây cú pháp cho hai câu sau:

a) Chúng tôi chuyển hàng xuống thuyền

b) Ông già đi nhanh quá

c) Cho biết mỗi câu ở a) và b) có nhập nhằng hay không và mô tả chúng.

Bài 3. *Dạng chuẩn Chomsky*

a) Thế nào là văn phạm ở dạng chuẩn Chomsky?

b) Hãy chuyển văn phạm sau về dạng chuẩn Chomsky

S -> NP VP RP RP -> R | ε NP -> N | N A VP -> V NP | R V NP	N -> *bò* | *cỏ* A -> *vàng* | *non* V -> *gặm* R -> *thường*

Bài 4. *Thuật toán CKY*

Cho văn phạm phi ngữ cảnh xác suất sau:

S → NP VP 0.9 S → VP 0.1 VP → V NP 0.5 VP → V 0.1 VP → V @VP_V 0.3 VP → V PP 0.1 @VP_V → NP PP 1.0 NP → NP NP 0.1 NP → NP PP 0.2 NP → N 0.7 PP → P NP 1.0	N → *bác* 0.5 N → *bảo_vệ* 0.2 N → *hàng* 0.2 N → *tàu* 0.1 V → *bác* 0.1 V → *bảo_vệ* 0.6 V → *hàng* 0.3 P → *trên* 1.0

Hãy áp dụng thuật toán CKY để phân tích câu "*bác bảo_vệ bảo_vệ hàng*" bằng cách điền vào bảng sau:

Bài 5. *BPE*
Cho corpus sau:

love lover loving cook cooking

Hãy áp dụng thuật toán BPE để xác định từ vựng có kích thước là 15 từ tố.